

AI的本质是内存——推理时代学习笔记

副标题：从“HBM之父”金正浩访谈出发——训练与推理、内存三部曲（HBM/HBF/HBS）与受益者图谱

整理日期：2026年7月7日 · 数据与行情信息均为截至整理日的时点信息

阅读提示：本笔记由一次围绕金正浩访谈（华尔街见闻，2026年7月）的连续问答重组而成，按“基础概念 → 产业事件 → 未来路线 → 应用浪潮 → 受益者 → 全景总结”的认知阶梯排列，不按聊天顺序。每章开头保留你当时的提问。涉及股票与行业判断的内容仅供学习，不构成投资建议。

目录

- 第一章 训练与推理：瓶颈在哪，老GPU能翻身吗
- 第二章 GPU与HBM的本质区别：“外通死局”与功率密度
- 第三章 GPU与HBM的配比：焊死的图纸与换代的弹性
- 第四章 时代分水岭：推理时代从哪天开始算
- 第五章 需求的数学：每年翻倍、十年千倍是怎么算的
- 第六章 HBF：给NAND抄HBM的作业
- 第七章 HBS：还在论文阶段的第三条路

- 第八章 “HBM相互通话”：联盟宣言的两层含义
- 第九章 Physical AI与端侧AI：机器人两头吃内存
- 第十章 谁是受益者：推理时代与机器人时代
- 第十一章 全景地图与总结
- 附录 一句话记忆卡合集

第一章 训练与推理：瓶颈在哪，老GPU能翻身吗

你当时的问题：按这个报告的说法，训练时代需要特别强的GPU，推理时代算力其实是充足的（利用率不到30%），瓶颈卡在存储和搬运上——那推理时代是不是可以用前几代的老GPU？现状到底是训练用的GPU最强，还是推理用的最强？

金正浩的观察没错：训练像做一大锅菜，数据一次搬进来反复计算，厨师（GPU计算单元）忙到冒烟，瓶颈在算力；推理生成答案时，每吐一个词都要把模型全部权重从HBM = High Bandwidth Memory（高带宽内存）里搬一遍，变成一份一份出餐——厨师大部分时间站着等传菜，利用率只有10%~30%，瓶颈在内存带宽。


但由此推出“推理可以用老GPU”，恰恰反了。关键在于：老GPU不只是算力老，它的内存更老。HBM和GPU芯片焊在同一个封装里，不能单独升级。既然推理的瓶颈是内存带宽和容量，那推理反而最需要新一代HBM——而新HBM只长在新GPU上。B200推理比H100强，主要不是算力大，而是

HBM带宽和容量大。换成餐厅类比：你嫌厨师太闲想换个老厨房省钱，结果老厨房的传菜通道更窄，出餐反而更慢。

现状是分层的，像一道“算力瀑布”：

层级	用什么卡	为什么
前沿模型训练	最新旗舰（GB200/B300集群）	算力+互联，缺一不可
前沿大模型推理（ChatGPT、Claude）	同样是最新旗舰	要的是HBM带宽和容量，单token成本更低、更省电
中小模型推理、微调	退役老卡（A100、L40S、4090）	模型塞得进老卡的内存就够用

所以训练和前沿推理用的卡一样强，老卡没有退休，而是“下沉”了——A100租价已跌超一半（2026年，来源：晨润云等租赁市场数据），成了中小模型推理的性价比之选。行业甚至开始为推理的不同阶段造专门的卡（如NVIDIA的Rubin CPX管“读题”阶段吃算力，旗舰卡管“写答案”阶段吃带宽）——这本身就印证了金正浩的判断：推理时代，值钱的是内存，而内存的载体还是最新的GPU。



记忆卡：推理时代淘汰的不是强GPU，而是“强算力配弱内存”的GPU——因为HBM焊死在GPU上，抢内存就得抢新卡。

第二章 GPU与HBM的本质区别：“外通死局”与功率密度

你当时的问题：“GPU陷入了外通死局”是什么意思？他这个逻辑链你觉得成立吗？GPU和HBM最本质的区别，是不是GPU会很热、HBM不存在散热问题，所以能堆叠？

“外通死局”是个翻译腔：韩语“외통수（外通手）”是韩国将棋术语，就是“将死”——被将军且无路可走。金正浩的意思是GPU被将死了：横着走（扩大芯片面积）撞上光刻机单次曝光的物理极限（约858平方毫米，早已做到头）；竖着走（垂直堆叠）被散热堵死。两条路都封死。

他的逻辑成立一半。物理前提都对，但“GPU技术成长停滞”说过头了。英伟达实际在用三条腾挪路：拼积木

（B200就是两块die拼成一颗，绕开单die面积极限）、降精度（FP8降到FP4，同样的晶体管吞吐翻倍）、以及“芯片不能叠就叠机柜”（NVL72用NVLink把72颗GPU当一颗用——堆叠发生在机柜层面）。逻辑芯片堆叠也非绝对禁区，AMD的3D V-Cache已经把缓存叠在CPU上了。准确说法是：“单颗GPU的平面缩放接近死局”成立，“GPU成长停滞”是他站在内存阵营的话术。

GPU与HBM的本质区别也要修正一处：不是“HBM不发热”，而是发热差了约两个数量级。GPU像一间所有炉灶同时开火的厨房（单封装约1000瓦，晶体管每秒开关几十亿次），散热器必须直接贴在芯片背面，堆叠等于把中间层封进烤箱；DRAM = Dynamic Random Access Memory（动态随机存取存储器）的单元大部分时间只是安静地存电荷，同一时刻只有一小片被访问，12~16层薄片叠一摞才约30瓦——像一座安静的图书馆，可以往上盖楼。NAND闪存更冷，所以能叠300多层。金正浩自己也承认HBM4集成逻辑功能后“像坐在暖炕上”要降温——热是程度问题，不是有无问题。



记忆卡：外通死局=被将死；GPU不能堆叠不是因为HBM不发热，而是GPU的热多了一百倍——芯片的死局不等于英伟达的死局（拼芯片、降精度、叠机柜）。

第三章 GPU与HBM的配比：焊死的图纸与换代的弹性

你当时的问题：GPU和HBM的配比是固定的吗？
一块GPU配多少HBM，受物理位置大小限制吗？
这个配比有没有弹性？


对一颗已经造出来的芯片，配比是焊死的；弹性只存在于换代的时候。

为什么焊死：每一栈HBM和GPU之间是一条1024位宽的并行总线——上千根导线，这些接口电路物理地刻在GPU die 四条边的“沿街店面”上，能开几个门脸在画图纸那天就定了。HBM必须紧贴GPU几毫米以内（远了信号就散），所有东西摆在同一块硅中介层（“地皮”）上，地皮大小又受CoWoS = Chip-on-Wafer-on-Substrate（台积电的2.5D先进封装）的尺寸与产能极限约束。出厂后既加不了，也换不了。

实际配比的演进（能看出弹性在哪）：

芯片	HBM栈数	容量	弹性用的是哪招
A100 / H100	6栈	80GB	基准（H100留一手：6栈只启用5栈，坏一栈不报废）
H200	还是6栈	141GB	地皮没动，每栈换更高的HBM3e——弹性二
B200	8栈	192GB	换更大地皮（两块die拼接）——弹性一
B300	8栈	288GB	每栈从8层加到12层——又是弹性二
Rubin Ultra（规划）	16栈	约1TB	两招一起上

弹性二（往上加层）是HBM厂商自己的主战场，弹性一（多盖楼）卡在台积电的封装产能上——这就是CoWoS产能过去两年一直是AI芯片出货量真正瓶颈之一的原因。这也串起了前两章：为什么“要新内存必须买新GPU”，以及为什么定制HBM改变了甲乙关系——每家客户的栈数、接口、堆叠高度都不一样，内存厂必须拿着订单承诺才开工。



记忆卡：GPU配多少HBM，画图纸那天就焊死了——单代芯片零弹性，弹性只藏在换代里：要么换大地皮多盖楼，要么同一块地往上加层。

第四章 时代分水岭：推理时代从哪天开始算

你当时的问题：我们总说从“训练时代”到了“推理时代”，但真正的分水岭、标志性事件究竟是什么？“2026年推理约占AI总计算量三分之二”这个数据是从1月算还是6月算？还会涨吗？从哪来的？另外Claude一直出新模型，

ChatGPT是不是要发5.7了——训练需求不是还在爆发式增长吗？

没有某一天“正式改朝换代”，但公认三个路标密集出现在2024年9月到2025年1月这四个月里：2024年9月OpenAI发布o1，第一次证明“回答时多想一会儿”（test-time compute，测试时计算）能直接换来智能提升，训练之外出现第二条增长曲线；2024年12月Ilya Sutskever在NeurIPS宣告“我们所知的预训练将会终结”（数据是AI的化石燃料），给训练时代念了悼词；2025年1月DeepSeek R1把推理模型成本打到o1的约5%还开了源，推理需求彻底平民化，英伟达当天暴跌说明市场开始重新给“训练叙事”定价。金正浩说的“去年夏天开始推理更重要”，对应的就是这条时间线。

“三分之二”不是精确测量的月度数据，而是行业估算的全年口径（主要出自德勤等机构）：2023年推理约占AI总计算量1/3，2025年约一半，2026年（全年）约2/3。没人能数清全球每块芯片在干什么，这个数是从云厂商资本开支、token消耗量、企业预算调研拼出来的——它是趋势刻度，不是仪表读数。它还会涨：主流预测2030年前后数据中心AI需求约70%来自推理；单个模型全生命周期80%~90%的成本花在推理上；企业调研里44%的公司已把超过四分之三的AI预算投给推理。它意味着AI从“研发烧钱”变成了“运营生意”——训练支出是赌注，推理支出跟着用户量和收入走。买卡标准从“峰值算力”变成“每token成本”，而后者卡在内存上，这是金正浩论点的财务注脚。

训练需求没有萎缩（顺带纠正：OpenAI最新的是GPT-5.6的Sol/Terra/Luna三款，不是5.7；节奏确实快——5.4在三月、5.5在四月、5.6在六月）。是整个蛋糕在暴涨、推理长得更快而已。更有意思的是训练和推理的界限在模糊：现在模型迭代主要靠强化学习后训练，其过程就是让模型海量地“生成回答—打分—改进”，训练内部大半计算本身就是推理形态的。所以更准确的说法不是“训练时代结束了”，而是“预训练独大的时代结束了，连训练都在推理化”——对内存又是一重利好。

记忆卡：分水岭是o1（2024.9）—Ilya悼词（2024.12）—R1（2025.1）这四个月；“2/3”是全年趋势估算且还会涨——它宣告AI变成了运营生意；训练没萎缩，而是在“推理化”。

第五章 需求的数学：每年翻倍、十年千倍是怎么算的


你当时的问题：他说内存需求每年翻倍，十年就是1000倍——是2的10次方对吧？这么算对吗？每年都在新增的基础上翻倍？底层逻辑是什么？另外，为什么计算机里1K=1024？1K不就是1000吗？

算术是对的：每年翻倍指在上一年总量基础上乘2（复利式连乘），十次连乘就是2的10次方=1024 $\approx$ 1000。这是半导体行业的祖传修辞——“每X年翻倍”正是摩尔定律的句式。

他算得对吗？拿实际数据校验，结论有点意外——从需求端看这个数字甚至偏保守：Google处理的token量，2024年5月披露9.7万亿/月，2025年5月480万亿（50倍），2026年5月I/O大会公布3200万亿（又7倍）；高盛预测2026—2030年全球token消耗还要再涨24倍（年化约2.2倍）。token消耗是内存需求最直接的代理指标，眼下实际增速比“每年翻倍”猛得多。

但有两个刹车。一是需求不等于出货：内存厂实际产量卡在建厂资本开支和电力上，增速远低于需求曲线——缺口本身就是涨价的来源。二是效率在对冲：每token成本三年降了约1000倍（量化、KV Cache = Key-Value Cache（键值缓存）压缩、蒸馏）。不过历史站在他这边：杰文斯悖论——东西越便宜用得越凶，蒸汽机时代煤耗效率提升反而让总煤耗暴涨。

底层逻辑：为什么是指数式而非线性？因为需求驱动因子是相乘关系——干活的智能体变多 × 每个24小时不睡 × 每次任务记住的上下文更长 × 内容从文字变成视频。四个因子各涨20%，乘起来就翻倍。指数增长从来不是某一个东西疯涨，而是几个温和的乘数悄悄叠在一起。



彩蛋：为什么1K=1024？人类世界1K确实是1000，但计算机用二进制数数，它的“整数”天然就是2的幂。内存地址用二进制编号，10根地址线恰好编出1024个门牌号，造不出“恰好1000个单元”的芯片。早期工程师发现2的10次方=1024和1000只差2.4%，干脆借来叫“1K”。这个偷懒的后遗症：买1TB硬盘电脑只显示931GB——硬盘厂按1000进制算，操作系统按1024进制算，两套“K”在打架。

记忆卡：2的10次方 $\approx$ 1000，算术没毛病；“每年翻倍”是四个温和乘数连乘出来的假设——按当前token增速他还说保守了，但真实出货会被产能和电力摁住。1024是离1000最近的“二进制整数”，被借来冒充1K。

第六章 HBF：给NAND抄HBM的作业

你当时的问题：你认可他说的HBF（High Bandwidth Flash）这种形态吗？这一块现在还没形成格局吧？现在更多是NAND加HBM，是吗？


方向认可，而且它已经不是教授的纸上概念了；但“今天还没有HBF格局”的判断完全正确。

HBF = High Bandwidth Flash（高带宽闪存），就是把NAND闪存抄HBM的作业：堆叠起来、开上千条并行通道、搬到GPU隔壁。认可它的两条硬逻辑：第一，需求端算得过账——推理时代要塞进GPU旁边的东西（模型权重、KV缓存、个人化记忆）涨得比DRAM供给快得多，而NAND每bit成本约为DRAM的十分之一，同样占地能给出8~16倍于HBM的容量（来源：Tom's Hardware）；模型权重“读一万

遍、几乎不写”，正好绕开NAND写入寿命短的命门。第二，产业已经真金白银跟进：闪迪2025年2月提出HBF，8月与SK海力士签约，2026年2月两家启动全球标准化（挂在OCP开放计算项目下），样品2026下半年，搭载HBF的推理设备2027年初送样；三星也开始了概念设计——正是金正浩点名的那几家。

保留意见：HBF是HBM的仓库，不是替代品——延迟仍是微秒级对纳秒级，只适合“读多写少”的分层；KV缓存这种高频写的活它干不好；时间表远，中间可能被别的方案截胡（比如CXL = Compute Express Link（内存池化互联标准））。

今天的现状是三层楼梯：HBM贴着GPU（纳秒级、同封装）、DDR/LPDDR在CPU旁边（百纳秒）、NAND以SSD形态住在走廊尽头（微秒到毫秒、隔着PCIe总线）。HBF的全部革命性就一句话：把书库从马路对面搬到阅览室隔壁，再开一千扇门。搬家还没开始，但设计图在画、施工队已签约。这也解释了闪迪、铠侠股价先涨——涨的不是今天的生意，而是“NAND从周期性大宗商品升格为AI核心链路成员”的预期；兑现要等2027年，时间差就是风险。



HBf 的本质：把住在走廊尽头的 NAND，搬到 GPU 隔壁并开上千扇门

记忆卡：HBf=给NAND抄HBM的作业（堆叠+宽总线），方向已被闪迪、海力士、三星用真金白银投票；但今天仍是“HBM管快、SSD管大”的旧格局，新楼层2027年才封顶。

第七章 HBS：还在论文阶段的第三条路

你当时的问题：HBS这段我看不懂——把整张12英寸晶圆全部做成SRAM再堆12至16层，容量从100GB到1600GB，“速度快1000倍，容量又足够，那就说得通了”——你解读一下？


一句话：HBS = High Bandwidth SRAM（高带宽静态内存），把“最快但最贵的那种内存”从小抽屉放大成整栋大楼。

用桌子类比记三种内存：SRAM = Static Random Access Memory（静态随机存取存储器）是摊在桌面上的纸——伸手就到，最快；DRAM是桌边的书架——起身取一下；NAND

是图书馆——量大但要走一趟。SRAM快是因为它用6个晶体管搭成自锁开关，不用像DRAM那样靠电容存电荷、不停刷新补电；代价是同样的信息占地是DRAM的好几倍，所以传统上只配当芯片里几十MB的小缓存。

他的思路是沿着现成的路往前推：Cerebras已经把整张12英寸晶圆做成一颗巨型芯片，但晶圆上大部分面积给了计算单元，SRAM只挤出44GB——放不下动辄几百GB的大模型，这是死穴。金正浩说：反过来，把计算全赶走，整张晶圆只铺SRAM，一层约100GB；再学HBM往上叠12~16层，1600GB——最大的模型也装得下。“又快”（SRAM本性）和“又大”（堆叠）同时成立，所以他说“那就说得通了”。SRAM功率密度远低于计算芯片，理论上可叠——用的正是第二章“谁能盖楼”的逻辑。

三盆冷水：一是成本——SRAM每bit造价是DRAM的几十倍，还得用最先进逻辑制程，16张先进晶圆叠一摞是天文数字；二是讽刺的一点——3纳米之后SRAM单元几乎不再缩小，它和DRAM一样逼近量子边界；三是他自己说时间尺度10到30年，且“今年硕士新生入学，打算让他们拿HBS当论文题目”——翻译过来：这东西处于“博士论文”阶段。还有个受益者彩蛋：HBS若成真，制造方是代工厂（台积电、三星代工），不是内存厂——他三条路线里唯一一条受益者名单不同的。



记忆卡：HBS=整张晶圆铺满最快的SRAM再叠16层，用“面积换密度、堆叠换容量”硬凑出又快又大；逻辑自治，但成熟度排序是HBM（量产）→HBF（签约施工）→HBS（画图纸）。

第八章 “HBM相互通话”：联盟宣言的两层含义

你当时的问题：“未来HBM芯片内将集成通信功能，实现HBM之间相互通话，形成类似联盟的结构——谁对我们更好就给谁更多内存，不听话的GPU就不分配”——这是什么意思？


这段拟人修辞下面藏着两层意思。

第一层是芯片架构（字面意思）。今天的HBM是“哑巴仓库”：GPU的内存控制器发指令，它收货发货，仅此而已；两栈HBM之间零交流——A仓库的数据要去B仓库，必须先运到GPU再运回来。这很致命，因为AI计算里搬运数据耗的电远超计算本身。转机在HBM4：每栈底部的“基础逻辑层”（base die）在定制化时代可以塞进智能——预取、压

缩、调度，甚至部分计算（PIM = Processing-In-Memory（存内计算），三星、海力士都出过样品）。金正浩设想再进一步：给仓库之间修直达通道，数据在HBM间平移，不绕道老板。“谁表现好给谁多分配”翻译成工程语言：带宽调度权从处理器侧搬到内存侧——GPU从发号施令的老板降级成排队领料的客户。这就是他说的“以内存为中心的计算”（Memory-Centric Computing）。

第二层是产业权力（弦外之音）。把芯片换成公司再读一遍：“不听话的客户，就不供货。”这是“甲乙关系逆转”的拟人版：标准化内存时代英伟达们挑内存厂；定制HBM+长期协议（LTA）时代，产能稀缺、客户排队，变成内存厂挑客户、定价格。他说的“联盟”，本质是暗示三家内存厂可以像OPEC之于石油一样掌握AI时代的战略资源。

冷静两句：技术上HBM互相组网还在论文阶段，且系统总线是英伟达设计的，NVLink正是它的护城河，这会拉锯而非政变；产业上三家真敢公然结盟挑客户会撞反垄断法，现实形态只会是各自与大客户签长期协议。这段话听三分技术、七分宣言。



记忆卡：“HBM相互通话”=仓库之间修直达通道、调度权从GPU搬到内存（架构），外加“不听话就断供”的定价权宣言（产业）——技术在路上，权力已在转移。


第九章 Physical AI与端侧AI：机器人两头吃内存

你当时的问题：从聊天到Agent，再到Physical AI 应该又是一波浪潮。Physical AI那时候是不是也需要海量存储？那种是不是就叫“端侧AI”？

不是一回事，但有交集。Physical AI说的是AI干什么——进入物理世界（机器人、自动驾驶）；端侧AI（edge AI / on-device AI）说的是在哪算——计算发生在设备本地而非云端。AI手机、AI PC是端侧AI但不是Physical AI；机器人是Physical AI，且必然大量依赖端侧——走路摔不摔倒是毫秒级的事，等不起云端网络往返，断网也不能瘫痪。

机器人的存储需求是两头都要，但要的东西不同：端侧小脑要大容量、低功耗的LPDDR = Low-Power DDR（低功耗内

存) 和NAND——不用HBM，太贵太耗电，这正是金正浩说“AI手机一半成本是内存”的同一逻辑；云端大脑要的还是HBM/HBF——几百万台机器人24小时回传的视频数据要存储、要拿来继续训练，这就是他说“内存需求千倍”的来源。端侧和云端两条线最后都汇到三星、海力士、美光的全线产品上。



记忆卡：Physical AI是干什么、端侧AI是在哪算；机器人小脑在端侧吃LPDDR、大脑在云端吃HBM——两头都是内存的生意。

第十章 谁是受益者：推理时代与机器人时代

你当时的问题：推理时代最大受益者，是不是第一Anthropic、第二HBM三家（美光、海力士、三星）？以后机器人时代，最大受益者会是做谐波减速器的、做灵巧手的、还是做丝杠的（比如恒立液压）？存不存在像HBM这样明确利好哪几家的公司？

推理时代：方向对，修三处。第一，Anthropic是“之一”不是确定的“最大”——推理时代对模型公司的利好是卖token的生意模式跑通，Anthropic的企业API是典型代表，但Google自研TPU = Tensor Processing Unit（张量处理器）、全栈成本最低，OpenAI规模最大，模型层竞争远未收敛，不像内存是三寡头。第二，HBM三家要排序：确定性上SK海力士（份额第一、绑定英伟达）>美光>三星（HBM认证落后，但靠DRAM/NAND全线涨价照样受益）。第三，预期已打满是风险——原报告末尾恰好有条新闻：“三家存储芯片公司撑起标普今年四分之一涨幅”（华尔街见闻，2026年7月）。受益链也比“模型+HBM”宽：NAND存储线（闪迪、铠侠——铠侠市值一度超过丰田成为日股第一）、推理定制芯片设计（博通）、电力与散热。

机器人时代：先想清楚HBM为什么“明确”——技术路线已定型 × 壁垒极高 × 只剩三家 × 绑死在核心链路上，四条全占。拿这把尺子量机器人零部件：

部件	人设	当前格局	像不像HBM
谐波减速器（旋转关节）	“最接近的一个”	哈默纳科约85%+绿的谐波约8%，双寡头、壁垒高	最像，但路线没锁死（有厂商改行星减速器/直驱）
行星滚柱丝杠（直线关节）	“增量最大的赛道”	Optimus 28个执行器中14个用它，恒立液压等玩家正涌入	空间大、格局未定
灵巧手	“价值最高的彩票”	腱绳/连杆/微型丝杠各家方案完全不同	最不像——押中路线大赢，押错归零


结论：机器人硬件今天还没有迎来“HBM时刻”，因为本体设计没定型——特斯拉、宇树、Figure方案互不相同，主机厂还故意多供应商备份压价（特斯拉光备选供应商就19家）。HBM自己也是2015年出HBM1、熬到2023年才爆发

的，爆发在路线定型之后。眼下最像HBM的确定性受益者，说来讽刺，是金正浩本人的答案：机器人的“大脑”——芯片和内存本身，绕一圈又回到HBM三家。

记忆卡：HBM式的确定性=路线定型×高壁垒×寡头。机器人零件最多占两条，谁先“定型”谁先封神——定型之前，最稳的受益者是给所有机器人供大脑的那批公司。

第十一章 全景地图与总结

把整场对话放回一张图：金正浩的核心论断是“AI=内存”，论据是推理时代GPU九成时间在等数据；他给出的路线是内存三部曲盖成“百层大楼”（HBM量产中、HBF签约施工、HBS还在画图纸），GPU坐屋顶散热；受益地图上，能同时做DRAM和NAND的三星与SK海力士握着最强的两张牌，美光、闪迪、铠侠各占一线，若HBS成真则代工厂入局。



三条骨干逻辑贯穿全部十章：其一，瓶颈决定价值——训练时代瓶颈在算力所以GPU为王，推理时代瓶颈在内存所以话语权西移；其二，功率密度决定形态——冷的能盖楼（内存

堆叠），热的只能摊平房（GPU），这一条物理定律解释了HBM、HBF、HBS全部三条路线；其三，确定性来自“路线定型×壁垒×寡头”——这把尺子既解释了HBM三家为什么涨，也解释了机器人零部件为什么还没到封神时刻。

需要保持警惕的对冲面：金正浩是内存阵营的旗手，“GPU成长停滞”“不听话就断供”都是立场鲜明的话术；英伟达的拼芯片、降精度、叠机柜三条路还很宽，NVLink护城河仍在；存储三家的预期已充分定价；HBF要2027年才兑现、HBS以十年计。叙事与事实之间的时间差，就是风险所在。

附录：一句话记忆卡合集

主题	一句话
老GPU能否做推理	推理淘汰的不是强GPU，而是“强算力配弱内存”的GPU——HBM焊死在GPU上，抢内存就得抢新卡
外通死局	被将死：横向撞光刻极限、纵向被散热封顶；但芯片死局≠公司死局（拼芯片、降精度、叠机柜）
GPU vs HBM本质	不是有无发热，是热差一百倍——功率密度决定谁能盖楼
GPU与HBM配比	画图纸那天焊死；弹性只在换代：换大地皮多盖楼，或同一块地往上加层
时代分水岭	o1（2024.9）—Ilya悼词（2024.12）—R1（2025.1）；金正浩的“去年夏天”即此
推理占2/3	全年趋势估算非仪表读数，还会涨——AI从研发烧钱变成运营生意
训练需求	没萎缩，在“推理化”——强化学习后训练大半是推理形态计算
每年翻倍十年千倍	2的10次方≈1024；四个温和乘数连乘的假设，按token增速甚至保守，但出货被产能电力摁住
1K=1024	计算机用二进制，1024是离1000最近的“二进制整数”，借来冒充1K
HBF	给NAND抄HBM的作业；闪迪/海力士/三星真金白银跟进；今天仍是“HBM管快、SSD管大”，2027年封顶
HBS	整晶圆SRAM叠16层硬凑又快又大；成熟度HBM量产→HBF施工→HBS画图纸
HBM联盟	仓库修直达通道+调度权搬家（架构）+断供宣言（定价权）——三分技术七分宣言

主题	一句话
Physical AI vs 端侧AI	干什么 vs 在哪算；机器人小脑端侧吃LPDDR、大脑云端吃HBM
推理时代受益者	Anthropic是之一非最大；海力士>美光>三星排序；预期已打满是风险
机器人受益者	HBM式确定性=定型×壁垒×寡头；零件最多占两条；定型前最稳的是供大脑的公司

免责声明：本笔记为个人学习整理，所有数据为截至2026年7月7日的时点信息，来源包括金正浩访谈（华尔街见闻）、德勤、高盛、Google I/O 2026、闪迪/SK海力士公告、TrendForce、Tom’s Hardware等公开资料。涉及上市公司与行业判断的内容仅供学习参考，不构成任何投资建议。