

AI 投资的物理墙

副标题：从三种材料的分工，到贯穿 AI 基建的九堵墙与三因子框架

整理日期：2026 年 7 月 5 日 · 文中行情与事实均为截至整理日的公开信息

阅读提示：本笔记由一次完整的费曼式对话沉淀而成，不按聊天时间线，而按“材料工具箱 → 800V 供电 → 推理与 HBM → 物理墙框架 → 三因子选股 → 三个专题 → 九墙全景”的认知阶梯组织。每章开头保留当时的原始提问。涉及股票内容仅供学习研究，不构成投资建议。

目录

- 第一章 概念工具箱：磷化铟、碳化硅、氮化镓的分工
- 第二章 800V 是怎么回事：电流墙与供电链条大改造
- 第三章 推理时代为什么是 HBM：口岸、字典与行李箱
- 第四章 物理墙框架：AI 是撞墙—绕墙前进的
- 第五章 三因子公式：寻找下一个 HBM
- 第六章 三个专题：TC Bonder、大型变压器、玻璃基板

- 第七章 全景地图：贯穿 AI 的九堵墙
- 附录 一句话记忆卡合集

第一章 概念工具箱：磷化铟、碳化硅、氮化镓的分工

你当时的问题：磷化铟、碳化硅、氮化镓，它们都是光模块/CPO 里要用的材料吗？还是说碳化硅、氮化镓是用在 800V 功率半导体上的？

这三种材料是“两条赛道、三个工种”。判断一种半导体材料的岗位，看它的两个天赋，就像给人相面：


嗓子好不好（直接带隙）：决定会不会“发光”。磷化铟（InP）是直接带隙，通电就能发出激光，而且波长正好是 1310/1550nm——光纤损耗最低、“听得最清”的调。硅和碳化硅是间接带隙，天生哑嗓，不会发光，所以光模块的激光器非 InP 不可。

扛不扛揍（带隙宽度）：决定耐不耐高压高温。硅带隙 1.1eV，几百伏就顶不住；碳化硅（SiC）和氮化镓（GaN）带隙 3.3/3.4eV，是“宽禁带”兄弟，天生耐高压高频。

材料	人设	会发光吗	主战场	代表标的
磷化铟 InP	光纤专属歌手	会，且唱对调（1310/1550nm）	光模块/CPO 的激光器与探测器	AXTI（衬底）、Lumentum/Coherent（激光器）、源杰科技
碳化硅 SiC	高压大力士	不会（间接带隙）	600V-3300V：电车主逆变器、	天岳先进/晶升（衬底）、意法/英飞凌/安森

材料	人设	会发光吗	主战场	代表标的
			800VDC 电源主干	美/罗姆、斯达半导
氮化镓 GaN	高频敏捷电工	会，但只会唱蓝光（LED，非通信波段）	中低压高频：快充、数据中心 DC-DC、800VDC 前级	纳微、英诺赛科、英飞凌、三安光电

两个关键澄清：其一，**CPO 不是材料，是封装方式**（共封装光学，把光引擎挪到交换芯片旁共同封装），里面干活的依然是硅光芯片加 InP 激光器，所以“CPO 概念”利好的是 InP 链，与 SiC/GaN 无关。其二，SiC 和 GaN 是 800V 电赛道的一对搭档而非对手：SiC 扛 600V 以上的主干，GaN 管中低压高频那段，英伟达的 Kyber 机柜方案两个都要用。有趣的交叉是 Coherent 两条赛道都占——既做光模块激光器（InP），又是全球主要 SiC 衬底供应商之一。



GaN 也会发蓝光（LED，三安光电），但不是光纤通信波段，所以不进光模块

记忆卡：InP 会唱歌（发光）进光模块，SiC 扛高压、GaN 打高频，哥俩分段守 800V 电赛道；CPO 是封装方式，点的还是 InP 的灯。

第二章 800V 是怎么回事：电流墙与供电链条大改造

你当时的问题：800V 的 V 是伏、DC 是直流吧？
800V 的趋势是什么，是因为英伟达要升级 Rubin 架构吗？为什么 800V 会是一个趋势？另外，原来的方案不是低压吗，怎么之前也需要层层降压？
为什么现在要把降压电源搬到柜外？

V 就是伏特（电压），DC 就是直流电（对应 AC 交流电）。
800VDC = 800 伏直流供电。引爆点确实是英伟达 Rubin 时代的机柜，但底层是一道初中物理题。

为什么必须升压：功率 = 电压 $\times$ 电流 ($P = V \times I$)，而输电损耗和发热跟电流的平方成正比 (I^2R)。AI 机柜功率从 Blackwell 的约 120kW 涨到 Rubin Ultra (Kyber 机柜，2027) 的约 600kW。若沿用 54V 配电，600kW 意味着 1.1 万安培电流——铜排粗得像铁轨、重几百公斤、损耗热到离谱，物理上装不下。改用 800V，电流缩到 750 安培，缩小约 15 倍，铜损（按平方）降约 200 倍。这不是“更好”，是“不升压就装不下一柜 GPU”的硬约束。城市电网一百年前就懂的道理（远距离高压输电），轮到数据中心内部补课。

为什么以前也要层层降压：因为 GPU 芯片只能喝“超低压”——先进制程晶体管娇嫩，核心供电只有 0.8V 左右。所以无论进柜多少伏，最后都要降到 0.8V；降压永远存在，问题只是在哪儿降、降几级、每级亏多少。旧链条（NVL72 时代）：

电网 13.8kV 交流 → 415V 交流进机房 → UPS 倒腾两次 → 柜内电源架整流成 54V 直流 → 板上 12V → VRM 降到 0.8V

四五次转换，端到端效率约 87%，且“415V→54V”电源架占掉机柜好几层。

为什么旧方案的电源搬不出去：54V 出不了远门——600kW 用 54V 送十米，铜排粗到发疯。低压像鲜榨果汁，运不远，只能每栋楼自建榨汁房（柜内电源）。800V 像浓缩汁，可以在集中工厂（柜外电源边柜）统一生产，细管道送进楼里，楼内只留最后的减压阀。新链条：

电网 → 柜外集中整流成 800V 直流（电池直挂母线，UPS 取消）→ 细铜排进柜 → 柜内 800V→中间压（SiC/GaN 高频转换）→ VRM → 0.8V

搬出去换来三件事：

1. **空间：**柜内空间还给 GPU，算力密度就是钱；
2. **效率：**转换级数从四五级砍到两三级，端到端效率提到 93% 上下，吉瓦级数据中心一年省的电费以千万美元计；
3. **冗余：**集中式大电源可做共享冗余（N+1），省钱省料。

记忆卡：功率=电压×电流，损耗按电流平方算；Rubin 机柜涨到 54V 的铜线扛不动，只能升到 800V——电压升 15 倍、电流缩 15 倍、损耗降 200 倍。

记忆卡：GPU 永远只喝 0.8V，降压少不了；54V 出不了远门所以电源被锁在柜内，800V 让电能“集中生产、细管配送”，电源搬出柜、空间还给算力。

第三章 推理时代为什么是 HBM：口岸、字典与行李箱

你当时的问题：我给朋友讲 HBM 时用了深圳湾口岸的类比——训练时代闸机全开并行进，推理时代出口收窄只能一个个走，所以卡点从算力变成了数据搬运。这样讲对吗？另外你说吐字时 GPU 利用率不到 10%，现在还是这样吗？数据哪来的？有没有办法让它满载？

口岸类比方向抓对了两件事：训练并行、推理串行；瓶颈从算力挪到搬运。但要打一个补丁，否则听众会问“出口窄，多开几个闸机（多买 GPU）不就行了”。补丁是：**过闸的不是数据，而是“查字典”这个动作**。AI 每吐一个字，都要把整个模型权重（几百 GB 的大字典）从仓库（HBM）搬到窗口（计算核心）完整翻一遍。

最终版三句话：

- **训练像团体游学：**一万人的旅行团排好队，海关翻一遍字典给全团盖章——搬一次字典服务一万人，成本摊薄，瓶颈是盖章手速（算力）；
- **推理像逐人通关：**“下一个字依赖上一个字”（自回归）注定串行，每盖一个章都要重搬几百 GB 字典，瓶颈是仓库到窗口的传送带（HBM 带宽）；
- **Agent 时代人手一个越聊越沉的行李箱：**KV cache，10 万字上下文占几十 GB，既吃容量（决定并发数和任务长度）又吃带宽（每个字连行李箱也要重过一遍）。

你总结的“速度+容量”两个核心，正好对应后两条。

利用率数据（截至 2026 年 7 月）：这个指标叫 MFU（模型算力利用率）。推理分两段：读题（prefill）是矩阵×矩阵运算，MFU 30-45%；吐字（decode）是矩阵×向量运算，MFU 只有 5-15%，即使 32 个用户拼一批也只有 8-12%（来源：zeroentropy、分离式推理分析等 2026 年资料）。旁证：吐字阶段 GPU 功耗只有额定的 20-40%——连电都懒得吃满，因为在等数据。

两个关键修正：

1. **HBM 不能后插：**它焊死在 GPU 封装里，“补卡点”的唯一途径是换代（H100 每卡 80GB/3.4TB 带宽 → B200 192GB/8TB → Rubin 288GB

HBM4/13TB+) ——HBM 需求是英伟达替全行业逐代强制加码的。

2. **100% 满载永远到不了**：decode 的“每字节配的计量”天生低于硬件平衡点，且带宽每提一代，模型更大、上下文更长——目标在移动。追不上正是 HBM 需求的结构性长逻辑。

但判断 HBM 行情何时到头，别盯利用率，盯供给端三个信号：三家 bit 供给增速何时超过需求增速、三星 HBM4 良率进度、2027 年合约价谈判。**利用率告诉你故事没讲完，供给告诉你估值到没到头。**

让 GPU 满载的三路优化：

• **第一路：拼车摊薄（不改串行，改摊法）**

- continuous batching：几十个用户同一轮各签一个字，搬一次字典服务几十人；但每人的行李箱都要塞进 HBM——带宽问题转成容量问题，绕一圈还是 HBM；
- MoE：DeepSeek 招牌，671B 参数每字只叫醒 37B，字典只翻相关章节；
- 量化与 MLA：字典印薄一半；MLA 把行李箱压掉九成。

• **第二路：变串行为并行（“改底层”真的存在）**

- 投机解码：实习生小模型先代签 5 个字，作者一次并行审阅，白嫖 2-3 倍速；

- MTP: DeepSeek 让模型一步吐多字，自己当自己的实习生；
- 扩散语言模型：像 AI 画图那样整段生成再逐轮修清晰，彻底抛弃自回归（谷歌已有演示，属潜在范式革命）。
- **第三路：换硬件（惹不起字典，把作者搬进图书馆）**
 - 存算一体 PIM、Groq/Cerebras 的 SRAM 大芯片路线、英伟达读题吐字分卡分工。

投资推论（杰文斯悖论）：这些优化是 HBM 的朋友不是敌人。2025 年 1 月“DeepSeek 时刻”一夜砸崩英伟达，随后推理变便宜、用量爆炸、需求反创新高——蒸汽机效率翻倍，煤炭消耗不降反升。效率优化降低每个字的成本，撬开百倍的用量。

生活同款低利用率：

- **私家车：**95% 时间停着，利用率 4%——解法是网约车（=batching），高峰打不到车（=容量墙）；
- **电网：**为峰值建电厂，平均利用率五六成——解法是储能错峰（=分离式 serving）。

凡为峰值/串行需求配置的昂贵资产，利用率都惨不忍睹，而每一个都养出了填缺口的大产业。

记忆卡：训练摊薄搬运、算力是王；推理逐字重搬、带宽为王；Agent 拖箱长跑、容量称王——HBM 一个人占了后两个王位。

记忆卡：吐字时 GPU 干活不到一成五、连电都吃不满——缺口是数学注定且追不平的；但价格何时见顶看的不是缺口，是三家扩产的铲子声。

记忆卡：签售会三招提速——拼批、实习生代签（投机解码）、把作者搬进印刷厂（存算一体）；效率每提十倍，排队读者多一百倍（杰文斯悖论），优化救的是成本，烧的是更多 HBM。

第四章 物理墙框架：AI 是撞墙—绕墙前进的

你当时的问题：美股 AI 投资的机会，好像都是在找“卡脖子”环节，更准确说是找物理边界上“撞墙”的事情——800V、CPO、HBM 本质都是撞上了物理上不可逾越的墙，只能换方案绕过去。我这样理解对吗？该怎么表达更好？

“卡脖子”这个词不够准——卡脖子是人为的墙（管制、专利），你说的是**物理的墙**（自然定律）。建议的表述：

AI 的进步不是匀速滑行，而是不断“撞墙—绕墙”地前进。每撞上一堵物理定律砌的墙，就被迫换一次技术方案；每换一次方案，就强制换一次供应链——供应链换血，就是行情。

关键在“从更好到必须”这个相变：工程瓶颈是渐进优化，利好在位者，炒不出大行情；物理墙是“不换就装不下、跑不动、烧起来”，需求从零起跳、没有替代品，这才是十倍股的土壤。

判断一堵墙值不值得押，看三条：**是定律不是难题**（ I^2R 、衍射极限、热容、带隙，工程师加班解决不了）；**撞墙时间可预测**（跟着英伟达路线图倒推：Blackwell 撞散热墙对应 2024-25 液冷行情，Rubin Ultra 撞电流墙所以 800V 是 2026-27 的菜）；**绕墙路线已收敛**（技术路线定了才有确定性受益者）。

框架的灵魂洞察：**墙是会传递的**。每拆掉一堵墙，算力洪水就冲到下一个最窄处：GPU 拆了计算墙 → 水冲到内存

（HBM）→ 冲到互连（光）→ 冲到散热（液冷）→ 冲到供电（800V）→ 冲到电网（燃机核电）→ 冲到封装

（Chiplet/玻璃）。AI 基建投资的本质，就是追着洪水跑，提前站到下一个窄口。

记忆卡：AI 投资=沿着英伟达路线图找下一堵物理墙；墙一撞上，“更好”变“必须”，供应链强制换血，行情就在换血处。

第五章 三因子公式：寻找下一个 HBM

你当时的问题：推理时代最大受益者是 Claude 和 HBM。Claude 的 ARR 跳跃式翻倍（帮我核实数据）；HBM 占机柜成本从 2% 涨到 18%，量价齐升（帮我核实）。设备和材料好像只走量不涨价，做不到 HBM 那样，我理解对吗？还有哪些“时代级”机会？HBM 是独一无二的吗，请给具体案例。另外“this too will pass”是什么意思？

数据核实（截至 2026 年 7 月）：

- **Anthropic ARR** 比你记的更陡：2025 年底 90 亿美元
→ 2026 年 2 月 140 亿 → 3 月 190 亿 → 4 月 300 亿
（VentureBeat “80 倍疯狂增长”）→ 5 月约
440-470 亿（Sacra）；4 月已在收入上超过
OpenAI。
- **“存储 2%→18%”** 精确出处未找到，但量级方向成立：普通服务器内存占成本约 2-5%
（SemiAnalysis）；如今 HBM 每 GB 比 DDR5 贵 5-6
倍、每片晶圆收入是 DDR5 的 3-5 倍、单卡配置量从
80GB 涨到 288GB。当叙事用没问题，别当精确数据
引用。

三因子公式（你的“时代思路”+“占比思路”合并，补上漏掉的一环——供给刚性）：

十倍机会 = 需求断层（时代切换）× 供给刚性（寡头+扩产慢）× BOM 占比跃迁（量价齐升的结果）

HBM 三条全中：推理/KV cache 造成需求断层；供给只有三家、扩产要两年、HBM 每 GB 吃 3 倍晶圆产能（扩 HBM 必挤压普通 DRAM，点燃整个存储市场）；于是量价齐升，占比 2%→18%。你说设备材料“只走量”，对，但根因是定价结构：ASML 长约定价没有涨价机制，信越硅片长约缓涨——不是环节不重要，是定价结构不给爆发机会。例外恰恰证明规律：**贴着瓶颈环节的寡头设备照样爆**（见第六章韩美半导体）。

用三因子公式扫一遍各“时代”，找每个时代的“HBM 位”：

时代	最像 HBM 的环节	三因子检验	判断
机器人时代	行星滚柱丝杠	人形放量（每台十几根）；高精度磨床全球产能极刚性（磨床本身就是“光刻机”）；单台价值量高	最佳候选
机器人时代	灵巧手	BOM 占比最高（15-20%）；但技术路线未收敛，谁受益还没定	早，盯路线收敛
机器人时代	谐波减速器（哈默纳科）	垄断；但绿的谐波等国产替代在压价，特斯拉刻意扶植第二供应商	半个候选——有量，价难齐升
电力时代	燃气轮机（GEV/三菱/西门子三寡头）	数据中心抢电；交货排到 2029、产能极刚性；已在涨价	正在进行时
800V 时代	SiC 衬底	量升；但供给端扩产凶猛、价格年年降	量升价跌，不像 HBM
推理时代续集	NAND/大容量 eSSD	推理数据湖；同样三寡头；正在重演 HBM 剧本	进行中（铠侠/闪迪已启动）

“This too will pass”（一切终将过去）：古老箴言——波斯国王让智者刻一句任何时候看都成立的话，得到的就是这句。放在 HBM 语境：暴利本身就是产能扩张的邀请函，占比能从 2% 跳到 18%，也能随三家扩产、价格均值回归而部分退潮。它不否定行情，是提醒这是周期的烈火，不是永动机。

具体案例（HBM 不是独一无二，它只是三因子最纯的样本），按演到第几幕分三桶：

正在直播（量价齐升进行中，中场）：

案例	供给刚性	证据	面板对应
近线硬盘 HDD	希捷/西数/东芝三寡头，行业衰退十年没人扩产，产能刚性比 HBM 还极端	AI 数据湖抢购，交货排到 2027、持续涨价	希捷近1年 +422%、西数 +349%——眼皮底下的第二个 HBM

案例	供给刚性	证据	面板对应
大容量 NAND/eSSD	铠侠/闪迪/三星三寡头	QLC eSSD 替代 HDD 溢出需求	闪迪 +3660%、铠侠 +3400%
燃气轮机	GEV/三菱/西门子能源三寡头，交货排到 2029	数据中心抢电，已涨价	GEV +70%、潍柴（发电机组）+88%
HBM 键合机（设备的例外）	韩美半导体 TC Bonder 市占 71.2%，刚拿海力士 HBM4 大单	证明“设备只走量”有例外：贴着瓶颈的寡头设备照样爆	已补入设备板块
大型变压器	日立能源/现代电气/效星，交货 3-5 年	现代电气是这轮真实的十倍股	已补入能源板块

剧本写好候场（还在“2%阶段”）：

- **行星滚柱丝杠**：三因子最纯候选，瓶颈藏在上游高精度螺纹磨床（磨床就是这个赛道的“光刻机”），等特斯拉 Optimus 量产一锤定音；恒立液压已在卡位；
- **玻璃基板**：见第六章专题；
- **铀**：矿山建设周期 10 年，SMR 需求在后面排队（Cameco）。

历史已验证：

- ABF 载板 2020-22（揖斐电三年三倍）、集装箱航运 2021、碳酸锂 2021-22、光模块 2023-25（新易盛毛利率 25%→45%）；
- 共同结局：**全都 passed**——既是框架成立的证据，也是纪律的来源。

谐波减速器的判断（你的候选）：像 HBM 的地方是垄断（哈默纳科工业市占约 8 成）和放量（人形每台几十个关

节)；不像的地方是客户在主动培养备胎——特斯拉扶植国产替代压价。终极一问：**客户被迫涨价接受，还是有备胎可扶？** HBM 的可怕在于英伟达想换都没得换。

记忆卡：找下一个 HBM，先问三句——时代来了吗（需求断层）、只有几家能供吗（供给刚性）、客户有备胎吗（定价权）；三问全过，占比才会从 2% 跳到 18%。

记忆卡：HBM 不孤独——HDD 正在直播、燃机变压器演到中场、丝杠和玻璃基板还在候场；三因子找入场，“this too will pass” 定离场。

第六章 三个专题：TC Bonder、大型变压器、玻璃基板

你当时的**问题**：TC Bonder 是什么？韩美半导体的代码和涨幅，炒过了吗？大型变压器也介绍一下。玻璃基板的“翘曲墙”给我做个专题：ABF 载板是什么、和玻璃基板什么关系、为什么一定要用玻璃、受益股有哪些？

TC Bonder（热压键合机）

HBM 是 12-16 层 DRAM 叠起来的千层饼，TC Bonder 就是那台“叠饼机”——把每层芯片加热几百度、加压，让层间几千个微凸点微米级精准焊合。

- **为什么贴着瓶颈**：HBM 产量翻倍（量）、层数从 12 层涨到 HBM4 的 16 层、HBM5 的 20 层+（每颗焊的次数变多）——设备需求双重放大；

- **龙头：**韩美半导体（042700.KS），TC Bonder 市占 71.2%，深度绑定海力士，2026 年 6 月拿下 HBM4 键合机大单（约 442 亿韩元）；
- **行情：**近 1 年 +178%，历史高点 42.6 万韩元（2026 年 5 月 12 日），当前回撤约 -36%——主升炒过一段，现处深回撤观察区，本质是“存储的设备影子股”；
- **弱点：**韩华精密、ASMPT 在追，客户有扶备胎动机。

大型变压器

电从电网几十万伏降到数据中心 415V 靠变压器层层接力，瓶颈在超高压（765kV 级）大变压器。

- **供给刚性：**全球能造的不到 5 家——日立能源（原 ABB）、西门子能源、现代电气、效星重工；取向硅钢铁芯+人工绕线是手艺活，建厂加培养熟练工要三年，没人敢为一轮周期扩产；
- **证据：**AI 一来，交货期从 6-12 个月拉到 24-36 个月，教科书式量价齐升；
- **行情：**现代电气（267260.KS）距高点回撤 -34%，是 2023 年起的真十倍股；效星重工（298040.KS）近 1 年 +528%；
- **判断：**演到中场偏后，股价已大幅定价，但订单能见度到 2029、业界喊“超级周期到 2035”，属回撤中的强逻辑。

玻璃基板专题：

ABF 载板是什么——芯片引脚是微米级、主板 PCB 走线是毫米级，中间需要“转接楼板”叫 IC 载板；高端载板用 ABF 膜（Ajinomoto Build-up Film，做味精的味之素公司发明的绝缘膜）在有机树脂芯板上层层堆出精细布线。玩家：揖斐电、新光电气、欣兴。2020-22 年 ABF 短缺就是上一轮量价齐升。玻璃基板不是 ABF 的对手，而是要替换它脚下那块“有机芯板”——把地基从树脂换成玻璃。

为什么必须玻璃（翘曲墙）——Chiplet 拼装让封装面积暴涨到 100mm 见方以上；有机树脂软、热胀冷缩系数和硅失配，面积一大、一加热，整块基板像烤箱里的披萨饼翘边，微米级布线全部对不准。玻璃的天赋全是解药：刚硬平整不翘、热胀系数可调到与硅匹配、耐高温、表面光滑能做 10 倍密度布线、能钻玻璃通孔（TGV）。封装越大越没得选——又一次“从更好到必须”。

受益股与阶段——

- **SKC (011790.KS)**：最激进，子公司 Absolics 佐治亚厂预计 2026 年底全球首个量产；截至整理日距高点回撤 -47.6%，典型的“还在 2% 阶段”；
- **三星电机 (009150.KS)**：2026 年中量产目标；
- **LG Innotek (011070.KS)**：与康宁联合研发；
- **康宁 GLW**：玻璃材料+GlassBridge 光电封装，2026 年 1 月签下 Meta 60 亿美元长约；
- 外围：日本电气硝子、AGC（玻璃原片）。

风险：玻璃易碎的良率问题未完全解决；Intel 起了大早，先驱有变先烈的前科。

三个专题放在一条时间轴上看：变压器（中场偏后）→ TC Bonder（主升后深蹲）→ 玻璃基板（片头曲刚响）。

记忆卡：叠饼机赚层数的钱、变压器赚手艺垄断的钱、玻璃基板赚“披萨饼翘边”的钱；三个里唯一还在 2% 阶段的是玻璃。

第七章 全景地图：贯穿 AI 的九堵墙

你当时的问题：从物理墙的角度理解整个 AI 的卡点和进展，是很酷的思路。请做一次完整梳理：每堵墙的旧方案对应哪些公司、新方案对应哪些公司；脉络要从 CPU 到 GPU 的起点讲起（黄仁勋赌对加速计算，本质是跨越“加速墙”），推理时代 CPU 的小阳春也要提；案例不要有遗漏。

#	墙	物理极限（一句话）	旧方案 → 代表公司	新方案 → 代表公司	演到第几幕
0	计算墙（起点）	2005 年后 CPU 频率撞功耗墙，单核性能停滞	串行 CPU：英特尔、AMD	并行加速：英伟达+CUDA、AMD GPU	演完的百倍史诗，框架原型
1	内存墙	算力增速远超带宽，吐字时 GPU 利用率<15%	普通 DDR 插条	HBM 堆叠：海力士/美光/三星；设备韩美；封装台积电	主升演过，回撒消化中
2	铜互连墙	趋肤效应，224G 时代铜缆传不过 2 米	铜 DAC/铜背板：安费诺、泰科	光模块→CPO：中际旭创/新易盛/Coherent/Lumentum；台积电 COUPE+奇景；衬底 AXTI	光模块炒过一波，CPO 第二幕

#	墙	物理极限 (一句话)	旧方案 → 代表公司	新方案 → 代表公 司	演到第几幕
3	散热墙	空气热容太低，风冷极限约 50kW/柜	风冷风扇散热器：台达、AVC	冷板→浸没液冷：Vertiv、英维克、申菱、高澜	中场
4	电流墙	损耗 $\propto I^2$ ，600kW 机柜用 54V 需 1.1 万安培	415V 交流+柜内 54V 电源：台达/光宝	800VDC+SiC/GaN：英飞凌/意法/安森美/罗姆/纳微/英诺赛科；设备伊顿/Vertiv	还没充分炒——当前甜点
5	电力墙	吉瓦需求撞上电网十年建设周期	市电+柴油备发：康明斯/卡特/潍柴	燃机+核电+储能：GEV/三菱/西门子能源；CEG/Talen；变压器日立能源/现代电气/效星	中后段，订单到 2029
6	微缩墙	光罩尺寸上限约 858mm ² ，单芯片没法再大	单片大芯片 SoC	Chiplet+CoWoS/SoIC：台积电；键合 ASMPT/BESI/韩美；封测日月光/Amkor	进行中，产能年年翻倍还缺
7	翘曲墙	有机基板与硅热胀失配，大封装翘边如披萨	ABF 载板：揖斐电/新光电气/欣兴	玻璃基板：SKC(Absolics)/三星电机/LG Innotek+康宁/电气硝子	片头曲刚响——最早期
8	衍射墙	193nm 光波长衍射极限，刻不出 7nm 以下	DUV 多重曝光：尼康/佳能（衰落史）	EUV→High-NA：ASML 独家；光学蔡司；光刻胶东京应化/JSR	EUV 已充分定价，High-NA 新章

三点钉牢脉络：

- **CPU 的小阳春是配比回摆，不是墙：**GB200 每柜标配 36 颗 Grace CPU，Agent 时代的任务编排、数据预处理都吃通用算力（英特尔近 1 年 +394%、Arm +103%）。但配比修复是“从 2% 回到 5%”的均值

回归，不是“2%→18%”的换血行情，弹性差一个量级。

- **存储墙藏着一个“新旧同涨”特例：**HDD 按框架该是被替代的旧方案，但三寡头十年没扩产、供给刚性比新方案还极端，于是旧方案演出了退场前的绝唱（希捷 +422%）。框架的胜负手永远在供给端。
- **面板覆盖检查：**九堵墙里数据面板已覆盖七堵半；变压器双雄（现代电气、效星）、键合机（韩美）、玻璃基板双雄（三星电机、LG Innotek）已于 7 月 5 日全部补入面板。

记忆卡：墙会传递——每拆一堵，洪水冲向下一个窄口；投资就是数着英伟达的路线图，提前站到下一堵墙前；现在水位最高的窄口是 800V，刚开始砌票房的是玻璃。

附录 一句话记忆卡合集

主题	一句话
三材料分工	InP 会唱歌进光模块，SiC 扛高压、GaN 打高频分段守 800V；CPO 是封装方式，点的还是 InP 的灯
800V 趋势	功率=电压×电流，损耗按电流平方算；54V 扛不动 Rubin 机柜，升到 800V——电压升 15 倍、损耗降 200 倍
供电链改造	GPU 永远只喝 0.8V；54V 出不了远门锁死柜内，800V 让电“集中生产、细管配送”，空间还给算力
推理与 HBM	训练摊薄搬运、算力是王；推理逐字重搬、带宽为王；Agent 拖箱长跑、容量称王——HBM 占了后两个王位
GPU 利用率	吐字时 GPU 干活不到一成五、连电都吃不满；缺口数学注定，但见顶信号看三家扩产的铲子声
推理优化	拼批、实习生代签、作者搬进印刷厂；效率提十倍、排队多百倍（杰文斯悖论），优化烧的是更多 HBM
物理墙框架	沿英伟达路线图找下一堵墙；“更好”变“必须”，供应链强制换血，行情在换血处

主题	一句话
三因子公式	时代来了吗、只有几家能供吗、客户有备胎吗；三问全过，占比才从 2% 跳到 18%
案例三桶	HDD 直播中、燃机变压器中场、丝杠玻璃候场；三因子找入场，this too will pass 定离场
三专题	叠饼机赚层数、变压器赚手艺垄断、玻璃赚披萨翘边；唯一在 2% 阶段的是玻璃
九墙全景	墙会传递，追着洪水跑；水位最高的窄口是 800V，刚砌票房的是玻璃

本笔记为个人学习记录，由费曼式对话整理而成，仅供学习研究，不构成任何投资建议。行情与事实数据时点为 2026 年 7 月 5 日，来源包括 VentureBeat、Sacra、SemiAnalysis、TrendForce、Yahoo Finance、Seoul Economic Daily 等公开资料。