

Kimi K3 与算力产业学习笔记

副标题：从 Kimi K3 的两份产业文档出发，拆解大模型架构、算力经济学与中美 AI 竞争全景

整理日期：2026 年 7 月 19 日 · 文中数据与新闻均以整理日为时点

阅读提示：本笔记由一场围绕“Kimi K3 与算力产业”的连续问答重组而成，按知识逻辑而非聊天顺序编排：先装工具箱（架构、财务、Infra 概念），再进入产业链与需求之辩，然后是公司案例，最后收拢成中美竞争全景。每章开头保留当时的原始提问，结尾附一句话记忆卡，附录汇总全部记忆卡速查。涉及股票与公司的内容仅供学习，不构成投资建议。

目录

- 第一章 模型架构工具箱——MoE、KV 缓存、KDA 与超节点
- 第二章 财务与商业概念工具箱——毛利率的两把尺子、微笑曲线与开源菜谱
- 第三章 推理 Infra 的厨房运营学——从池化到利润再分配
- 第四章 两份文档的解读与可信度评估
- 第五章 定价与成本经济学——每美元智能、任务总成本与 K3 的四个短板

第六章 算力产业链实况——B300、租赁条款与灰色渠道

第七章 算力需求之辩——份额、增量、两个池子与 ROI 口径魔术

第八章 公司案例——Kimi 的十年主线、字节的赛马困境与 Anthropic 的护城河

第九章 全景：中美大模型竞争史与壁垒的迁移

附录 一句话记忆卡合集

第一章 模型架构工具箱——MoE、KV 缓存、KDA 与超节点

你当时的问题：MoE 是 Mixture of 啥？“896 激活 16” 什么意思？KV 缓存为什么能砍 75%，砍了会有什么弊端，Claude 和 OpenAI 为什么不砍？“Scale-up 域的容量和带宽要求极高” “需要部署在 64 卡以上的超节点” 没读懂。“算力通缩” 是不是产能过剩？

MoE 与 “896 激活 16”：一家养了 896 个专科医生的医院。MoE = Mixture of Experts（混合专家模型）。K3 总参数 2.8T，内部像一家大医院养了 896 个专科医生（专家网络），每个病人（token）进来只叫 16 个最对口的会诊——这就是 “896 激活 16”，每次真正干活的参数只占约 2%，故称 “稀疏”。省的是计算量（只有 16 个医生动脑），省不掉的是驻院成本——896 个医生全得住院随叫随到：2.8T

参数用 MXFP4（4 比特极限压缩）存储仍要约 1.5TB 显存，而最强单卡 B300 只有 288GB，光装模型就要几十张卡。

KV 缓存：开卷考试的笔记。模型生成文字是开卷考试：每写一个新词要回看前文所有词。为免重算，把前文每个词的关键信息（Key/Value）存下来，这本“笔记”就是 KV Cache（Key-Value Cache，键值缓存）。问题是笔记随上下文线性变长——100 万 token 就有 100 万条，且每生成一个字都要把整本笔记从显存读一遍。长上下文时模型九成时间在“翻笔记”而非“思考”，瓶颈是显存带宽。

KDA：会自己擦的白板。KDA（Kimi Delta Attention）是 K3 的非主流架构赌注。学界早想用“线性注意力”替代笔记：只维护一块固定大小的白板，新信息来了往上写——但白板越写越糊（新旧信息互相干扰），所以坐了多年冷板凳。KDA 补了两刀：Delta（差量）法则——写新内容前先把同位置旧内容擦掉再写，记忆变成覆盖更新；精细遗忘门——白板分成小格，每格有自己的橡皮擦力度，模型自己学“这格信息留多久”。再配上混合比例：每 4 层注意力里 3 层用白板（KDA）、1 层保留完整笔记兜底精确检索——KV 缓存因此砍掉约 75%，1M 上下文吞吐提升 6.3 倍（两个数字是同一个改动的两面：每字要读的笔记只剩 1/4，省出的显存又能装更大批次）。

代价（天下没有免费午餐）：一是精确回忆变弱——摘要有损，“大海捞针”类任务退化，留 1/4 完整层只是兜底不是无损；二是缓存复用变难——传统 Paged KV 笔记分页可部分复用（不同对话共享相同开头），KDA 摘要卡是一路更新

的整体快照，差一个字就完全不同，只能精确续写、一人存一份，存储成本高，所以平台只保留 10 分钟。

闭源为什么“不砍”：其一你不知道他们砍没砍（闭源不发表论文，混合注意力类技术内部可能早有）；其二约束不同——中国实验室被管制卡显存，砍缓存是生存刚需，算力富裕的公司与其冒质量风险改架构不如多买卡（稀缺逼创新，富裕容忍冗余）；其三改注意力机制等于换地基，须从头预训练全套验证，对靠可靠性收高毛利的公司不划算。

Scale-up vs Scale-out：同桌开会 vs 视频连线。连接 GPU 有两种方式：Scale-up（纵向扩展）把几十张卡用 NVLink 级高速专线焊成“一张大桌子”，面对面喊话，带宽是普通网络几十倍，但桌子做不了无限大；Scale-out（横向扩展）是桌子之间拉网线开视频会，人数无限但慢一个数量级。“Scale-up 域”就是同一张桌子的成员范围。K3 用 WideEP（宽专家并行）把 896 个医生摊在几十张卡上，每个 token 都要跨卡喊医生，必须发生在同一张桌子上——所以要 64 卡以上的“超节点”（英伟达 NVL72 为 72 卡一桌，华为 CloudMatrix 为 384 卡一桌）。国产芯片单卡打不过，就把桌子做大——“以多补弱”，用系统能力换芯片能力；K3 这种“必须一大桌人伺候”的模型恰是国产超节点的对口客户，这就是“国产超节点红利”。

算力通缩的正解：不是已发生的产能过剩，而是一种担忧/叙事——怕模型效率提升让单位智能所需算力缩水、卡卖不动（DeepSeek 时刻英伟达单日跌 17% 即此叙事发作）。“无所谓算力通缩”意为 K3 亲手证伪了它：效率提

升省下的算力，立刻被 2.8T 参数、64 卡起步的更大野心吃掉——省 = 多用（杰文斯悖论）。

记忆卡：MoE 是 896 个医生只叫 16 个会诊的稀疏医院；KDA 是会自己擦的白板，换来 75% 缓存削减与 6.3 倍吞吐，代价是摘要有损、快照不能共享；超节点是把几十张卡焊成的一张桌子，国产芯片靠拼大桌子以多补弱。

第二章 财务与商业概念工具箱——毛利率的两把尺子、微笑曲线与开源菜谱


你当时的问题：1P API 是什么？成本利润率 545% 怎么会超过 100%？微笑曲线我一直了解得不透彻，展示展示？开源的 Kimi 为什么还能收费？我 128G 内存的 Mac 能装吗？大公司自部署都不用给 Kimi 交钱、不需要授权吗？

1P API 与渠道。1P = First-Party（第一方），指 Anthropic 自己直接卖的 API（Application Programming Interface，应用程序接口），钱全进自己口袋；对应 3P（第三方渠道，如 AWS Bedrock、Google Vertex），云厂商抽成后毛利变薄。SemiAnalysis 报道 Anthropic 1P API 毛利率约 75-80%（2026 年中）。

成本利润率 vs 毛利率：煎饼摊的两把尺子。DeepSeek 2025 年 3 月披露推理系统“理论成本利润率 545%”：成本 100 元、收入 645 元、利润 545 元。成本利润率 = 利润 ÷ 成本 = 545%（分母是小小的成本，暴利生意可轻松破百、上不封顶）；毛利率 = 利润 ÷ 收入 = 545/645 ≈ 85%

（利润永远是收入的一部分，天生超不过 100%）。同一个煎饼摊，两把尺子：投 1 块赚 5 块 4，等价于每收 1 块里 8 毛 5 是赚的。换算式：成本利润率 545% $\Leftrightarrow$ 收入是成本的 6.45 倍 $\Leftrightarrow$ 毛利率 84.5%；Anthropic 毛利 75% $\Leftrightarrow$ 收入是成本 4 倍 $\Leftrightarrow$ 成本利润率 300%。口径不统一就没法比较。另注意 545% 是理论值——假设每个 token 都按标价收到钱，实际因免费流量与折扣远低于此。

微笑曲线：利润长在壁垒上。1992 年宏碁施振荣提出：把产业链各环节的利润率画出来，两端高（上游研发专利、下游品牌服务）、中间低（制造组装），像微笑的嘴角。经典例证是 iPhone 账单：苹果凭设计品牌拿走过半利润，上游台积电高通吃丰厚毛利，中间组装的富士康每台只赚个位数美元。原理一个词：可替代性——中间“谁都能干”拼价格，两端“只有我能干”（专利垄断、品牌粘性）有定价权。必须记住反例：台积电位置在“中间制造”却是全链利润王，因为它把制造做到全球无可替代——决定利润的从来不是位置，而是该环节壁垒的高度，微笑只是壁垒分布的常见形状（日本产业界还提出过中间高的“武藏曲线”反驳版）。映射到 AI：上游芯片（英伟达/HBM/EDA）笑，下游应用（用户入口）笑，中间的开源模型层与纯推理代工哭。



开源 = 公开菜谱，不 = 免费吃饭。Kimi 开源指权重文件免费公开下载（菜谱免费），但 API 收 \$3/\$15 收的是“代工做饭”钱：替你养超节点、付电费、雇运维。个人电脑装不下——K3 光权重约 1.5TB，128GB 的 Mac 只有需求的 1/12（不过 128GB Mac 跑 30B–70B 级开源模型绰绰有余）；K3 的开源是开给拥有超节点的机构看的。**许可证即授权：**部署不需要找 Kimi 签合同，遵守许可证条款即自动生效——K2 用改良版 MIT（月活超 1 亿或月收入超 2000 万美元须显著标注 Kimi 字样），Llama 则规定月活超 7 亿须单独谈授权，K3 条款以 7/27 权重开放时为准。**收入全归部署者，利润另说：**人人都拿同一份菜谱，没有独家性，价格必被卷到贴近成本——赚钱只能靠厨房比别人省、稳、近。Kimi 白送菜谱图的是事实标准、心智与流量（安卓免费，谷歌照样是赢家）。

记忆卡：545% 和 85% 是同一门生意的两把尺子（分母一个是成本一个是收入）；微笑曲线画的其实是壁垒的分布，

台积电证明位置不是宿命；开源开的是菜谱不是饭，许可证即授权，但人人同谱，利润只归厨房开得最好的人。

第三章 推理 Infra 的厨房运营学——从池化到利润再分配

你当时的问题：算力调度池化、PD + vLLM、Mooncake 分离式推理、分布式 KV Cache 池、多级缓存和缓存降级都是什么？Infra 指什么？“CSP 和国产算力将享受顶级开源模型的利润再分配机遇”没太懂。缓存只保留 10 分钟，对用户什么利弊？对 Kimi 好处是什么？

Infra = Infrastructure（基础设施），此处特指跑推理服务的软硬件底座。超节点是大厨房，这一章全是“厨房运营学”：

术语	大白话	厨房类比
算力调度池化	零散的卡汇成共享池，谁有活谁用，不让卡闲着	共享厨房，灶台永不空烧
PD 分离	推理分两段：Prefill（读题）吃算力，Decode（写答案）吃显存带宽，拆到两组卡各干各的	备菜间和炒菜灶分开
vLLM	最流行的开源推理引擎；“PD + vLLM”即在该引擎上实现 PD 分离	厨房管理系统软件
Mooncake 分离式推理	Kimi 自研并开源的推理架构：PD 分离 + 以 KV 缓存为中心的分布式缓存池	Kimi 公开了自家厨房动线图纸
分布式 KV Cache 池	“笔记”集中放进全集群共享仓库，老客户来了任何灶台都能调取，不用重读全文	中央食材库统一冷藏半成品
多级缓存与缓存降级	笔记按热度分层：最热放 HBM，温的放内存，冷的放 SSD，过气自动下放	手边调料架 → 后厨货架 → 地下冷库

这些“抠门技术”直接等于毛利率：推理成本 = 卡的租金 ÷ 榨出的 token 数，上面每一项都在放大分母。同样一批卡，

Infra 功夫到家能多榨两三倍 token——K3 定价 \$3/\$15 还能保住约 50% 毛利，靠的就是这套功夫；功夫差一档的厂商跑同一个模型可能直接亏本。

缓存 10 分钟的利弊账。API 多轮对话每轮都要重发全部历史，厂商把已“读过题”的部分缓存，命中通常只收约一折且首字更快。只留 10 分钟意味着：你离开一刻钟回来，笔记已被扔掉，几万字历史按全价重读，这轮输入费翻约十倍。对连续快跑的 Agent 无碍，对人类真实节奏（开会、隔天续聊）很伤。这不是利弊权衡而是架构代价的暴露：KDA 快照“谁也不能共享、一人存一份”，长期保留的存储账算不过来——省显存的红利归 Kimi 的成本表，缓存失效的账单寄给用户的发票（按 token 计费世界里的激励错位，全行业通病，K3 的架构放大了它）。

利润再分配的完整逻辑：闭源时代利润集中在配方持有者（Anthropic 拿 75% 毛利，代工推理的 Oracle 只有 14–16%）。顶级菜谱免费公开后，配方环节利润被压缩，但钱不消失，流向把饭做得又便宜又稳的人——有大厨房（超节点）+ 好动线（这套 Infra）的 CSP（Cloud Service Provider，云服务提供商）与国产算力厂商。AI 产业链的利润池从“卖配方的”往“开厨房的”搬家。

记忆卡：池化不空灶、PD 分离各司其职、缓存池不重复备菜——Infra 功夫全变成毛利；菜谱一开源，利润就从卖配方的手里流进厨房开得最好的人口袋，这就是利润再分配。

第四章 两份文档的解读与可信度评估

你当时的问题：为我分析这两个 PDF，解读解读，点评点评。

第一份《Kimi K3 对产业的积极意义》（DJN/Colin）：质量较高的多头框架。核心论证链：K3 = 2.8T 超大稀疏 MoE → 权重吃掉 1.5TB+ 显存 → 必须 64 卡超节点推理 → 无所谓算力通缩，利好 CSP 与国产超节点。两点加分：其一不回避缺点（实测 62 TPS 低于同档中位数 72、缓存仅留 10 分钟、Agent 框架不适配级联调度），利空自曝提升可信度；其二提出了全文最值的判断——开源崛起后模型分发权向 CSP 转移，Anthropic 的 ARR（Annual Recurring Revenue，年度经常性收入）不再是跟踪行业景气的唯一指标，估值锚在迁移。需打折处：结尾“我们有充足的信心保持乐观”暴露立场先行；“接近 Fable 5 水平”基于挑选出的最佳演示案例（48 小时芯片设计、2 小时科研编程），演示不等于平均水平。

第二份《产业专家交流》：信息密度高但需大幅折价。给出一手价格数据（八卡机月租 50 万+、B300 长协 28 万/月年内涨 3 倍、期货 550 万到付款 1000 万、违约罚则 30–40% 加 10% 预付），若属实说明高端算力租赁处于极度卖方市场。但专家会议纪要可信度最低的信息品类之一：数字精确得可疑（“Kimi 账上近 400 亿现金”“ROI > 10”无口径无来源）、“从 Meta 谷歌同行了解下来”超出正常信息半径、B300 灰色链条中人有渲染紧缺抬价的动机。使用原

则：方向可参考，绝对值当情绪温度计，不拿任何具体数字做测算。

交叉结论：两份文档指向同一命题——K3 越强、算力需求越涨（杰文斯叙事），方向成立；但纪要里疯狂的租赁条款既可读作“需求好”，也可读作典型的周期顶部特征（2021 年的集装箱运价、矿卡价格都长这样）。真正健康的信号是超节点大规模落地、推理成本持续下降、红利向应用传导；租金暴涨恰说明供给瓶颈在透支下游 ROI。

记忆卡：第一份的框架可以收藏（CSP 承上启下 + 估值锚迁移），第二份的数据只能当温度计——它告诉你市场很热，但别拿里面任何数字做投资测算。

第五章 定价与成本经济学——每美元智能、任务总成本与 K3 的四个短板

你当时的问题：Dylan Patel 说“定价差异是利润率差异而非效率差异”，是不是像大家生产纸巾成本一样、利润全看卖价？训练成本为什么难量化？DeepSeek 和 K3 到底有没有效率优势，国内是不是亏本卖？K3 的“极致性能”指什么、对 Kimi 好处是什么？K3 消耗 token 特别快，完成同一任务算下来反而更贵，用户为什么还要用它？

用毛利率倒算真实成本。Dylan 的推理是反推题：价格 × (1 - 毛利率) = 成本。

	Opus 4.8	Kimi K3
标价（每百万 token 输入/输出）	\$5 / \$25	\$3 / \$15

	Opus 4.8	Kimi K3
假设毛利率	75%	50%
倒算真实成本	\$1.25 / \$6.25	\$1.5 / \$7.5

标价差 40%，倒算的生产成本几乎一样——便宜不是造得省，而是主动少赚。你的纸巾厂类比成立，加两个限定：成本相近是推理侧粗略倒算（受硬件、批处理、利用率影响），且只覆盖推理。

训练成本难量化：边界画在哪没有标准答案。四层原因：最终一跑 vs 全部试错（DeepSeek V3 著名的 558 万美元只是最终预训练的租赁等价成本，不含失败实验、消融、数据清洗、后训练）；自有卡按折旧还是市场租金算，差数倍；人力与数据从不计入；闭源根本不公布。任何训练成本数字误差以“倍”计。

效率优势与“亏本卖”的正解。中国实验室有真实的工程效率创新（MLA、FP8、极稀疏 MoE、KDA），相对公开基线领先；但闭源内部可能早有类似技术，“中国训练更省”无法证实，能证实的是研究算力更少、每块 GPU 被压榨得更狠。亏本与否分两层：单看推理生意国内不亏（50% 毛利照样赚）；看公司整体全行业几乎都亏——推理毛利盖不住训练研发（OpenAI 2026 年 Q1 收入 57 亿美元烧掉 37 亿、全年预亏约 140 亿，来源：Fortune/Yahoo）。准确说法：大家推理成本相近，Anthropic 敢定高价且客户愿付（能力与品牌溢价），毛利厚规模大先摸到盈亏平衡；国内低价换份额。定价权本身就是护城河的体现。

K3 四短板一根线串起。其一默认 max 思考强度 token 消耗大、指令模糊时“过度主动”（帮你看文件顺手把文件改了

——烧钱且越权）；其二 2.8T 级权重部署门槛极高，实测输出 62 TPS 低于同档中位 72（但 TTFT 1.99s 占优：第一个字来得快，之后每个字蹦得慢）；其三缓存仅留 10 分钟（见第三章）；其四 Agent 框架须完整回传历史思考——换模型接力时“内心独白只有自己看得懂”，挡死了级联调度（简单步骤派便宜小模型、难步骤请大模型的省钱标配），Swarm Max 蜂群模式（几十个子智能体并行数小时）的调度稳定性只有厂商演示、无第三方复现。全是“为极致性能付出的通用性代价”：极致性能 = 超长上下文 + 单卡吞吐 + 长程 Agent，红利进 Kimi 的成本表，话痨与缓存失效的账单寄给用户。

任务总成本才是真尺子，但证据未定。该看的不是每百万 token 单价，而是做完一件事的总价。用户端“烧 token 快”的抱怨是真实信号；但 Artificial Analysis 的口径恰是“每个智能任务的成本”——K3 约 \$0.9/任务与 GPT-5.6 Sol 打平，低于 Opus 4.8（约 \$2）与 Fable 5（约 \$3-4）。榜单工况与真实工况可能有差距，结论悬而未决。且思考强度是可调开关、缓存时长是工程问题大概率会修——别用暂时的毛病下永久的结论。**K3 的长期饭票**也不在“比 GPT 便宜”：中国用户的菜单上本来就没有 GPT/Claude（见第七章两个池子），海外用户图的是闭源给不了的私有部署与自主权——别拿油耗否定一辆能自己改装的车。

记忆卡：推理成本大家半斤八两，差别在敢不敢卖贵；训练这本账谁都算不清；K3 的四个短板全是极致性能的通用性代价——按 token 计费的世界里，永远算“做完一件事的总价”，而不是单价。

第六章 算力产业链实况——B300、租赁条款与灰色渠道

你当时的问题：B300 和 H200 是什么？“月租超过 50 万/台八卡服务器”什么意思？Kimi 找 AWS 租算力，数据会不会被亚马逊盗取？国内外租赁有什么区别？“五年闭口长协 28 万/月”“违约罚则 30-40%”“对有交付能力的公司另有 10% 预付”是什么意思？中国能搞到卡的租赁公司都有哪些？

两代 AI 发动机。都是英伟达数据中心 GPU（不是游戏显卡）：H200 是 Hopper（2022 代）旗舰的“大油箱改款”（显存 141GB）；B300 是 Blackwell（2024 代）的加强版 Blackwell Ultra（显存 288GB），当前最强量产旗舰。显存关键因为模型和“笔记”都得装进去。两款按美国出口管制都不能合法卖入中国大陆——纪要里的二手渠道、期货加价、租金暴涨全是管制造成的灰色溢价。

租金账。AI 服务器标准形态是一机箱 8 张 GPU（八卡机），万卡集群约合 1250 台八卡机。 $50 \text{ 万/月} \div 8 \text{ 卡} \div 720 \text{ 小时} \approx 87 \text{ 元/卡/小时}$ （约 12 美元），是海外行情（H200 约 2-4 美元/时）的约三倍——“中国客户可触达渠道”的稀缺溢价。

合同术语逐条翻译（租房类比）：五年闭口长协 = 五年死约且价格锁死（“闭口”对应可调价的“开口”，工程合同术语）； $28 \text{ 万/月一台八卡机} \times 60 \text{ 个月} = 1680 \text{ 万}$ ，而设备下游售价约 1300 万（期货原价 550 万）——房东光收租五年

就赚回整台设备还有余，这就是 A 股公司抢做这门生意的原因；违约罚则 30-40% = 租客中途毁约赔合同总额三四成；“对有交付能力的公司另有 10% 预付” = 反过来读——市场上“PPT 房东”太多，租客愿意先付定金给真能交货的公司排队锁货。租客给房东塞定金，是卖方市场热到极致的标志。

数据安全与国内外区别。云厂商是银行保险库：物理上摸得到你的箱子，但整个商业模式建立在绝不开箱之上，加上加密、隔离、客户自持密钥，“AWS 偷 Kimi 模型”不是现实风险。真正的区别在四条：管辖权（美国 CLOUD Act = Clarifying Lawful Overseas Use of Data Act，政府可依法调取）、政策风险（随时可能被禁止中国公司用美国云训练，训练到一半断供）、合规（训练数据出境须过中国监管）、芯片（去海外租就是为了合法用上顶级卡）。另一个结构性软肋：阿里既是 Kimi 大股东和算力房东，又是直接竞争对手（Qwen）——算力紧张时房东先保自家孩子，供应商集中 + 利益冲突比数据安全风险大得多。

A 股算力租赁版图（截至 2026 年 6 月，证券时报等）：70 多家公司跨 15 个行业入局，分四层——真龙头（英伟达授权 + 重资产 + 稳定大客户订单）：利通电子、润泽科技、协创数据；专业算力/云出身：并行科技、青云科技、优刻得、首都在线；IDC 底座转型（手握电力指标与机柜——电才是最终瓶颈）：数据港、光环新网、奥飞数据、云赛智联；跨界闯入者（养猪的做味精的都来了，业绩冷暖两重天）：鸿博股份、中贝通信、莲花控股、华铁应急等。**关键提醒：**B300 属管制品，没有公司会在公告里承认持

有，“能搞到 B300 的不超过 6 家”永远无法从公开信息验证；辨真假只看三个硬指标——资产负债表上的设备（固定资产/在建工程暴增）、现金流量表的购买支出、真实确认的租赁收入。公告签约金额是最廉价的信号：签约 $\neq$ 交付 $\neq$ 收钱。这门生意本质是高价囤卡吃租金差，供给一旦放量（特供版或国产芯片）、租金跳水，囤卡最猛杠杆最高的摔得最重，且股价先于租金见顶。

记忆卡：B300/H200 是两代 AI 发动机，管制给它们贴上三倍中国溢价；闭口长协是五年死价租约，房东五年净赚一台设备；租客塞定金说明缺货是真的——但历史上每次“租客求房东”的市场，离租金见顶都不远了。

第七章 算力需求之辩——份额、增量、两个池子与 ROI 口径魔术

你当时的问题：K3 的算力需求是行业整体增加，还是抢了 Anthropic 的份额？中国用户“用不上”Anthropic 是真的吗，Anthropic 的 ARR 构成里中国很少吗？“下游厂商 ROI > 10”的下游是谁、数据准不准？大厂资本开支会不会降？半导体最近下跌是不是纯找借口？K3 竞争激烈是不是利好 CSP 和应用？

份额与增量同时发生，增量主导。“该怎么用还是怎么用”的假设在 Agent 时代不成立：聊天时代一个用户一天烧几万 token，Agent 时代一句“做个炉石传说”自主跑 2-3 小时、烧掉成百上千倍——这些需求在 K3 之前不是被谁服

务着，而是根本不存在（太贵或能力不够）。便宜且够强的模型唤醒沉睡需求，是净增量（修高速的逻辑：路一便宜，原来不开车的人全上路）。纪要自带证据：199 元套餐 10–12 小时烧完、周末高峰用不了——排队本身就是需求大于供给的铁证。

两个池子：出口管制把全球算力切成两半。这不是比喻而是财务事实。Anthropic 一直不对中国大陆提供服务（订阅和 API 都在禁令内），2025 年 9 月升级为中资控股超 50% 的全球子公司一律禁用；2026 年 7 月指控阿里用约 2.5 万个假账号进行 2800 万次对话的“蒸馏攻击”，阿里同步内部禁用 Claude（CNBC）——被压制的需求大到大厂开马甲偷用，但马甲变不成正规采购。Anthropic ARR 2026 年 5 月官宣破 470 亿美元、7 月第三方估计约 690 亿（年化口径，非每月），75–85% 来自 API，客户主体是美西方企业，中国正规贡献约等于零。中国企业“不敢用”的三道锁：中国备案监管（面向公众的服务必须用备案模型）、数据出境合规、断供风险；OpenAI 完全同理。所以国内企业的现实菜单就是 DeepSeek、Qwen、Kimi、智谱、豆包——K3 在国内引爆的推理需求对国产算力几乎是纯增量，没有从 Anthropic 集群搬走一瓦电；真正的替代只发生在海外价格敏感开发者身上，影响 Anthropic 的利润率，不影响全球 GPU 总需求（token 换人服务，卡照样转）。受益梯队：云厂（阿里云、字节火山引擎、腾讯云、百度智能云）确定性最高，二线云（金山云等）弹性大盈利弱，国产芯片（华为昇腾、寒武纪、海光、摩尔线程 + 中芯国际）受益于替代逻辑但要过良率生态两道坎。

训练端是军备竞赛，只做加法。K3 越成功，所有人越要更早更大地训下一代（纪要：6T 模型要 3-4 个万卡集群）——对手花钱逼你花更多钱。宏观印证：五大云厂 2026 年资本开支预计约 6000 亿美元（2024 年约 2560 亿），token 消耗有机构预测到 2030 年再涨 24 倍（CreditSights/Futurum）。

ROI 口径魔术。“下游厂商”指产业链下游=租算力干活的模型与应用公司。三个数字的真相： $ROI > 10$ （纯推理）= $API \text{ 收入} \div GPU \text{ 租金}$ ，扣掉了免费流量、研发工资、闲置；“算训练后 $ROI > 3$ ”命门在模型寿命假设（旗舰 6-12 个月就过时，摊销期砍半 ROI 砍半）；“云厂商 $ROI > 2$ 、每个环节都赚钱”被 Oracle 当场证伪——内部文件显示其租英伟达卡给 OpenAI 的毛利仅 14-16%（CNBC/DCD）。

与“OpenAI 巨亏”的调和：卖 token 的单位经济学为正，公司报表巨亏是因为把毛利连本带息砸进下一代训练与基建——亏损是扩张的选择（面包店每个面包赚钱，老板同时在建十家新店）。并且注意专家的屁股：论证终点是“算力再涨价 1-2 倍也便宜”，这是算力卖方最想让买方相信的话术。资本开支不会降的结论成立，但理由是付费推理单位经济学为正 + 军备竞赛谁停谁出局，不是“每个环节都赚钱”的童话。

2026 年 7 月半导体下跌的解读。SMH 当月跌超 17%，导火索有两个：K3 发布引发的“算力通缩”恐慌（DeepSeek 时刻重演，历史剧本显示大概率错杀——上次暴跌后资本开支不降反升股价新高）；以及 Meta 宣布成立 Meta Compute 外卖富余算力——这是性质不同的供给侧信号（连

买卡最凶的巨头都有余粮外卖，“缺疯了”叙事出现第一道裂缝，正是“供给管道变粗、租金见顶”剧本的美国版预告片）。高估值定价完美，任何瑕疵都是下跌的充分理由——短期是投票机，长期是称重机；“完全不合理、纯找借口”说过头了。验证点：巨头财报资本开支指引是否下修、Meta Compute 定价是倾销还是高价。

受益排序（模型竞争加剧的完整图景）：应用（纯受益，原材料降价）> 上游芯片（军费加码）≈ 会运营的 CSP（利润搬家接收方）> 不会运营的 CSP（伪受益，Oracle 为证）> 模型层（出血方，75% 毛利被开源从底部侵蚀、被同行正面对轰）——微笑曲线两头笑、中间哭；一切的前提是资本市场继续愿意付军费。

记忆卡：K3 对 Anthropic 是抢份额，对算力行业是修高速；两个池子是财务事实（ARR 690 亿美元里中国约等于零、马甲 2.5 万个）；ROI>10 是口径魔术，Oracle 的 14% 和 OpenAI 的巨亏才是全账本；模型打架，两边看戏的都赢。

第八章 公司案例——Kimi 的十年主线、字节的赛马困境与 Anthropic 的护城河

你当时的问题：K3 出来之前怎么感觉 Kimi 没什么存在感，为什么是这个团队？字节的赛马文化和充足算力，为什么做不出 DeepSeek/Kimi 这样的产品？Claude 靠 To B 和 Agent 数据飞轮遥遥领先的说法对吗？Anthropic 的后训练先发优势是

不是永远拉不开差距？CSP “承上启下” 的判断你认可吗？

Kimi：突兀感来自观察位置。时间线：2023.10 上线主打 20 万字长文本 → 2024 上半年全民爆火（第一次高光，A 股炒概念）→ 2024 下半年投流烧钱被诟病、仲裁风波 → 2025.1 被 DeepSeek 时刻盖住 → 战略急转弯（砍投流、转开源、回归模型）→ 2025.7 K2 开源（1T 参数）海外轰动 → 2025.11 K2 Thinking（约 460 万美元训练成本比肩闭源旗舰）→ 2026 年 K2.5/K2.6/K2.7 Code 一季一发 → 2026.7.16 K3。K3 是连续第六级台阶，前五级搭在开发者舞台（HuggingFace/GitHub），大众媒体只报破圈时刻不报爬楼梯。**为什么是他们：**创始人杨植麟（1992 年生，清华 → CMU 博士）是 Transformer-XL 和 XLNet 的共同作者——Transformer-XL 解决的正是超长序列问题，从 20 万字长文本到 KDA 的 1M 窗口是同一条研究主线走了十年，敢押非主流架构因为那是他最熟的领域；技术型创始人是人才磁铁，研究品味（敢把旗舰押在 KDA 上）是算力买不来的资产；阿里持股 30%+、数百亿现金弹药；DeepSeek 蹚出了开源逆袭路线图。所谓跨越式创新，永远是外部视角的突变 + 内部视角的连续——判断一家公司是不是昙花一现，看喷发前有没有那条安静的积累曲线。

字节：赛马选得出最快的马，选不出第一辆汽车。先纠偏：字节 Seed 团队不弱（2026 年 Seed 2.0/2.1 旗舰、豆包是分发之王），“不行”的印象一半来自旗舰闭源、不上开源榜单。但没有“DeepSeek 时刻”有三个组织学原因：赛马逻辑的适用边界——赛马前提是反馈快、可量化、试错便宜

（推荐算法 A/B 一天出结果），而预训练旗舰是周期一年、中途无中间指标、单次几亿美元的一次性大爆炸项目，赛马只会摊薄算力人才，且非主流架构前期跑分一定难看，任何按季度考核的机制都会淘汰 KDA 这种赌注——它能活下来只因杨植麟是创始人兼首席研究员一人拍板（DeepSeek 梁文锋同理），激进的研究赌注需要“研究独裁者”，大厂决策机制天然生产稳妥的平均值；目标函数不同——字节模型团队的真实 KPI 是伺候几亿日活（成本延迟安全够用），考核什么就得到什么；富裕容忍冗余——算力充足可以暴力堆卡快速跟随，fast-follow 对它是理性策略（让创业公司去承担架构试错，验证了再用规模碾压）。公道话：微笑曲线两个笑的位置（豆包应用 + 火山引擎云）字节都占，做不出“时刻”对它的商业结局未必重要。

Anthropic 飞轮的修正版。“压对方向（To B + 编程）”是对的，但“用户数据直接反哺训练”机制不准——

Anthropic 默认不用企业 API 数据训练。真飞轮有两个：收入飞轮（编程 API 是最肥现金流，钱变算力）；评测与环境飞轮（大规模真实使用让它知道模型在哪摔跤，从而构造更好的 RL 训练环境与内部评测）。推论：编程恰是“可验证任务”（代码跑不跑得通机器自动判分），不依赖私有数据也能大量生成训练信号——这是开源模型在编程上追得最快的原因；真正难追的是不可验证任务（品味、长程判断）。

RL 后训练与新护城河。预训练养出书呆子（读完图书馆但不会干活），SFT（Supervised Fine-Tuning，监督微调）是老师傅示范（徒弟超不过老师傅），RL（Reinforcement Learning，强化学习）后训练是把模型扔进“模拟工

厂”（任务环境：能真跑代码的沙盒、能点击的模拟浏览器，装着数万个“修好这个 bug、测试通过才算赢”的任务）自己试错、按结果奖惩，可以超越人类示范（AlphaGo 逻辑）。环境的死穴：太简单学不到真本事，有漏洞模型学会作弊（reward hacking，比如删掉测试用例让测试“通过”）。评测体系 = 绝不公开的私有考卷（公开榜单会被刷题污染）。这是最深的商业机密：抄不走（不在论文里）、买不到、砸钱速成不了（需要真实使用数据告诉你该造什么练功房）。

但先发优势会漏气，四条通道：成品即泄密（输出行为可被蒸馏——阿里 2.5 万个马甲就是活案例）；人才跳槽（环境库带不走，方法论和品味装在脑子里——Meta 成建制挖走 OpenAI 的赵晟佳们）；可验证任务的练功房人人能重建（GitHub 是公共的，这正是 K3 前端代码榜第一的原因）；方法论被论文开源（DeepSeek R1 公开推理 RL 配方，全行业水位整体抬高）。历史投过反对票：2022 年 OpenAI 靠 RLHF 独步天下，两年内全行业学会。后训练的领先是“时间差租金”——永远领先六个月，但永远只有六个月；Anthropic 的解法是往下游占位置（Claude Code 卡住程序员工作流），让泄漏速度赶不上迭代速度。护城河不是挖一次就完工的沟，是每天都要重新挖深的沟。

对“CSP 承上启下”的评审结论：方向认可六七成——分发权转移、数据主权驱动、ARR 降级为“指标之一”都成立；但“占据上风”言之过早（前沿仍在闭源手里，企业关键业务为最强付溢价），分发权不等于利润（Oracle 为证），且闭源在垂直整合反击（OpenAI 的 Stargate 本质是自建

CSP，分发权之争最终打的是谁拥有用户关系）；结尾“我们有充足的信心保持乐观”说明是带仓位观点。验证指标：CSP 财报 AI 收入披露口径、开源模型的生产级推理份额、GPU 租赁真实毛利率。


记忆卡：K3 是十年长文本主线的第六级台阶；字节输在赛马机制天然淘汰前期难看的赌注；Anthropic 的新护城河是 RL 练功房与私有考卷，但先发者赚的是永远六个月的时间差租金——靠飞轮转速续租，而不是一劳永逸的地契。

第九章 全景：中美大模型竞争史与壁垒的迁移

你当时的问题：回看中国大模型发展史应该如何客观评价？2022-2026 年中美各多少分，预测 2027-2029？为什么追赶发生在中国而不是日本、印度、英国、俄罗斯？华人在美国 AI 实验室到底多到什么程度？现在中美差距的壁垒在训练还是推理？

逐年评分（能力感受分，非线性——后段每一分都比前段难十倍）：

年份	美国	中国	差距感受	定标事件
2022 末	60	8	代差约 2 年	ChatGPT 问世；中国无对标产品但非零基础
2023	75	30	约 18 个月	GPT-4 vs 百模大战
2024	85	60	约 8 个月	o1/Claude 3.5 vs 年底 DeepSeek V3
2025	92	82	3-6 个月	GPT-5/Claude 4 vs R1 时刻 + K2 开源
2026	96	91	一个身位	Fable 5/GPT-5.6 vs K3 榜三
2027-29e	97→99	94→98	贴身缠斗	开源层面反复互超，绝对前沿仍在美国



客观评价：成就是真的，配三个冷静。从代差追到一个身位、且在买不到最好芯片的前提下完成，全球仅此一例。但：最后一公里最贵——从 91 到 96 需要的不是追赶（有路标）而是原创（没路标），原创吃的正是中国最缺的研究算力；追赶仍站在美国生态上——K3 用 B300/H200（灰色渠道）训练，硬件自主层面差距远没有模型层好看；“接近”与“引领”是两个物种——交卷时间差三个月和出题权不是一回事，所有考卷（Transformer、RLHF、推理范式）都还是美国出的题。

为什么是中国：四张牌必须同时在手。人才存量（全球顶尖 AI 研究员近半产自中国，几十年教育投资的复利）；完整互联网工程生态（大厂、场景、数据、工程师军团）；超大单一市场 + 资本，且美国服务被隔离在外形成真空保护带；稀缺逼出的效率创新 + 开源奇袭路线。对照：日本缺超大互联网平台与人才密度，英国有 DeepMind 但被谷歌收编、人才被硅谷虹吸，印度前沿研究与资本两头薄，俄罗斯制裁加人

才外流——四缺一都不行，这不是奇迹，是几十年积累恰好凑齐一桌牌。

华人人才的硬数据（MacroPolo 全球 AI 人才追踪）。在美国机构的顶尖 AI 研究员（前 20%）中，中国本科出身占 38%、美国本土 37%——华人与东道主并列最大来源，合计四分之三；全球顶尖 AI 研究员 47% 本科毕业于中国（2019 年为 29%），美国雇佣全球约 57-59% 的精英——中国生产人才，美国消费人才。分布形状：研究一线极强（OpenAI 首席研究官 Mark Chen、被 Meta 挖走的赵晟佳、xAI 创始团队十二人中约五席华人），决策顶层缺席（Altman/Amodei/Hassabis/马斯克，无华人统帅）；印度裔正相反（研究一线不如华人密集，CEO 层极强）。“硅谷回流”的准确版本是三层：留存率上升（更多人不出国或直接回国，DeepSeek 团队几乎全本土博士为极致证明）、少量高调回流（签证收紧 + 国内机会变好在加速）、知识回流（38% 的在美华人构成校友网络，方法论持续回传）。中国的底气不在回流而在产量：47% 的产量，漏到本土的零头就够打追赶战。

壁垒的迁移（本笔记的收官判断）。预训练壁垒在下降（配方公开化、数据见顶），推理服务在商品化（Infra 技巧全行业扩散、毛利被卷）。真正的护城河剩三样：RL 后训练的任务环境与评测体系（最深的商业机密）；研究算力（试错次数 = 原创能力，美国对中国真正的卡位）；分发与 workflows 的嵌入位置（Claude Code 们占住程序员的手）。使用数据反哺的主要是后训练（RL、评测），基本不反哺预训练，

也不是推理本身——推理只是收钱和观察的窗口。追赶的故事接近尾声，出题权的战争刚刚开始。

记忆卡：四年从代差追到一个身位，靠的是全球唯一凑齐的四张牌；华人是美国实验室里 38% 的兵团但不是统帅部；最后一公里拼原创，原创拼研究算力和 RL 练功房——追赶看模型榜单，出题权看谁先定义下一个范式。

附录 一句话记忆卡合集

主题	一句话记忆卡
两份文档	第一份的框架可收藏，第二份的数据只当温度计——别拿专家会的数字做测算
定价与效率	推理成本半斤八两，差别在敢不敢卖贵；定价权本身就是护城河
545% vs 85%	成本利润率分母是成本可上千，毛利率分母是收入超不过 100%——同一个煎饼摊的两把尺子
KV 缓存与 KDA	四本笔记三本换成会自己擦的白板：翻得快了，但摘要有损、只能精确续写
B300/H200	两代 AI 发动机，管制贴上三倍中国溢价；租 AWS 不怕被偷、怕被断
份额 vs 增量	K3 对 Anthropic 是抢份额，对算力行业是修高速——路一便宜，不开车的人全上路
租赁条款	闭口长协是五年死价租约；租客塞定金说明真缺货，但“租客求房东”的市场离见顶不远
ROI 口径	ROI>10 是把最肥一段单拎出来的口径魔术；Oracle 的 14% 和 OpenAI 的巨亏才是全账本
CAD/EDA/反编译	三者都是“错一步就全废”的专业硬活，用来证明 K3 能干真工程而不只是聊天
MoE 与超节点	896 个医生只叫 16 个会诊；医生全得住院，逼出“一张大桌子”，国产芯片以多补弱
算力通缩	不是产能过剩，是效率恐慌叙事——省下来的算力立刻被更大的野心吃掉
开源商业模式	开的是菜谱不是饭：1.5TB 的厨房个人装不起；许可证即授权；白送菜谱赚标准和流量
厨房运营学	池化不空灶、PD 分离各司其职、缓存池不重复备菜——Infra 功夫全变成毛利
利润再分配	菜谱一开源，利润从卖配方的手里流进厨房开得最好的人口袋
K3 四短板	

主题	一句话记忆卡
	爱思考所以烧钱、块头大所以难部署、快照不能共享所以缓存只留 10 分钟、独白只有自己懂所以接不了力
极致性能的代价	红利进 Kimi 的成本表，账单寄到用户的发票上——永远算任务总价，不算 token 单价
模型竞争	模型打架两边看戏的都赢：应用买到便宜 token，CSP 接住利润，铲子商收军费
两个池子	ARR 690 亿美元里中国约等于零；三道锁把中国企业焊死在国产池子里，水位涨受益国产云与芯片
算力租赁股	真龙头看三样：英伟达授权、报表里的设备、落地的租金收入——公告签约金额最不值钱
半导体下跌	K3 恐慌是 DeepSeek 时刻重演大概率错杀；Meta 外卖富余算力才是真消息
Kimi 发展史	K3 是十年长文本主线的第六级台阶——爆发只是积累换了个舞台亮相
KDA 与字节	赛马选得出最快的马，选不出第一辆汽车——激进赌注需要“研究独裁者”
中美竞争	四年从代差到一个身位，靠人才存量、工程生态、隔离市场、稀缺创新四张牌
微笑曲线	利润长在壁垒上，位置不是宿命——台积电把嘴角踩在自己脚下
华人人才	美国实验室 38% 的华人是兵团不是统帅；中国的底气在 47% 的产量
RL 后训练	预训练养书呆子，SFT 教模仿，RL 扔进模拟工厂试错——练功房和私有考卷是新护城河
先发优势	后训练领先会从四个口子漏气，先发者赚的是永远六个月的时间差租金

免责声明：本笔记为个人学习整理，信息时点为 2026 年 7 月 19 日；文中涉及的公司、股票、行业数据部分来自媒体报道与第三方估算（SemiAnalysis、CNBC、Fortune、证券时报、MacroPolo 等），未经独立审计；专家会纪要类信息可信度有限，均不构成投资建议。