

模型厂调研与存储层级学习笔记

从预训练到冷热调配：一篇谷歌模型调研纪要的完整拆解

整理日期：2026 年 7 月 5 日 · 基于公众号“北向牧风” 2026-07-05 文章《模型厂关于近期热点的碎碎念》及对话中联网核实的公开信息

阅读提示：本笔记按“基础概念 → 存储结构 → 调配机制 → 投资映射 → 全文解读 → 全景总结”的知识逻辑组织，不按聊天顺序。每章开头保留当时的提问，末尾附一句话记忆卡。全文用一个“大厨与厨房”的类比体系贯穿。原文是匿名内部调研纪要，所有数字无法独立核实，仅作参考，不构成投资建议。

目录

第一章 概念工具箱：预训练与后训练——培养一位大厨

第二章 存储金字塔：HBM、DRAM、SSD 与 Blob Storage 管家

第三章 冷热数据自动调配：管家的巡逻路线

第四章 1:10 配比、“吃满算力”与 DRAM 的投资映射

第五章 全文解读：一切都被算力（和电）卡着脖子

第六章 全景总结与知识地图

附录 一句话记忆卡合集

第一章 概念工具箱：预训练与后训练——培养一位大厨


你当时的问题：能帮我费曼小白一下，什么叫后训练，什么叫预训练吗？文章里说“后训练效果很大程度依赖预训练的底子”，他有没有提到这一点？

一句话定义：预训练是让模型“读万卷书”学会语言和知识，后训练是教这个博学的“书呆子”怎么当一个好用的助手。

用培养一位大厨来打比方。预训练（Pre-training）相当于从小背菜谱、吃遍天下：把几乎整个互联网的文字喂给模型，它只做一件事——看着前面的字，猜下一个字是什么。听起来笨，但为了猜得准，它被迫学会了语法、事实知识、甚至推理的雏形，就像一个孩子为了背下全世界的菜谱，顺带搞懂了火候和食材搭配的底层逻辑。这一步烧掉训练成本的大头（数月时间、上万块 GPU），产出的是一个“毛坯模型”：满腹经纶，但你问它问题，它只会续写，不会好好回答。

后训练（Post-training）相当于进餐厅当学徒。毛坯模型再经过两类调教：一是 SFT（监督微调），给它看大量“人类示范的好答案”，学会问答的格式和礼貌；二是 RLHF／强化学习，让它反复试做，人类或规则打分，做得好有奖励，做得差被纠正——学徒就这样学会了听懂客人点菜、按规矩

摆盘。后训练成本比预训练低得多，但迭代最频繁，各家模型的“性格差异”主要来自这里。



关于“后训练依赖预训练底子”：原文确实一字不差地提到了。在“Anthropic 的领先会不会形成打不破的正循环”那个问答里，专家答：“后训练效果很大程度依赖预训练的底子——对追赶者来说，最初架构一旦没选好，后训练追赶的速度和效率都会受很大影响。”上下文更进一步：这种领先会一直持续，直到竞争者重新做模型选型、拿到同类预训练数据——想追上大概率要用不同架构重新预训练，没法在现有底子上缝缝补补。用类比说：学徒阶段教不会的东西，得回炉重背菜谱，而重背菜谱是几个月、几十亿美元级的事。

记忆卡：预训练决定模型“知道多少”（天花板），后训练决定它“会不会好好说”（把本事释放出来）——底子不够，调教难补。

第二章 存储金字塔：HBM、DRAM、SSD 与 Blob Storage 管家

你当时的问题：Blob Storage 到底是个什么东西？为什么通过它的层级划分就能实现降本和透明化？DRAM、SSD 和 HBM 我一直没分清，它们三者到底有什么不同？我理解 HBM 是最“热”的高带宽存储、DRAM 介于 SSD 和 HBM 之间，对吗？


一句话总纲：整个数据中心的存储就是一个大厨房——芯片是大厨，数据是食材，放得离灶台越近越快也越贵；Blob Storage 是那位管家，决定每样食材放哪一层。

Blob 是 Binary Large Object（一大坨二进制数据）的缩写，Blob Storage 即“对象存储”，可以想成酒店的寄存处：你把行李（数据）交出去，拿到一张凭证（key），要用时凭证取回。行李究竟放在前台柜子还是地下仓库，你既不知道也不用关心——这就是“对开发者透明”。省钱的原理在于数据访问天然极度偏斜：绝大部分数据大部分时间没人碰（冷），只有一小撮被反复读写（热）。管家把热的放贵而快的层（DRAM/SSD），冷的搬去便宜的 HDD 甚至磁带。开发者一行代码不用改，账单却降下来了。所以“要不要多用 HDD 降本”是个伪问题：HDD 早就在用，管家自动会把冷数据放过去，真正缺的不是便宜的仓库，是灶台边的操作台（DRAM）。

三种存储介质的区别：

	HBM「灶台调料架」	DRAM「操作台」	SSD「储藏间」
本质	就是 DRAM 芯片，堆叠后直接封装在 GPU/TPU 旁边	独立内存条，插在主板上	NAND 闪存
速度	带宽极致（TB/s 级）	快（纳秒级延迟）	慢一两个数量级（微秒级）
断电后	数据消失	数据消失	数据还在
容量/价格	最小、最贵	中等	大、便宜

你的理解是对的：HBM 最热最快，DRAM 介于 HBM 和 SSD 之间。最值得记住的一点：HBM 不是一种和 DRAM 并列的新东西，它就是 DRAM，只是“焊在大厨手边”的豪华封装版。同样的晶圆，做成 HBM 还是普通内存条，是厂商的产能分配选择——这正是后面投资逻辑的钥匙。



记忆卡：HBM 就是焊在芯片边上的 DRAM；大厨不缺仓库缺操作台——数据放哪一层，是速度与价格的换算题。

第三章 冷热数据自动调配：管家的巡逻路线

你当时的问题：如果 HBM、DRAM 继续涨，存储系统会自动调整冷热数据策略来控成本吗？它具体的机制原理是什么？帮我这个小白科普一下。

一句话定义：所谓“自动调整冷热数据”，就是管家手里有一本实时更新的点单记录，谁被点得勤就往灶台边搬，谁积灰了就往地窖搬——而“搬家的门槛”会跟着各层的价格自动浮动。机制分四步循环。


第一步，记录温度。系统里每份数据（每个 Blob）都挂着一小条元数据：最后一次被读是什么时候、过去一小时/一天/一周被读了几次。这是“体温计”，成本极低，因为只是记账，不碰数据本身。

第二步，打热度分。核心公式思想：热度 $\approx$ 访问频率 $\times$ 新近度。刚被读过加分，久不被读按时间指数衰减——今天被点 50 次是爆款，三个月没人点自动沦为“下架候选”。有些系统还加预测：新数据默认先当热数据供着，因为经验规律是“新的头几天最热，之后冷得很有规律”。

第三步，对照门槛——控成本的核心。每一层（DRAM/SSD/HDD）都有一条准入线：热度分过线才配住这层。关键在于这条线不是死的，它的输入包括每个数据中心当下各层的容量余量和单位成本。DRAM 涨价或紧张了，系统等于收到“涨租通知”，自动把 DRAM 层的准入线抬高——原来热度 60 分就能住内存，现在得 80 分。最贵的地皮只留给最烫

的数据，控成本不需要任何人开会拍板，价格信号直接变成了调度参数。

第四步，后台搬运。升降级由后台进程在访问低峰期批量执行，搬完只改索引里“存放位置”那一栏——凭证（key）从头到尾没变，所以开发者完全无感，这就把“透明”闭环了。为防数据在两层间被反复搬来搬去，升舱要明显过线、降舱要明显掉线才动手。



DRAM 涨价 → 第3步门槛自动抬高 → 热层只留最烫的数据，成本自动收紧

为什么这套东西源自 YouTube？因为视频访问是最典型的“幂律分布”：约 1% 的视频吃掉绝大多数播放量，海量长尾视频几乎无人问津但又不能删。YouTube 早年被迫建了这套分层系统，还摸透了热度衰减规律。AI 时代的数据访问偏斜得一模一样——正在训练的数据集滚烫、上周的 checkpoint 温、三个月前的原始语料冰凉——Google 直接让这位管了十几年视频仓库的老管家转岗管 AI 数据。

一个重要边界，别高估它：这套机制省的是“放错地方的浪费”，省不掉真实的热数据需求。推理时的 KV Cache、正

在训练的批次，再怎么调度也必须待在 DRAM/HBM 里。巧劲降本和 DRAM 稀缺可以同时成立。

记忆卡：冷热调配 = 点单记录打分 + 随价格浮动的准入门槛 + 后台无感搬家；它优化“数据住哪”，省不掉“必须住豪宅的那批数据”。

第四章 1:10 配比、“吃满算力”与 DRAM 的投资映射

你当时的问题：TPU v7 的 HBM 与 DRAM 理想配比 1:10 就能把算力“吃满”——可上个窗口聊过 GPU 推理效率不到 10%，这 10 倍空间很难只靠加 HBM 解决，为什么这里说配好 1:10 就能吃满？“吃满”是指 GPU 没有任何闲置吗？DRAM 的生产厂商是铠侠还是闪迪？投资机会在哪里？

“吃满算力”的意思是让 GPU/TPU 的计算单元尽量不空转。大厨炒菜手速极快，瓶颈从来不是刀工，而是食材递得不够快：推理时长上下文的 KV Cache（这桌客人点过的所有菜的备料）体积巨大，HBM 这个调料架根本放不下。只有两个选择：要么买更多带 HBM 的芯片纯粹当容量用（为了多个调料架再雇一个大厨，奢侈），要么在旁边配一张巨大的操作台（DRAM），把暂时不炒的备料放那里随取随用。1:10 就是一份 HBM 配十份 DRAM 当二级缓冲，让大厨基本不用停手等料。

这和“GPU 推理效率不到 10%”不矛盾，是同一件事的两面：利用率低的最大元凶之一就是“内存墙”——算得快、

喂不上。加 DRAM 解决的是容量这一半，带宽、调度、通信等瓶颈依然存在。1:10 是谷歌基准测试里的理想值（厂商叙事，带宣传成分），不等于现实一配就满血。而现实配比只有 1:1 到 1:2，缺口巨大——所以结论“利好 DRAM”成立。

纠错一处：铠侠和闪迪不生产 DRAM，它们做的是 NAND 闪存（SSD 里的“储藏间”）。DRAM 全球基本被三家垄断：三星（2026Q1 份额约 38%）、SK 海力士（约 29%）、美光（约 22%），外加追赶中的合肥长鑫。HBM 也出自这三家（SK 海力士目前领先）。“DRAM 稀缺”的直接受益者是三巨头，不是铠侠/闪迪——后两者要涨也是搭 SSD 需求外溢的顺风车，逻辑隔了一层。

投资映射按“事实 / 叙事 / 风险”三层拆开（信息时点：2026-07-05，来源：虎嗅、新浪财经、SMM 等公开报道）：

事实层面：本轮存储超级周期已非常凶猛——DRAM 价格四年累计涨约 7 倍，2026 年 Q1、Q2 环比各涨约 90% 和 60%；HBM 与普通 DRAM 共用晶圆产能，且 HBM 每单位容量约吃 3 倍晶圆面积，产能挤占导致普通内存暴涨；AI 服务器已吃掉全球 DRAM 产能的一半（两年前约 35%）。这也解释了“存储占服务器价值从个位数百分比冲到 30% 以上”——主要不是用量变了，而是价格飞了。

叙事层面：文章说的“1:10 配比、加 DRAM 空间巨大”，是看多 DRAM 的核心故事；“除非内存价格高过 TPU 和 HBM，否则公司宁可投内存，也不投 TPU”。

风险层面：存储是强周期行业，Jefferies 预计涨势延续到 2027 年、2028 年才明显放缓——但三巨头已因涉嫌联手控

产抬价在美国吃了集体诉讼，且历史上每轮内存周期的顶都比预测来得突然；此刻价格已在高位，追高的赔率和两年前完全不同。这些叙事已在市场流传，价格里含了不少预期。本笔记仅作学习整理，不构成投资建议。

记忆卡：大厨不缺仓库缺操作台——DRAM 是这轮 AI 存储行情的主角，而做操作台的只有三星、海力士、美光三家（铠侠/闪迪做的是储藏间）。

第五章 全文解读：一切都被算力（和电）卡着脖子

你当时的问题：这篇文章比较棒啊！你来解读一下吧。

《模型厂关于近期热点的碎碎念》（北向牧风，2026-07-05）自称一篇谷歌内部的大模型调研纪要。全文可以拧成一条主线：现在这个行业里，一切都被算力（以及给算力供电的电力）卡着脖子。需求、收入、模型竞争、存储，全是这条主线的分支。

需求与收入侧：企业在省 token，但总需求没降——单价往下、总量往上。Anthropic 的 ARR 三月 190 亿、四月 300 亿、五月 450 亿（美元年化），但这个斜率之后看不到了，原因不是需求没了，而是算力供给跟不上——“卡的用量趋势约等于收入趋势”是全文最值得记住的等式。Anthropic 一家吃掉 GCP 一半以上的算力需求、TPU 总量的 30% 以上（约 200 万~250 万片），V6 基本全供它，V7 除 DeepMind

训练任务外也优先供它，连 Google 自家 Gemini 项目都排不上队。

供给侧（最硬核）：瓶颈已经不是造卡，而是电——新买的 TPU 和 GB300 面临“卡到了、插不上电”，原规划 12GW 可能只落地 6GW。所以 2026-2027 年行业核心动作是在现有机房里拆旧卡换新卡而不是盖新机房；TPU 租赁价格未来两个月预计大涨（远超 20-30%）。真正的产能释放点在 2028 年——Google 与台积电合资的 TPU 工厂投产，出货量从 2026 年约 340 万片跳到 2027 年约 700 万片。成本牌：TPU v7 单机架 BOM 约 150 万美元，英伟达 GB200 NVL72 约 324 万；据称 V8i 单卡性能测试超过 GB300——“TPU 便宜的底气在这里”。

模型竞争与架构：GPT-5.6 相比 5.5 只有微小提升。专家诊断：OpenAI 不缺数据（Codex 用户量够大），缺的是架构选型——它的 MoE 是“小专家太多”，单个专家维度太小，吃不下反馈循环数据里的信息。

MoE（Mixture of Experts）就是把模型的每一层拆成一队厨师，来一个 token，调度员（Router）只叫醒其中几个干活，省算力。早期业界缺高质量长任务数据，主流思路是靠 LongCOT “先想清楚再干”——任务前生成十万字的思考，把各种可能性想一遍，这需要多样性，一大群各有偏科的小厨师正合适。但等到用户真实使用产生的高质量、长程反馈数据多起来（比如一次改几小时代码的完整记录），小厨师脑容量不够、记不全，只有少数几位全能大厨（大专家）装得下。文章说 Anthropic 在 2025 年就押注了大专家；竞争者一缺同类数据、二没法轻易改已定型的架构——绕回第一

章那句话：架构是预训练时定死的地基，地基不对，后训练装修装不出摩天楼。



存储部分（第二至四章已详拆）文章还补了个彩蛋：冷热温自动调配机制源自早年 YouTube 管理热门/冷门视频的分层系统——Google 把管了十几年视频的管家直接派来管 AI 数据。

可信度提醒三点：第一，这是匿名“内部调研纪要”，公众号自己声明不对观点背书，文中所有数字（ARR、芯片数、BOM、1:10 配比）都无法独立核实，当“高质量的行业耳语”看，别当财报看。第二，文中大量吹捧 Anthropic 与 Fable 5，这些是受访专家的说法，不是官方口径，应多打个问号。第三，往投资上引（TPU 链、DRAM、电力设备）时，记得这些叙事已在市场流传。

记忆卡：这篇文章一句话——算力荒决定收入（卡的用量约等于收入），电力荒决定算力（有卡插不上电），而架构选型在预训练那天就决定了谁能吃下反馈数据、坐稳牌桌。

第六章 全景总结与知识地图

把全部话题放回一张逻辑地图：最上游是电力（当前最硬的物理约束），电力之下是算力（TPU/GPU + HBM），算力旁边是存储金字塔（HBM→DRAM→SSD→HDD，Blob Storage 管家自动调配冷热），算力之上是模型（预训练打底子、定架构；后训练教做事，效果受制于底子），模型之上是收入（卡的用量约等于收入趋势）。四个环环相扣的稀缺：电 → 卡 → DRAM → 好底子的模型。

投资视角下，每层稀缺对应一批受益者：电力设备与电源链（电荒）、TPU/先进封装链与台积电（卡荒）、三星/海力士/美光（DRAM 荒）、押对架构的模型厂（底子荒）。同时每层也对应一个风险：电力落地不及预期、算力租金周期反转、存储周期见顶、架构范式再次迁移。

记忆卡：一条产业链四层稀缺——电、卡、内存、底子；谁卡脖子谁涨价，谁涨价谁的供应商受益。

附录 一句话记忆卡合集

主题	一句话
预训练 vs 后训练	预训练决定“知道多少”（天花板），后训练决定“会不会好好说”；底子不够，调教难补
存储金字塔	HBM 就是焊在芯片边上的 DRAM；大厨不缺仓库缺操作台
冷热调配	点单记录打分 + 随价格浮动的门槛 + 无感搬家；优化“住哪”，省不掉“必须住豪宅的数据”
DRAM 投资	操作台只有三星、海力士、美光在做；铠侠/闪迪做的是储藏间（NAND）
文章主线	算力荒决定收入，电力荒决定算力，架构选型在预训练那天定生死
全景地图	四层稀缺：电 → 卡 → 内存 → 底子

免责声明：本笔记为个人学习整理，基于 2026-07-05 时点的公开信息与匿名调研纪要（未经独立核实），仅作知识科普，不构成任何投资建议。DRAM 市场数据来源：虎嗅、新浪财经、SMM、seccw 等公开报道。