

英伟达换账本 · 后训练为何突然可以花钱

从一篇英伟达博客出发，拆解“每美元智能”、后训练拐点与第三次算力范式

整理日期：2026 年 7 月 20 日 · 文中数据均标注时点，市场类信息以整理日为准

阅读提示：本笔记源自一次围绕华尔街见闻《英伟达：从“一次性训练”的大模型到“后训练改进”的 Agent》的连续追问。内容不按提问顺序排列，而是按“概念工具箱 → 机制 → 产业结构 → 商业模式 → 原文评估 → 全景推演”重新组织。涉及公司与产业判断的部分仅供学习理解，**不构成任何投资建议**。

目录

- 第一章 概念工具箱：token 的两个身份
- 第二章 两把尺子：每 token 成本与每美元智能
- 第三章 后训练到底变了什么：从 RLHF 到 RLVR
- 第四章 英伟达为什么偏偏挑后训练来讲
- 第五章 谁为失败买单：结果付费与风险转移
- 第六章 回到原文：这篇博客的可信度评估
- 第七章 全景：瓶颈迁移与第三次范式推演

第一章 概念工具箱：token 的两个身份

你当时的问题：后训练消耗的 token，是因为它也要消耗算力，输入也是一种消耗对吧？那现在对外销售的到底是什么 token，是推理的 token 吗？

这一章是全篇的地基。后面所有关于成本、指标、商业模式的讨论，都建立在“token 到底指什么”这件事上。

token 同时有两个身份：一个是**技术单位**（一段文本被切开后最小片段），一个是**计费单位**（账单上的那一行）。后训练和推理烧掉的 token，技术性质完全一样，区别只在于——**有没有人为它开账单**。

对外销售的 token：推理 token

	是什么	为什么是这个价
输入 token	提问 + 历史对话 + 系统提示 + 工具定义 + 检索到的文档	便宜。可以一次性并行灌进模型（prefill，预填充）
输出 token	模型吐出来的字， 包括思考过程	贵。必须逐字往外蹦（decode，解码），每吐一个字都要把整个模型权重重新过一遍，卡在内存带宽上

所以“输入也是一种消耗”这个理解是对的，**但它是便宜的那一种消耗**。以整理日的公开价格看，Claude Opus 4.8 输入 5 美元/百万 token、输出 25 美元/百万 token，这五倍价差就来自上面这个物理差别。

一个容易被忽略的点：Agent 内部那些“反复思考、调用工具、读取返回结果、再思考”的过程，**全都是计费的推理 token**，一分不少。它们只是不被终端用户看见，账单落在应用厂商头上。所以严格说，Agent 烧的 token 不是“没账单”，而是**账单换了个人付**。

不对外销售的 token：后训练消耗

用途	干什么	谁掏钱
RL rollout	模型自己生成几百万次尝试，供打分学习	模型厂自己
合成数据生成	用大模型造训练数据喂给小模型	模型厂自己
评测跑分	跑 SWE-bench 之类的基准测试	模型厂自己

这些 token 生成出来就被拿去打分，然后丢弃，没有任何外部客户看到它们。

一个必须补上的缺口

“后训练消耗 token”这个说法只描述了它的一半。后训练的算力实际是两块：

- **前向传播**：生成 rollout——这部分产生 token，性质与推理相同
- **反向传播**：算梯度、更新权重——这部分**根本不产生 token**，但计算量通常是前向的 2 到 3 倍

这个缺口非常关键，它是第二章那个新指标出现的技术性理由：后训练里有一半的算力，压根不产生任何可计价的 token，用“每 token 成本”这把尺子永远量不到。

记忆卡：token 的技术性质只有一种，账单性质有两种——推理 token 有客户付钱，后训练 rollout 由模型厂自掏腰包。而后训练里还有一半算力（反向传播）连 token 都不产生。

第二章 两把尺子：每 token 成本与每美元智能

你当时的问题：英伟达提到“每 token 成本”和“每美元智能”这两个概念，挺让人混淆的。每 token 成本感觉讲的是效率，就像 token 工厂生产一个 token 花多少钱；每美元智能是不是就是我懒得算 token 了，直接算一美元能干成多少事？这两者的本质区别到底是什么？

先看三代广告语

英伟达的销售叙事换过三次，但结论从来没变过。

时代	口号	分母（衡量什么）	潜台词
训练时代	买得越多，省得越多	模型规模	算力稀缺，规模摊薄成本
推理时代	买得越多，赚得越多	token 产量	多产 token 等于多收钱
Agent 时代	每美元智能	模型能力	能力越强，钱花得越值

三句话的宾语一直是“多买 GPU”，变的只是分母。

为什么“买得越多、赚得越多”在 Agent 时代失效了

这是理解整件事的枢纽。

Chatbot 时代：用户问一句、模型答一句，token 是**卖给用户**的商品。产量越大，收入越高，“多产多赚”成立。

Agent 时代：用户买的不是 token，是**任务结果**。而 Agent 为完成一个任务会在内部疯狂烧 token——反复思考、调工具、失败重试、读取长上下文。这些 token 用户看不见、也不直接为之付费。

于是 token 的性质发生了根本翻转：**从收入项变成了成本项**。

一旦如此，“每 token 成本”的味道就变了。它原本是个赚钱指标（成本低 → 卖得多 → 赚得多），现在变成了纯粹的**省钱指标**。而省钱故事有天花板——它顶多等于客户的成本预算。英伟达不能只讲省钱故事，所以必须再叠一个增长故事，这就是“每美元智能”的由来。

两把尺子的本质区别


用一个贯穿全篇的类比：**家里水管漏了，要雇师傅来修。**

- **每 token 成本 = 师傅的时薪。** 它衡量“雇人这件事本身贵不贵”。
- **每美元智能 = 这笔钱花完，水管到底通没通。** 它衡量“钱有没有办成事”。

便宜师傅 100 块一天，来了 20 天没修好，你花了 2000 块，水还在漏。贵师傅 1000 块一天，两天修好，你也花了 2000 块，水不漏了。**时薪上便宜师傅赢十倍，结果上他输得干干净净。**

同一个任务：修好一个真实的软件 bug

两个模型，最后都花掉 0.20 美元



每 token 成本：A 赢 10 倍 — 它衡量的是「造 token 便不便宜」
每美元智能：B 完胜 — 它衡量的是「这笔钱办没办成事」

还有半层：两个指标的“钱”，覆盖范围不一样

这是最容易漏掉、也最关键的一点：

- **每 token 成本**的分母，只包含**推理时烧的电和卡**，是 token 工厂的车间成本。
- **每美元智能**的分母，包含**造模型 + 持续维护模型 + 部署服务**的全部投入，是整个模型生命周期的 TCO (Total Cost of Ownership，总拥有成本)。

想明白这一点就看穿了英伟达的用意：**后训练的算力开支，塞不进“每 token 成本”这个框里**——因为后训练消耗的 token 不对外销售，在那本账上纯粹是负担。所以英伟达造了一个**更大的框**。


换指标，本质上是换账本。旧账本上后训练是费用，新账本上后训练是投资。

两者嵌套成的闭环

英伟达说这两个指标“相互嵌套”，技术上没错：

- 每 token 成本下降 → RL 的 rollout 更便宜 → 造智能更便宜 → 每美元智能上升
- 每美元智能上升 → 模型更强 → 每个 token 能卖更贵 → 单位 token 价值上升

英伟达最聪明的一步：让两个指标互为因果



这个闭环在逻辑上没错，但它是自封闭的：无论客户关心成本还是关心能力，箭头最终都指向同一个收银台。这正是需要保持警惕的地方。

但要看清楚：这是一个**自封闭的闭环**。客户若关心成本，箭头指向买卡；客户若关心能力，箭头还是指向买卡。逻辑上无懈可击，而恰恰因为无懈可击才要留个心眼——一个怎么推导都指向同一个收银台的框架，通常是为收银台设计的。

它是不是就是“每美元有效 token”

这个压缩基本成立，损失很小。可以给出一个近乎精确的公式：

每个有效 token 的成本 = 名义 token 单价 ÷ 任务成功率

注意这里的数学结构：**成功率是除数，不是减数**。成功率从 100% 掉到 10%，真实成本直接乘以 10——它对成本的影响是**乘法级**的，而制程、架构带来的效率提升只是**百分比级**的。所以在 Agent 场景里，成功率这一项能压倒其他所有优化。

那“每美元智能”有多少是包装？一个量化判断：**约八成是包装，两成是真视角**。

说它是包装的证据很硬：一是这个概念行业里早就有，只是叫法不同（pass@1、任务成功率、token efficiency）；二是**英伟达没给出任何计算方法**——“每 token 成本”有公式（美元 ÷ 百万 token），人人能算，而“智能”怎么量化，文章只字未提。全文唯一的实证是 SWE-bench 的 71.7%，而那本身就是一个任务成功率指标。

能算的叫指标，不能算的叫口号。

说它有两成真东西，是因为它把“造模型的钱”和“用模型的钱”合进了同一本账。这个 TCO 视角在财务上确实成立，也正是它让后训练开支变得合法。

一个需要修正的直觉

把 Opus 与 Sonnet 的差异理解成“前沿模型 vs 垃圾模型的竞争”并不准确。真正决定用谁的，不是模型好坏，而是**这一次失败要赔多少钱**：

- 写营销文案失败 → 重来一次，成本约等于零 → 便宜模型永远赢
- 改生产环境代码失败 → 一个工程师半天，外加可能的线上事故 → 前沿模型再贵都值

有效 token 的经济价值，不由 token 价格决定，由失败的代价决定。所以模型的分层定价不是质量分级，而是按客户的**失败承受能力**做的价格歧视。

顺带一个事实订正：不存在“Claude 3.5 Opus”这个型号。历史上是 Claude 3 Opus（15/75 美元每百万 token）与 Claude 3.5 Sonnet（3/15），差 5 倍。而截至整理日，Opus 4.8 是 5/25、Sonnet 5 标准价 3/15（促销 2/10），**差距已收窄到不足 2 倍**——前沿模型的溢价正在被快速压缩。

记忆卡：每 token 成本问“这个零件造得便不便宜”，每美元智能问“这笔钱最后有没有办成事”。前者的账本只装得下车间，后者装得下整条产业链——包括英伟达最想让你付钱的那部分。

第三章 后训练到底变了什么：从 RLHF 到 RLVR

你当时的问题：后训练一直都有，对不对？那你突然说它会爆发式消耗算力、甚至模型强不强完全取决于它，我觉得很突兀。它本质上发生的变化是什么？催化因素是什么？拐点又是什么？这些并没有被说清楚。

这是整场讨论里最关键的一问，而英伟达那篇博客只描述了现象，没有指认原因。这一章补上机制。

先看数字：拐点是真实存在的

时点	模型	RL 算力占预训练的比例
2025 年初	DeepSeek-R1	约 3.75%–5%
2025 年	o1 → o3	RL 算力增加 10 倍以上 （Grok-3 → Grok-4 同量级）
2026 年	Cursor Composer 1.5	RL 后训练算力超过了预训练

（来源：arXiv 《The Art of Scaling Reinforcement Learning Compute for LLMs》等公开研究）

从 4% 到反超 100%，用了约一年半。**这不是渐变，是相变。**

名字没变，工作内容换了

“后训练一直都有”这句话之所以让人困惑，是因为它掩盖了一个事实：**2022 年的后训练和 2026 年的后训练是两件不同的事，只是共用了一个名字。**

	RLHF 时代（2022–2024）	RLVR 时代（2024 秋至今）
目的		

	RLHF 时代 (2022–2024)	RLVR 时代 (2024 秋至今)
	对齐 ：让模型有礼貌、听指令、不说坏话	造能力 ：让模型会推理、会用工具、能完成任务
奖励从哪来	人类标注员投票	程序自动判定 （跑测试、对答案）
瓶颈是什么	人 （标注又慢又贵）	算力 （有多少卡就跑多少轮）
算力占比	约 1%	可超过预训练

- **RLHF** = Reinforcement Learning from Human Feedback（基于人类反馈的强化学习）
- **RLVR** = Reinforcement Learning with Verifiable Rewards（可验证奖励的强化学习），该术语 2024 年秋才被正式提出

拐点只有一句话

奖励信号从“人给”变成了“程序给”。


RLHF 时代，每一次学习都要一个人来评判 A 好还是 B 好。**人是线性成本，而且供给有上限**——雇再多标注员也标不出几百万次迭代。所以那个时代**算力根本不是瓶颈，人才是**：你就算有一万张卡也没用，因为没人给你打分。

RLVR 把裁判换成程序：数学题对答案、代码跑单元测试、Agent 任务看沙箱有没有执行成功。**裁判成本从“每次都花钱”变成“写好一次，无限使用”**。


人这道闸门一拆，算力立刻从“闲着没用”变成“多少都不够”。

同一个循环，闸门换了位置

RLHF 时代：裁判是人



RLVR 时代：裁判是程序



不是后训练突然重要了，是拆掉人这道闸门之后，钱终于花得进去了。

这就是那种突兀感的真正来源：不是后训练突然重要了，是后训练突然可以花钱了。

第二个催化：环境本身变贵了

这是 2026 年区别于 2025 年的地方。早期 RLVR 做的是数学题，**环境就是一个字符串**，判题几乎不花钱。现在做的是 Agent 任务，**环境是一个真在运行的容器**：有文件系统、有代码仓库、要装依赖、要跑浏览器、要调网络接口，一次 rollout 可能耗时几分钟真实时间。

回头看原文那句“Vera CPU 在真实 RL 沙箱负载下吞吐高 30%”——**这句话到这里才有意义**。它说明 RL 已经从“生成 token 然后打分”变成了“同时开着几千台真电脑”，这是一个连 CPU 都成为瓶颈的新负载形态。

第三个催化：隔壁不好使了

互联网上的高质量文本基本被吃完，预训练仍在推进，但**每一块钱买到的能力提升在下降**。边际资本自然流向回报更高

的地方。RL 之所以爆发，一部分原因不是它变好了，而是隔壁变差了。

但“完全取决于后训练”是过头话

预训练决定天花板，后训练决定你能摸到天花板的百分之几。

像一个人：**上学**（预训练）决定知识面和脑子，**实习练手**（后训练）决定他会不会干活。没上过学的人怎么实习也成不了工程师；但博士不练手，照样修不好水管。Cursor 的 Composer 1.5 恰是例证——它 RL 算力超过预训练，但那个预训练底座不是它自己造的。

最诚实的一条边界

RL scaling 的天花板，等于“**能被便宜验证的任务**”的总量。数学、代码、可执行的 Agent 任务，验证器便宜，RL 就能疯狂 scale；而战略判断、审美、开放式研究没有裁判，RL 就烧不动。

这给出一个**可证伪的预测**：如果机制正确，模型能力会长成“**尖刺状**”——代码、数学猛涨，开放判断涨得慢。而这正是过去一年多被广泛观察到的现象。**机制预测与现实吻合**，这是它比英伟达那套说辞更可信的原因。


记忆卡：后训练不是突然重要了，是突然可以花钱了。RLHF 时代瓶颈是人类标注员，有卡也用不上；RLVR 把裁判换成程序，闸门一拆，算力从闲置变成不够用。拐点只有一句话——奖励信号从人给变成程序给。

第四章 英伟达为什么偏偏挑后训练来讲

你当时的问题：从训练时代到推理时代，是 token 需求十倍二十倍增长的范式变革。后训练我觉得并不属于这种性质的变革吧？

这个判断是对的。训练到推理那次是真变革，因为分母从“几百家实验室”变成了“几十亿终端用户”，需求主体的数量级换了。后训练没有这种性质，它的主体还是那几百家。

那英伟达为什么非讲它不可？答案是：它挑的不是最大的那块，是护城河最深的那块。



为什么 RL 后训练是英伟达最难被攻破的地方

	推理负载	RL 后训练负载
计算图	规整、静态、可预测	动态、异构、随时变

	推理负载	RL 后训练负载
训练与推理	只有推理	两者必须同时跑
通信	节点内为主	训练节点与推理节点高频同步
通用计算	几乎不需要	沙箱要跑真实代码、真实工具
能否被 ASIC 替代	能	很难

专用推理芯片能打赢通用 GPU，靠的正是“负载规整、可以把电路刻死”。而 RL 循环在每一个维度上都反着来——它需要 CUDA 生态的通用性、高速互联，还要 CPU 去跑沙箱里的真实环境。

回头看原文那两个客户细节，会发现它们根本不是随手举例：

- Perplexity 的“**两秒内**完成万亿参数权重同步”——在证明**互联**的价值，ASIC 做不到
- Prime Intellect 的“Vera CPU 在真实 RL 沙箱负载下吞吐高 30%”——在证明**通用计算**的价值，ASIC 更做不到

这两个数据点被放进博客，是因为它们恰好落在专用芯片打不到的位置上。而原文末尾那条相邻新闻（Anthropic 被曝测试 AMD GPU）不是巧合——**推理这块正在被撬动，英伟达需要一个新战场。**

还有一层纯财务动机

即使后训练的绝对算力不如推理，它的**收入性质**不同：

- 预训练：脉冲式采购，客户就那么几家，波动巨大
- 推理：跟随终端需求，被动，且可被替代

- 后训练：常态化、持续、绑死 CUDA

对一家巨型公司而言，收入的可预测性和收入的绝对量同样值钱。把一块业务从“项目制”讲成“订阅制”，享受的估值倍数是不一样的。

记忆卡：英伟达讲后训练，不是因为它是最大的蛋糕，而是因为它是别人最打不进来的那块。推理池子最大但正在被 ASIC 蚕食，后训练池子最小但需要互联、通用计算、CUDA 生态三件套齐活。

第五章 谁为失败买单：结果付费与风险转移

你当时的问题：为“任务完成”付费真的能做到吗？任务其实很难量化。现在确实会出现模型卡在那里跑了一个小时最后也没解决问题、token 却浪费了很多的情况，对吧？

先做一个订正：“用户买的不是 token，是任务完成”这个说法在整理日只对了一小部分。结果付费确实已经落地，但只落在一个很窄的角落里。

它已经在跑了

Intercom 的 Fin 是活例子：每解决一次收 0.99 美元，49 美元/月基础套餐含 50 次。Sierra 走企业定制，不公开报价。

而最关键的一条条款正面回答了那个疑问：“没发生的结果不收费”——客户明确要求转人工，或流程执行失败，均不

计费。所以“跑了一小时没解决、token 全浪费”这个场景，在结果付费模式下答案很明确：**这一小时的成本，厂商自己吞。**

门槛不是“能不能量化”，是“验收贵不贵”

结果付费不需要量化“完成得多好”，它只需要一个双方都能便宜观察到的二值信号。

Fin 的做法很聪明：它**根本不判断答得好不好**，只看“客户有没有要求转人工”。一个主观的质量问题，被替换成一个客观的行为信号，判定成本几乎为零。

任务类型	验收信号	验收成本	结果付费
客服工单	客户没转人工	几乎为零	已落地
流程 / 数据录入	字段对不对	低	已落地
代码修复	单元测试跑没跑过	低（前提是有测试）	部分可行
销售线索	有没有成交	中，且归因扯皮	零星
写文案 / 战略分析	没有客观标准	极高	基本不可能

这里要串一下第二章：SWE-bench 那个 71.7% 之所以能被英伟达拿来当“智能”的证据，正因为它**自带验收器**——项目自己的单元测试判定成败。这和 Fin 是同一个逻辑：**有廉价裁判的地方，结果才能被定价。**

所以“先按 token 付费、后按任务付费”这个两阶段模型需要修正：**不是时间上的先后两段，而是按验收成本切开的两个市场，会长期并存。**

风险转移已经发生了

结果付费的本质，是把失败的成本从买方转移到卖方，卖方从此变成一家保险公司。

但这件事不需要等结果付费普及，按座席收费已经做到了。Cursor、Copilot 这类产品向用户按座席收月费，向模型厂按 **token** 付钱。用户多烧 token 不多付钱，那些 token 全是它自己的成本。

它的毛利率，直接等于模型的任务成功率。

2025 至 2026 年一批“无限量套餐”翻车、被迫改成信用点制，根源就在这里。

绕回英伟达：一个漂亮的闭环

- **按 token 计费时**，浪费的 token 是模型厂的**收入**。跑一小时没解决问题，模型厂照样赚钱，它没有任何动机去减少无效 token。
- **按座席 / 按结果计费时**，浪费的 token 是应用厂商的**成本**，成功率直接写进毛利率。

只有在第二种模式下，才真的有人肯为“提升成功率”持续掏钱做后训练。而按座席收费已经是应用层主流——也就是说，这个动机不是未来时，是现在进行时。

这恰恰是英伟达那套叙事里**最扎实的一环**，比它自己在博客里讲的理由扎实得多：不是“Agent 环境每周在变所以要重

训”（偏营销），而是“应用厂商的毛利率被失败率直接吃掉，所以必须持续买算力去买成功率”（硬约束）。

两个要留的余地：其一，这条链目前只在有廉价裁判的领域成立，裁判越贵链条越松；其二，一旦按“客户没转人工”计费，Agent 就有动机把转人工的按钮藏起来——**指标一旦变成钱，就会被优化**，结果付费的下半场多半要花在反作弊上。

记忆卡：结果付费的门槛不是“任务能不能量化”，而是“有没有一个便宜的裁判”。而风险转移其实已经发生了，只是发生在按座席收费的应用层——谁吞下失败的 token，谁就会拼命买算力去提高成功率。

第六章 回到原文：这篇博客的可信度评估

你当时的问题：解读一下这篇文章。

把前面五章的工具都拿到手之后，再回看原文（华尔街见闻，2026 年 7 月 19 日），可以做一次分层评估。


原文的核心主张

英伟达将下一代 Vera Rubin 平台的价值主张从推理成本延伸至训练效率，提出“每美元智能”这一新指标，主张随着 Agentic AI 兴起，模型后训练已从一次性收尾步骤演变为持续循环的核心工作负载；并称 Vera Rubin 在训练最大规模模型时，仅需上一代 Blackwell 四分之一的 GPU 数量。

旧范式：一条直线，算力是一次性项目支出



新范式：Agent 时代，后训练变成永不停止的循环



分层评估

属于事实、可验证的部分：

- Nemotron 3 Ultra：5500 亿参数、MoE（Mixture of Experts，混合专家）架构，SWE-bench Verified 得分 71.7%，后训练方案完整公开。这是全文含金量最高的硬数据。
- Perplexity：基于 RDMA（Remote Direct Memory Access，远程直接内存访问）的权重传输引擎，两秒内完成万亿参数模型在训练节点与推理节点间同步。
- Prime Intellect：Vera CPU 在真实 RL 沙箱工作负载下，较 x86 架构平均吞吐高 30%。
- Together AI：以服务形式提供后训练（监督微调、强化学习、DPO 直接偏好优化），寻求接入 Vera Rubin。

属于叙事、需要打折的部分：

- “每美元智能”没有给出任何计算公式（见第二章：约八成是包装）。
- “四分之一 GPU 数量”是官方博客口径，无第三方复现。
- “后训练循环永不停止”——机制上成立（见第三章），但**当前更接近愿景而非行业现状**，真正在生产环境跑连续在线 RL 的公司全球屈指可数。
- 客户“表示计划迁移”与“已下单”之间，隔着相当距离。

属于风险、原文没写的部分：

- 持续后训练的经济性尚未被完整验证。若推理端收入撑不起持续训练的成本，这个循环会被客户主动掐断。
- 原文末尾的相邻新闻——Anthropic 被曝测试 AMD GPU——本身就是一条反向信号：**英伟达越强调需求常态化，客户就越有动机把这块常态化支出多元化。**

一个观察方法

这里有个耐人寻味的错位：**英伟达的博客在讲后训练，但英伟达的产品路线图在建“上下文记忆存储平台”**（见第七章）。博客是给市场听的，路线图是给工程师用的。

当两者不一致时，信路线图。

记忆卡：读厂商博客要分三层——事实（可验证的基准与客户数据）、叙事（无公式的新指标、无复现的性能宣称）、风险（原文不写的反向信号）。而最可靠的一层，是它的产品路线图而非它的措辞。

第七章 全景：瓶颈迁移与第三次范式推演

你当时的问题：从训练时代切到推理时代，因为 token 需求爆炸，诞生了像存储这样十倍级别的投资机会。第三次范式变革你觉得会有吗？如果有，会是什么？

先立判据


复盘前两次会发现一个规律——**需求变大不算范式变革，瓶颈换了物理位置才算。**

推理时代的十倍机会为什么出在存储而不是 GPU？因为解码阶段每吐一个字，都要把**整个模型权重从显存里读一遍**，算力再强也没用，卡在搬运上。瓶颈从“算得快不快”挪到了“搬得快不快”，于是钱流向了此前没人正眼看的 HBM（High Bandwidth Memory，高带宽内存）。

十倍机会永远出现在“瓶颈刚挪过去、而那个位置此前不被重视”的地方。

拿这把尺子量后训练：它的瓶颈是算力和互联——**还是英伟达自己的地盘**。所以它撑不起第三次变革，它是英伟达守住第二次成果的防御工事。

瓶颈一路往下走，钱跟着往下走



后训练在这张图上没有自己的位置——它的瓶颈还是算力和互联，也就是英伟达的老地盘。所以它是防御工事，不是新大陆。

注：示意图，用于说明瓶颈迁移逻辑，非投资建议。

判断：第三次的关键词是“状态”

Agent 时代真正新增的东西，不是算得更多，是**记得更久**。前两个时代的分母都是**流量型**（参数量、用户数 $\times$ token 数），用完即弃。而 Agent 引入了一个全新变量：**状态**。一个 Agent 要连续工作几小时甚至几天，要记住它读过什么、改过什么、试错过什么。**状态是存量型的，随时间累积，而非随用户数增长**。这两种曲线的形状根本不同。

而今天的架构处理状态的方式极其原始：每次对话把上下文重灌一遍，KV Cache（Key-Value Cache，键值缓存）用完就扔。这既是巨大的浪费，也意味着巨大的空位。

这已经不是推测，它在路线图上

- **量级**：一个大型 Agent 任务的 KV Cache 可膨胀到**几十 TB**，这个数字彻底排除了用任何 DRAM 层级装它的可能——**只能落到闪存上**。
- **英伟达 2026 年 1 月发布 CMX 上下文记忆存储平台**，由 BlueField-4 DPU（Data Processing Unit，数据处理单元）管理，在本地 SSD 与共享存储之间插进一个新层级（业内称 G3.5 层）。
- **Dynamo 已支持把不常访问的 KV Cache 卸载到 CPU 内存和 SSD**，避免重新预填充。
- **HBF（High Bandwidth Flash，高带宽闪存）** 专为推理设计，2026 年下半年开始送样，**2027 年初进设备**。

这就是那个新层级：**HBM 之下、传统 SSD 之上，一个专门用来装“AI 的记忆”的介质层**。

候选排序

候选	逻辑	评价
状态 / 记忆层	瓶颈下移到闪存，新层级正在成型	最看好 ：机制清晰、产品已落地、共识度还不高
互联 / 光模块	RL 与分布式推理都吃互联	逻辑硬，但 已经很热 ，超额收益被摊薄
电力 / 电网	算力的最终物理约束	逻辑最硬，但 也最共识 ，大概率已定价
Agent 经济基础设施	机器身份、Agent 间支付、行为审计	最早期、最不确定 ，但若成立是全新品类——现有体系全部按“人是主体”设计
世界模型 / 具身	数据基质从文本换成物理交互	潜在最大， 时间表最不可测 ，可能是第四次而非第三次

可跟踪的验证信号

1. **HBF 能否在 2027 年初如期进设备**——最硬的时间锚点，延期即说明需求没起来。
2. **企业级 NAND 的扩产公告**——存储厂扩不扩产，比任何分析师报告都诚实。
3. **云厂商会不会把“上下文 / 记忆”单独定价**——最关键的一条。

第三条背后是个通用原则：**当某样东西开始被单独计价，说明它已经从技术细节变成了独立成本中心。** HBM 当年就是这么浮出水面的。

两句诚实话

第一，范式变革的方向几乎总是事后才清晰。 2020 年没有任何人预测到“内存带宽”会成为 AI 时代的硬通货。所以上面这套**框架（追着瓶颈走）比结论（押注存储）可靠得多**——框架可以反复用，结论应当持续质疑。

第二，信息有边界。 本笔记的 2026 年数据来自整理当日的若干次公开检索，不构成系统性行业跟踪。产业里正在发生而未被检索到的事，一定比检索到的多。

记忆卡：范式变革的判据不是“需求变大”，而是“瓶颈换了物理位置”。 训练→GPU，推理→HBM，Agent→大概率是闪存与上下文存储层。而后训练在这张迁移图上没有自己的位置，它是英伟达的防御工事，不是投资人的新大陆。

附录 一句话记忆卡速查表

主题	一句话
token 的两个身份	技术性质只有一种，账单性质有两种：推理 token 有客户付钱，后训练 rollout 由模型厂自掏腰包
后训练的算力构成	只有一半（rollout）产生 token，另一半（反向传播）连 token 都不产生，却贵 2-3 倍
两把尺子	每 token 成本问“零件造得便不便宜”，每美元智能问“这笔钱有没有办成事”
换指标的本质	换账本——旧账本上后训练是费用，新账本上后训练是投资
有效 token 公式	有效 token 成本 = 名义单价 ÷ 成功率；成功率是除数，杀伤是乘法级的
模型分层的真相	有效 token 的价值不由 token 价格决定，由失败的代价决定
三代广告语	宾语从来没变过（买 GPU），变的只是主语：省钱 → 赚钱 → 变聪明
后训练的拐点	不是它突然重要了，是它突然可以花钱了——奖励信号从人给变成程序给
预训练与后训练	预训练决定天花板，后训练决定你摸到天花板的百分之几
RL 的天花板	等于“能被便宜验证的任务”的总量，与结果付费的边界是同一条线
结果付费的门槛	不是“能不能量化”，而是“有没有一个便宜的裁判”
风险转移	已经发生在按座席收费的应用层：谁吞下失败的 token，谁就拼命买算力买成功率
英伟达挑后训练的原因	不是最大的蛋糕，是别人最打不进来的那块
读厂商材料的方法	分三层看：事实、叙事、原文不写的风险；两者不一致时信路线图
范式变革的判据	需求变大不算，瓶颈换了物理位置才算
第三次的方向	从“算得多”转向“记得久”，十倍机会大概率在闪存与上下文存储层

免责声明：本笔记为学习性质的概念梳理与产业逻辑推演，包含大量前瞻性与不确定判断，**不构成任何投资建议**。文中价格、财务与产品数据均标注了时点与来源，使用前请自行核实。整理日期 2026 年 7 月 20 日。

主要来源：华尔街见闻（2026-07-19）原文；Anthropic 官方定价页与模型发布说明；arXiv 《The Art of Scaling Reinforcement Learning Compute for LLMs》《The Landscape of Agentic Reinforcement Learning for LLMs》；Intercom Fin 与 Sierra 官方定价文档；Blocks & Files、Samsung Semiconductor、TrendForce 关于 KV Cache 卸载与 NAND 需求的报道。