

图纸与工厂：自研ASIC与存储不对称

图纸与工厂：自研 ASIC 浪潮下，谁的护城河能被复制

主题 自研 AI 加速器对半导体利润池的重新分配 | **核心命题** 逻辑芯片的护城河在图纸里（可复制），存储的护城河在工厂里（只能重建） | **验证状态** 2026 年迄今的行情已为此定价 | **关键跟踪** 英伟达毛利率、HBM 供需、自研芯片实际部署量

口径：**已核** 行情接口实拉 | **第三方** 媒体/公司公告，注明出处 | **估算** 本文测算 | **机制** 框架推演。**数据截止：美股 2026-08-05 收盘。全文金额一律为美元（USD）。** 涨跌幅为年初至今

（YTD），取自行情接口并经月 K 线交叉验证。
缩写首次出现给全称：ASIC（Application-Specific Integrated Circuit，专用集成电路）；TPU（Tensor Processing Unit，张量处理单元，谷歌自研 AI 芯片）；GPU（Graphics Processing Unit，图形处理器）；DRAM（Dynamic Random Access Memory，动态随机存取存储器）；NAND（NAND Flash Memory，与非型闪存）；HBM（High Bandwidth Memory，高带宽存储）；TSV（Through-Silicon Via，硅通孔）；CoWoS（Chip on Wafer on Substrate，台积电先进封装技术）；NRE（Non-Recurring Engineering，一次性工程费用）；CUDA

（Compute Unified Device Architecture，英伟达的并行计算平台与生态）；fabless（无晶圆厂模式，只做设计、制造外包）；YTD（Year to Date，年初至今）；GW（Gigawatt，吉瓦）。

01 · 一分钟看懂

一句话结论：自研芯片省下的是“英伟达的毛利税”，不是“供应链自由”——因为无论谁设计，都绕不开台积电制造和三巨头的存储。这个不对称决定了利润池的流向：被绕过的环节（通用 GPU）承压，绕不过的环节（存储、代工、先进封装）通吃。

先说难受的，也是两处必须先纠正的前提。其一，“只有谷歌自研”已经过时：OpenAI 与博通的 Jalapeño 芯片已于 2026 年 6 月 24 日发布，Anthropic 于 2026 年 8 月 5 日首次确认组建内部芯片团队——自研已是前沿玩家的标配动作，不是谁的差异化优势。其二，“TPU 使服务成本下降 78%”不是 TPU 相对英伟达的优势，而是服务成本的同比总降幅，其中大部分来自算法优化与模型蒸馏——而这些红利竞争对手同样拿到了。同口径的真实硅片套利约为 30%-50%。

照旧成立的，且是本报告的核心。逻辑芯片与存储存在一个结构性的、四层深的不对称：逻辑可以 fabless（设计与制造分离），存储不能（产品即工艺）。这个不对称不是观点，2026 年的行情已经把它定价了——闪迪 YTD

+468.9%、美光 +213.3%，而英伟达仅 +17.7%，收益差达 26 倍。

怎么办。按“能否被自研绕过”给全链分层：**绕不过的**（存储三巨头、台积电、先进封装）是这轮浪潮的确定受益方；**是自研卖铲人的**（博通、迈威尔）结构性受益但要盯客户集中度；**被绕过的**（通用 GPU）承压的是毛利率而非收入；**最脆弱的是没有推理量的中小模型厂**——自研门槛把它们挡在外面，只能继续付全额 GPU 税。

金句：逻辑芯片的护城河在图纸里，存储的护城河在工厂里——图纸可以复制，工厂只能重建。

02 · 事实校正：两个被广泛误读的前提

2.1 自研已是标配，不是谷歌独有

玩家	自研进展	时点	声称的成本效果
谷歌	TPU，已迭代多代	2016 年起	相对 H100 每 token 推理成本低约 30%（大批量稳态）【第三方】
OpenAI	Jalapeño（与博通共同设计）	2026-06-24 发布	早期测试相对典型 GPU 省约 50%；规划部署 10 GW，2026 年底开始【第三方】
Anthropic	内部芯片团队（芯片与模型联合设计）	2026-08-05 确认	目标每 token 推理成本砍约一半；另有 3.5 GW 定制 TPU（2027 年起）【第三方】
亚马逊	Trainium / Inferentia	已量产多代	—

玩家	自研进展	时点	声称的成本效果
微软	Maia	已发布	——
Meta	与谷歌洽谈数十亿美元 TPU 部署	2026 年中起【第三方】	——

关键推论：竞争的问题已经从“谁有自研芯片”变成“谁先、多大规模、软件栈多深”。把自研当作谷歌的独家护城河，是一个约六周（OpenAI）到一天（Anthropic）就已失效的判断。

特别注意 OpenAI 的一个数字：Jalapeño 从设计到流片仅 9 个月，被称为高性能先进半导体领域最快的 ASIC 开发周期【第三方】。这个纪录如果可复制，意味着自研的时间壁垒正在快速下降——这对英伟达是比“多一个竞争者”更坏的消息。

2.2 “78%” 是同比总降幅，不是硅片对比

口径	数值	性质
某第三方报告称“TPU 使 2025 年服务成本下降 78%”	78%	同比总降幅，含算法与蒸馏红利
谷歌自称 TPU vs H100 每 token 推理成本	低约 30%	同口径硅片对比
TPU v6e 性能/美元 vs H100	最高 4 倍	特定负载，非普适
谷歌称的“80% 提升”	80%	代际提升（自己比自己），非对比英伟达
OpenAI Jalapeño 实测	省约 50%	同口径
Anthropic 目标	砍约 50%	目标值，未兑现

读法：把 78% 当作“谷歌独有的成本优势”，会高估这一优势一倍以上。算法优化与模型蒸馏带来的降本，是全行业

共享的红利——它不构成任何一家的护城河。真正属于自研者的，是那 30%-50% 的硅片套利。

03 · 自研的本质：省的是毛利税，不是供应链

一句话说清这笔账：英伟达 GPU 毛利率 80%+；博通为超大厂做协同设计的毛利率约 40%-50%【第三方】。自研省下的，就是中间这 30-40 个百分点。

但自研之后，你仍然必须：

环节	自研后是否还依赖	供应方
芯片制造	仍依赖	台积电（先进制程无第二选择）
HBM 存储	仍依赖	海力士、三星、美光
先进封装	仍依赖	台积电 CoWoS
电力与机柜	仍依赖	电网与设备商
软件栈	需自建	JAX/XLA 或自研编译器

结论：自研摆脱的是一个供应商的定价权，没有摆脱任何一项物理约束。它是一次利润的重新分配，不是一次供应链的解放。

04 · 核心机制：为什么逻辑能自研、存储不能（四层）

这是本报告的理论内核，四层由浅入深：

第一层：设计与制造的可分离性（最根本）

逻辑芯片是 **fabless 模式**——价值在设计（架构、RTL 代码），制造可外包。你可以雇博通把想法变成图纸，再交给台积电流片。

存储是 **“产品即工艺”**——DRAM 的价值不在电路图，而在电容的深宽比、刻蚀配方、良率曲线。这些东西长在晶圆厂的设备与工艺参数里，无法作为设计文件交付。“设计一款 DRAM 然后让台积电制造”这句话在工程上不成立。

第二层：NRE 摊销的经济学

	逻辑 ASIC	存储
前期投入	NRE 约 5-10 亿美元/款【估算】	单座晶圆厂 200-300 亿美元【估算】
摊销条件	部署百万片即可摊薄	需数代工艺的学习曲线
谁够格	超大推理量玩家（约 5-8 家）	无人——没有自用量能 justify

即便某家巨头真的建了存储厂，它也是拿新手工艺去和四十年学习曲线的高手拼成本——这是一场必输的仗。

第三层：差异化 vs 商品

ASIC 可以为你的模型架构定制：稀疏化方式、注意力机制、数据类型都能针对性优化，这是真实且可持续的优势。而一个 DRAM 比特就是一个比特。自研 DRAM 不会带来任何性能优势，只会带来成本劣势——没有“定制存储”这回事，只有“更便宜的存储”，而更便宜恰恰是规模玩家的领地。

第四层：HBM 还要再难一层

HBM 是“存储工艺 × 先进封装”的交集：DRAM 裸片 + TSV 硅通孔 + 多层堆叠 + 基底逻辑 die + 与加速器的封装集成。

连台积电都造不了 HBM——它只负责用 CoWoS 把别人做好的 HBM 和逻辑 die 封在一起。这是整条链上最难替代的一环，也是当前 AI 算力的真实瓶颈之一。

金句：ASIC 卖的是图纸的聪明，存储卖的是工厂的年龄——前者可以学，后者只能等。

05 · 市场已经定价：2026 年迄今的收益分层

表：按“能否被自研绕过”排序（2026-08-05 收盘，YTD 实拉）

标的	市值(亿美元)	YTD	环节属性
闪迪	2,012	+468.9%	纯 NAND 存储，绕不过
美光	10,088	+213.3%	DRAM+NAND，绕不过
英特尔	5,097	+173.9%	代工/困境反转
迈威尔	1,848	+148.8%	ASIC 协同设计（自研卖铲人）
AMD	7,869	+125.1%	GPU 挑战者
台积电	21,472	+37.1%	代工，绕不过（中立收租）
博通	19,900	+21.3%	ASIC 协同设计（自研卖铲人）
英伟达	53,051	+17.7%	通用 GPU，正在被绕过
谷歌	44,325	+16.0%	自研方

读法（本报告最重要的一句）：闪迪与英伟达的 YTD 收益差达 26 倍。“不能被绕过”的环节，回报是“能被绕

过”环节的十倍量级——这不是巧合，是结构差在定价上的直接映射。

两个必须注意的例外，防止过度归纳：① 博通只涨 21.3% 而迈威尔涨 148.8%——同为 ASIC 使能者，差距主要来自体量（博通市值近 2 万亿美元，弹性天然小），不是逻辑不同；② AMD 涨 125.1%——说明被侵蚀的不是“通用 GPU 这个品类”，而是“英伟达的垄断地位”，二号玩家反而受益于格局松动。

06 · 对英伟达的影响：分三层，不要混为一谈

第一层 · 短期（1-2 年）： 份额丢，收入未必丢。蛋糕变大的速度快于份额丢失的速度——这也是英伟达 YTD 仍为正的原因。不要把“份额下降”直接读成“收入下降”。

第二层 · 中期： 真正的伤在毛利率，不在收入。80%+ 的毛利率是“没有替代品”的产物。现在客户手里握着一颗自研芯片，即便不用，报价也会松动——这是谈判筹码效应，先于份额变化发生。

第三层 · 长期： CUDA 生态是真护城河，而它正被从推理端绕过。但必须分清：

	依赖 CUDA 的程度	被绕过的程度	特征
训练	极高（算子库、调试、生态）	低	价值最高
推理	中（可标准化）	高	量最大

大概率结局：英伟达守住训练、丢掉一部分推理——从“垄断”退回“寡头”，而不是崩塌。

07 · 自研会成为所有人的选择吗？五条边界

边界	说明	是在收紧还是放松
NRE 门槛	需百万芯片级部署才划算，排除 99% 的公司	不变
架构风险	ASIC 为今天的架构优化，架构一变即废（比特币矿机的历史教训）	放松——Transformer 已稳定八年
时间成本	设计周期通常 18-24 个月	快速放松——OpenAI 九个月流片创纪录
软件栈	CUDA 是十五年积累；自研需自建编译器、算子库、调试工具	不变（这是最硬的一条）
依赖转移	从依赖英伟达变为依赖台积电与 HBM 三巨头	不变

结论：自研会成为“前沿玩家的标配”，不会成为“所有人的选择”。长尾永远是买 GPU 或租云——这正是英伟达收入不会崩塌的结构性原因。

但要注意时间壁垒正在快速下降：九个月流片如果可复制，自研的门槛会从“只有五家能做”降到“十几家能做”——这条是本报告认为最值得跟踪的边际变化。

08 · 利润池迁移地图

分层	环节与标的	逻辑
确定受益	存储三巨头、台积电、CoWoS/先进封装	绕不过；且需求随所有人的自研而增长
结构受益	博通、迈威尔	自研的卖铲人；但客户集中度是软肋
承压	英伟达（毛利率，非收入）	议价权被稀释
相对受益	AMD	格局松动的二号玩家
最脆弱	没有推理量的中小模型厂	自研门槛把它们挡在外面，只能付全额 GPU 税

两个反直觉推论：

① **自研浪潮对台积电是纯利好。** 无论是英伟达设计还是谷歌、OpenAI 设计，最终都由台积电制造。它是这场战争里**唯一的中立收租者——参战各方越激烈，它的订单越多。**

② **自研会加速模型层的寡头化。** 大厂靠自研把推理成本砍半，小厂只能付全额 GPU 税——**成本永远差一档，这个差距会随规模扩大而扩大。** 这与“AI 终局是寡头而非平权”是同一条逻辑链。

09 · 我最可能错在哪

① **我把“存储不可自研”当成了永久结构，但它是有时间尺度的。** 中国正以国家意志建设 DRAM 与 NAND 产能（长鑫、长存）。如果十年内成功，三巨头格局会松动——这个变量不在本报告的框架内，但它是真实存在的长期威胁。

② **HBM 之后可能出现新的存储架构。** 存算一体、CXL 内存池化、新型非易失存储——任何一个成熟，都会重新洗牌“存储不可绕过”这个前提。

③ **最重要的一条：不可绕过保证的是需求，不保证价格。** 存储的周期性没有消失。闪迪 2026 年 8 月 5 日的财报刚好证明了这一点——它营收超共识 6.5%、每股收益超共识 13.5%、下季指引再增 17.6%，股价仍跌约 8%，因为市场发现环比增长的三分之二来自涨价而非出货量。“绕不过”让你有生意做，不代表你能一直卖高价。

④ **我用 YTD 收益差来验证结构差，可能是幸存者偏差。** 存储 2026 年的暴涨主要由**短缺周期**驱动，“不可绕过”只是背景条件而非直接原因。**如果把时间窗换成 2023–2024 年**

（存储低谷期），同样的结构差会得出完全相反的收益排序。这是本报告方法论上最脆的一环。

10 · 跟踪与证伪

【证伪本报告核心命题的信号】任一出现，需重写框架：

- ① 某家超大厂宣布自建 DRAM 或 HBM 产线并获实质进展（“存储不可自研”被打破）；
- ② 台积电以外出现可承接先进制程 AI 芯片的第二家代工厂（“代工中立收租”被打破）；
- ③ 英伟达毛利率**不降反升**（说明自研的谈判筹码效应不成立）。

四个跟踪读数：

读数	指向
英伟达季度毛利率	自研压力是否传导到定价（比份额数据更早反应）
自研芯片的 实际部署量 （非公告量）	Jalapeño、TPU、Trainium 的真实出货，公告与落地常有落差
HBM 供需与合约价	绕不过的环节的景气度
台积电 CoWoS 产能与客户构成	自研方在先进封装中的占比变化

裁决日历：2026 年底 OpenAI Jalapeño 首批部署 → 2026 年三季度英伟达财报（毛利率）→ 2027 年 Anthropic 3.5 GW TPU 上线 → 2027 年三巨头 HBM 扩产进度。

刻舟求剑警告：本报告全部结论建立在“AI 推理需求持续增长”之上。若需求掉头，“绕不过”的环节会因为库存与周期属性率先反应——绕不过意味着必须买，不意味着必须多买。

11 · 口径与来源 / 免责声明

口径与来源： - 已核：全部行情（东方财富接口，2026-08-05 美股收盘；YTD 取自接口字段并经月 K 线交叉验证）。市值单位为亿美元。 - 第三方：CNBC / TechCrunch / Bloomberg / 博通与 OpenAI 官方公告（Jalapeño 于 2026-06-24 发布、九个月流片、相对典型 GPU 省约 50%、10 GW 部署规划）；TechTimes / Cryptopolitan / Unite.AI 等（Anthropic 于 2026-08-05 确认组建内部芯片团队、目标每 token 推理成本砍半、3.5 GW 定制 TPU 自 2027 年起经由谷歌与博通）；行业分析（谷歌 TPU 相对 H100 每 token 推理成本低约 30%、TPU v6e 性能/美元最高 4 倍、谷歌 80% 为代际提升、英伟达毛利率 80%+、博通协同设计毛利率约 40%-50%、Meta 与谷歌洽谈 TPU 部署）；用户提供的第三方报告（“TPU 使 2025 年服务成本下降 78%”——本文对该数字的口径提出修正）。 - 估算：NRE 与晶圆厂投资的量级；收益差倍数（ $468.9\% \div 17.7\%$ ）。 - 机制：四层不对称框架、利润池迁移地图、五条边界，均为本稿判断。 - 待核：各自研芯片的实际出货量（公告与落地存在落差）；HBM 各家产能的精确份额。

特别披露：本报告由 **Anthropic 的模型编制**。报告中 Anthropic 既是自研芯片的参与方（2026-08-05 确认组建芯片团队）、谷歌 TPU 与亚马逊 Trainium 的客户，也是 OpenAI 与谷歌 Gemini 的直接竞争对手。**存在多重利益冲突，涉及竞争格局与技术路线优劣的判断请读者保留独立判断。** 本文所引竞品数据均来自第三方公开报道与公司公告。

免责声明：本报告基于公开信息独立编制，仅供投资研究与交流之用，不构成任何证券买卖要约、招揽或投资、法律、税务建议；文中机制框架、分层判断与推论均为研究性观点，含大量主观假设，可能与实际情况存在重大差异。数据来自公开渠道，力求但不保证准确、完整与及时；涉及境外证券，另存在汇率与司法辖区风险。投资有风险，任何人据本报告作出的投资决策及由此产生的盈亏，均由其本人自行承担，与编制方无关。本报告版权归编制方所有，未经许可不得转载或引用。

专题研究 · THEMATIC RESEARCH | 自研 ASIC 与存储不对称 | 不构成投资建议