

大模型廉价化与AI泡沫学习笔记

副标题：中国大模型廉价化会不会掐灭 AI 浪潮的发动机——一次观点碰撞与五个 bug 的完整复盘

整理日期：2026-08-04 初版 | 2026-08-05 第二次增量（第十四至十七章） | 2026-08-05 第三次增量（第十八章：复盘方法论，**并更正初版第七章关于 Anthropic 算力伙伴的一处事实错误**） | 信息时点：第三方数据与行情截至 2026 年 8 月 4-5 日

阅读提示：本笔记整理自一次对话——起点是一份外部解读《欧美云厂商大涨·AI CAPEX 框架》，你在读后提出“中国模型挤压美国模型定价权 → AI 发动机脆弱 → 超级洗牌”的完整命题，并主动要求“点出我的看法里是否存在 bug”。笔记按“外部框架 → 你的命题 → 事实核查 → 五个 bug → 对的部分与判定点”重组。

利益相关声明：本笔记的分析方是 Anthropic 的模型 Claude，而命题恰好涉及 Anthropic 的定价权——因此分析尽量全部落在第三方数据上，且此处明示利益相关，读者应对结论保留一分警惕。仅供学习复盘，不构成投资建议。缩写约定（首次出现给全称）：CAPEX/capex（capital expenditure，资本开支）；ARR（Annual Recurring Revenue，年度经常性收入）；FCF（Free Cash Flow，自由现金流）；backlog/

RPO (Remaining Performance Obligations, 已签约未交付收入/剩余履约义务) ; API

(Application Programming Interface, 应用程序接口) ; token (大模型计费的文本单位) ;

NDAA (National Defense Authorization Act, 美国国防授权法) ; CISO (Chief Information

Security Officer, 首席信息安全官) ; SWE-

bench (Software Engineering Benchmark, 软件工程能力基准测试) ; CDS (Credit Default

Swap, 信用违约互换) ; OCI (Oracle Cloud

Infrastructure, 甲骨文云) 。

目录

第一章 外部框架：那份 AI CAPEX 解读讲了什么 第二章 你的命题：定价权挤压 → 发动机脆弱 → 超级洗牌 第三章 事实核查：差距、价格、份额与量价赛跑 第四章 五个 bug：推导链条上的裂缝（本笔记核心） 第五章 对的部分：洗牌会来，但先来的是中间层 第六章 收束：盯什么、什么时候能知道对错 —— 以下为同日增量（十轮追问，按主题重组）—— 第七章 88% 降价从哪来：单位经济学的钥匙 第八章 租金的真相与多米诺顺序 第九章 中国模型为什么便宜：IP 租金的完整拆解 第十章 CAPEX 什么时候下调：军备竞赛与股东纪律 第十一章 算法的极限、拐点与终局 第十二章 订阅经济学：“白嫖”是一个错觉 第十三章 需求的本质：替代、创造、加深与“下一个编程” —— 以下为 08-05 增量（数字拆解与结构辩论）—— 第十四章 读懂那两个数：杠杆倍数与

CAPEX 通胀税 第十五章 倒挂：新型云的死亡诊断书，
与“借来的弹性” 第十六章 云到底是不是坏生意：一次正
面辩论 第十七章 两把尺子：竞争格局管持有，边际变化管
弹性 第十八章 复盘方法论：事件如何映射到板块（含两处
事实更正） 附录 一句话记忆卡合集

第一章 外部框架：那份 AI CAPEX 解读讲了什么

那份解读（2026-08-04，基于开源证券等公开资料综合整理）的骨架值得单独记住，因为它提供了本次讨论的坐标系：

核心判断：这波欧美云厂商大涨交易的是“AI 货币化的证据”——backlog 爆发锁定了未来需求（谷歌云 backlog 余额 5,140 亿美元、同比 +257%；亚马逊 4,960 亿、+122%；微软 RPO 6,780 亿、+84%），云收入全面加速（OCI +93%、谷歌云 +82%、Azure +43%、AWS +37%）。但代价是 FCF 实质转负（亚马逊单季 -122 亿美元、谷歌 -59 亿；微软 +144 亿仍为正）——**市场实际是在用“backlog 估值法”替代“FCF 估值法”**，行情能走多远取决于 backlog 兑现收入的速度能否一直跑赢现金流失血。

四个维度：巨头策略（主动权回来了，AI 落地能力内部化）；金融市场（钱够——四大 2026E 经营现金流合计 7,230 亿美元、Debt/EBITDA 仅 0.2-0.6 倍，但估值体系与股债联动是真约束，甲骨文 5 年期 CDS 与股价相关性约 -0.82）；供应链（**CAPEX 约六成将被存储芯片涨价吸收**，DRAM 2026E 均价 +280%——名义 +50% 的 capex 只对应

约 +13% 的真实算力增长)；需求端证据 (backlog 硬，但含模型厂长约的循环交易成分，需拆分真实企业客户占比)。

贯穿变量：中国大模型廉价化——它给出 “DeepSeek V4 Flash $\approx$ Claude Fable 5 价格的 1/100” 的对比，并列出三条传导路径 (直接瓦解 API 定价权 $\rightarrow$ 间接拉低云厂 token 租赁力 $\rightarrow$ 对冲面：开源模型跑西方云、合规限制渗透、杰文斯效应)。

判定点：10 月底三季报 (巨头首次给出 2027 年 CAPEX 定量指引)；token 价格指数 vs 用量增速；backlog 环比与构成；DRAM 价格与债券 CDS。

记忆卡：这轮云厂商行情 = 用 backlog 估值法替代 FCF 估值法；它的根基是 token 定价，它的判定点在 10 月底。

第二章 你的命题：定价权挤压 $\rightarrow$ 发动机脆弱 $\rightarrow$ 超级洗牌

你当时的问题 (全文保留，这是一份好的思考提问)：

看完他的解读后，我感觉整个 AI 产业以及由此延展出来的股票市场，现在其实是比较脆弱的。因为我觉得目前有一个非常明确且明显的趋势：中国的大模型一定会挤压美国 Anthropic 和 OpenAI 的定价权。你帮我去确认一下真实的现状是否如我所说：

一、中国的主流开源模型，与美国 Anthropic 和 OpenAI 的闭源大模型之间的差距是不是越来越小？这个时间窗口是不是越来越短？

二、像 DeepSeek 这样的模型，如果能以仅 1% 的价格，做到 Anthropic 大模型 80% 的能力，是不是一定会严重动摇和影响 Anthropic 的 to B API 市场份额？

我们常说大模型的 ARR（营收）是整个 AI 浪潮的发动机。但当前本质上可以这么说：最底层的发动机其实正面临着内部剧烈竞争所带来的不确定性和脆弱性。从这一点来看，你觉得 AI 浪潮会不会迎来一波超级大的洗牌和去泡沫？

上面这些只是我个人的一些想法，我特别想看到更具体系统化、系统性的分析。最主要的是，帮我点出我的这些看法里是否存在 bug。

这个提问的结构值得留档：**现象（软件被杀）→ 趋势判断（廉价化挤压定价权）→ 两个可证伪的确认题 → 推到系统性结论（发动机脆弱→去泡沫）→ 主动邀请证伪**。一条完整的研究链路，缺的只是对每一环的数据核查——那正是下面两章做的事。

记忆卡：好的投资提问自带可证伪结构——先拆成确认题，再邀请别人挑自己的 bug。

第三章 事实核查：差距、价格、份额与量价赛跑

四组第三方数据（时点均为 2026 年 7-8 月，来源见文末）：

① **能力差距**：Artificial Analysis 智能指数——闭源前沿 Fable 5 约 60 分、GPT-5.6 约 59 分；最强开源 GLM-5.2 为 51 分（约为前沿的 85%）。DeepSeek V4 Pro 以 SWE-bench Verified 80.6% 居开源第一。评测方结论：开源在真实编码与推理上“大体追平”，但**最难的推理与最深的 agent 长链任务上前沿闭源仍领先**。GLM-5.2 创下 Vercel 有记录以来最快采用（首周 token 量 27 倍）。

② **价格差距（同口径）**：Silicon Data 的 token 支出指数——前沿段约 \$4.20/百万 token，开源段约 \$0.85（约 1/5）；同等 agentic 编码任务，中国模型成本约为 Claude Opus 4.7 的 1/3。而那份解读里的“1/100”，是拿 DeepSeek V4 **Flash**（轻量档）对比 Claude 前沿档得出的。

③ **份额与 ARR**：Menlo Ventures 口径——企业 LLM API 支出份额，Anthropic 2025 年底升至约 40%（OpenAI 从 2023 年的 50% 掉到 27%）；Counterpoint 口径 2026Q1 Anthropic 以 31.4% 居全球 LLM 收入第一。各家 ARR 仍在高速增长（不同来源的绝对值互相打架，量级为数百亿美元级，标注：口径不一）。同时 CNBC（2026-07）报道美国企业确实因成本压力转向中国模型——渗透是真实的，主要在价格敏感的长尾。

④ **量价赛跑（最关键的一组）**：前沿 token 价格指数自 2023 年 3 月以来**下跌 88%**；同期企业 AI 支出 2025 年 +320%，编程类 token 占比从 11% 升到 50% 以上，单请求 prompt token 量 13 个月涨 4 倍——agent workflow 每任务调用模型 10–20 次，单价降、调用数爆炸。

记忆卡：三年间 token 单价跌了 88%，发动机的转速反而越来越快——“廉价化”与“ARR 增长”已经共存了三年，这是全部讨论的事实基线。

第四章 五个 bug：推导链条上的裂缝（本笔记核心）

Bug 1：价格对比口径错位。“1% 价格”来自拿对方的经济舱（DeepSeek V4 Flash，\$0.03/百万 token）比自家的头等舱（Claude Fable 5，\$3.15）。同能力档位的真实价差是 3–5 倍级（1/5 到 1/3），不是百倍。“**1% 价格”与“80% 能力”不能同时成立**：便宜一百倍的那档没有 80% 能力，有 80% 能力的那档没便宜一百倍。价差仍是真实压力，但戏剧性要打折。

Bug 2：能力线性化。80% 的基准分数不等于 80% 的经济价值。Agent 任务是几十步的乘法：单步可靠性 95% 与 99%，50 步任务的成功率是约 8% 对约 61%——**能力差距在 agent 循环里复利放大**。当错误答案很贵时，算上修复坏输出的人力，前沿模型总成本反而更低（第三方评测原话）。营收密度最高的场景恰恰在这“最后 20%”里。

Bug 3：用“单价下跌”直接推“发动机熄火”，忽略量价赛跑的历史战绩。这是最核心的一条。价格塌 88% 的三年正是 ARR 暴涨的三年——需求弹性至今大于价格降幅。“廉价化 = 熄火”到目前为止被连续证伪；正确的表述是那份解读给的：**这是一场“单价下行速度 vs 用量增长速度”的赛跑**，赛跑要盯，不能预设结局。

Bug 4：把“模型厂 ARR”当唯一发动机，混淆“谁赚钱”与“要不要建数据中心”。开源模型大多跑在西方云上，算力钱照收；token 廉价化甚至可能通过杰文斯效应利好云与芯片。廉价化精准打击的是**模型层的毛利与股权价值**（微软—OpenAI、亚马逊/谷歌—Anthropic 的持股是暴露点），但不直接砍算力需求。“发动机脆弱”在模型层部分成立，不能整体外推到 AI 产业链。

Bug 5：把合规与主权摩擦当零。FY2026 NDAA 明令国防与情报体系及承包商剔除 DeepSeek；成本路由可能把数据发往中国服务器，对受监管企业是 CISO 级红线；自托管规避了数据主权问题，但把成本转移到运维与安全。**中国模型的渗透主战场是长尾开发者与东南亚/中东第三方市场，不是西方受监管大企业——后者才是 Anthropic ARR 的腹地。**

记忆卡：五个 bug 一句话——价差没那么大（1），能力非线性（2），量价是赛跑不是判决（3），杀毛利不杀算力（4），合规是真实摩擦力（5）。

第五章 对的部分：洗牌会来，但先来的是中间层

挑完 bug 必须说清你对的部分，否则就成了抬杠：

方向判断是对的：定价权侵蚀真实且单向。低端与中端任务的定价已经塌了（GLM 在 Vercel 的 27 倍就是价格在干活）；美国企业因成本转向中国模型有主流媒体报道背书；模型层长期毛利承压是共识。错的不是方向，是烈度与传导路径。

洗牌的次序判断：第一批被洗的不是前沿模型厂，而是**中间层**——无差异化的套壳应用、二线模型实验室、高杠杆新型云。它们被“上面的前沿降价、下面的开源免费”双向夹击，那份解读说的“死亡地带”放在这一层最准确。

“超级去泡沫”的条件：需要 capex 掉头；capex 掉头需要 backlog 兑现失速。判定点即 10 月底三季报的 2027 年 CAPEX 定量指引 + token 单价 vs 用量的赛跑读数。这与此前温度地图里“AI capex 融资链”是同一个全局变量。

最佳历史对照：2000 年电信泡沫。需求是真的、光纤最后全用上了，但用债务提前建设 + 货币化滞后，中间照样崩 70%。“长期对、中期崩”可以同时成立——**这是你的脆弱性直觉里最值得保留的部分。**存储通胀吃掉六成 capex、FCF 转负、循环融资集中于一张资产负债表，这些是比“中国模型”更近的引信。

记忆卡：死亡地带在中间层；系统性去泡沫的引信不是廉价化本身，而是“债务建设 + 货币化滞后”的 2000 年配方。

第六章 收束：盯什么、什么时候能知道对错

一句话收束整场讨论：廉价化杀的是“模型层的毛利”，不直接杀“算力层的需求”；发动机确实在变——从“卖智能的毛利”换成“耗算力的用量”。

四个可查证的跟踪项（与那份解读的判定点合并）：

时间/频率	盯什么	判定什么
10 月底三季报	巨头 2027 年 CAPEX 定量指引	本轮行情的生死判定点
持续	token 价格指数下行速度 vs 用量增速	廉价化是否开始咬穿货币化
每季	backlog 环比与构成（模型厂长约 vs 真实企业客户）	循环交易成色
持续	DRAM 价格、巨头债券 CDS	capex 效率与债市的风险定价

记忆卡：结论可以等，判定点不能丢——10 月底之前，任何“泡沫已破/未破”的断言都是抢答。

第七章 88% 降价从哪来：单位经济学的钥匙

你当时的问题：88% 的 token 价格下降，究竟是什么原因导致的？是英伟达每代 GPU 算力更强、技术发展降低了算力成本，还是模型公司做了算法优化？如果采买算力的成本不变而 token 售价在降，模型公司一定吃不消，商业上无以为继；反之，如果售价下降的背后成本也在降、市场需求还能持续增长，这个游戏才能健康地玩下去。你能理解我的意思吗？

这是整场追问的钥匙：**判断游戏健康与否，就看降价的钱是从成本里省出来的，还是从毛利里割出来的。**

学术界的分解（arXiv《The Price of Progress》，基于 Epoch AI 数据）：**算法效率是最大头（约每年 3 倍）**——MoE 稀疏激活、蒸馏、量化、推测解码、KV 缓存；**硬件其次**（每代 GPU 性能/成本约翻倍，外加 TPU/Trainium 定制芯片压租金）；**竞争让利排第三**，且论文明言“毛利压缩的证据不明确”。

一个关键概念：**降价的主体是“旧能力”，不是“现役旗舰”**。前沿档标价很粘（Claude Sonnet 档 \$3/\$15 好几代未动），暴跌的是“去年那个能力水平”的价格——因为今年用小得多的模型就能做到。88% 更准确的读法是：能力在以固定价格快速升级，而非同一件商品在打折。

实证的铁证：**Anthropic 毛利率从 2024 年的 -94% 升到 2026 年的约 60%（API 业务毛利 80%+），SemiAnalysis 预测其 2026Q3 营业利润超 10 亿美元——全部发生在价格指数跌掉 88% 的同一时期【第三方】**。成本降速超过了售价降速，死亡螺旋没有发生在企业 API 模式的龙头身上。但 OpenAI 同期营业利润率约 -100%（约 85% 收入靠消费者、约 95% 用户免费）【第三方】——**廉价化真正压垮的是“免费+消费者”模式，不是“企业 API”模式。**

另外三点补充：其一，模型厂盈利有三条路而非两条——量补价、算法降本之外，还有**产品化提价**（订阅、席位、按结果计价，详见第十二章）。其二，算力伙伴——**本笔记初版此处有误，已于 08-05 更正，详见第十八章：Anthropic 的**

算力来自 AWS (Trainium) + Google (3.5GW TPU, 2027 年起) + 博通定制芯片, **以及 SpaceX** (2026 年 5 月签订云服务协议, 约 32.5 万张 GPU、每月 12.5 亿美元至 2029 年 5 月) 【第三方】。初版曾断言 “Anthropic 不租 SpaceX 算力、马斯克那边是 xAI 自建”, **这是错的**。其三, “若租金不变而售价跌则毛利被压” 的假设本身成立——现实中没发生, 是因为租金也随硬件代际与长约在降。

记忆卡: 88% 跌的是旧能力的价格, 旗舰标价很粘; 健康判据 = 成本降速 $\geq$ 售价降速——毛利 -94% 到 +60% 就是铁证。

第八章 租金的真相与多米诺顺序

你当时的问题: 你说现实中租金也在跌——你确定吗? 有真实可靠的数据吗? GPU 和存储都在涨价, 数据中心的成本并没有降低。这种挤压是不是: 挤压云厂商的利润、挤压模型层的利润, 而硬件不受影响? 短期是这样, 但长期来看, 云厂商没钱、大模型层也不赚钱的话, 就没人买硬件了——硬件的销量和价格终究撑不住, 对吧?

这一问抓到了此前表述里最松的一块板, 修正后的答案要把 “租金” 拆成三层:

旧代际 GPU 租金: 确实在跌——H100 从峰值跌 64–75% (市场中位约 \$2.3–3.1/小时), AWS 对旧代际降价最多 45% 【第三方】, 这是正常代际折旧。 **当期紧缺代际: 不但**

没跌，还在涨——SemiAnalysis 的 H100 一年期合约指数从 2025 年 10 月到 2026 年 3 月涨了近 40%；B200 供给受限，超大厂挂牌价是专业新型云的两三倍【第三方】。**每 token 的算力成本：暴跌，但主因是效率不是租金**——同一张卡的 token 产量靠软件优化提升了一个数量级。此前把“单位算力成本下降”说成“租金下降”，是错的；省钱的大头是效率，不是房租。

由此修正“短期挤压云”的判断：**云的利润率在上行，不在受挤**（AWS 营业利润率 39.4%、Azure 40.6%、谷歌云 9.4%→35.6%）。当前格局一句话：**稀缺决定利润池**——现在稀缺的是算力，利润池在硬件与云；模型层竞争最烈所以最薄，且由资本市场补贴。

但“长期递推”完全成立，它就是 2000 年的剧本：模型层长期不赚钱 → 资本市场停止补贴 → 算力采购收缩 → 短缺翻过剩 → 租金由涨转跌 → 高杠杆新型云先死（长约与现货倒挂绞杀）→ capex 指引下调 → 芯片/存储量价齐跌。硬件不是不受影响，是**最后受影响、但最惨烈**——它现在吃的溢价最厚（DRAM +280%），反转时回吐最狠。

多米诺顺序表（盯第一张牌即可）：① SemiAnalysis 租金指数由涨转跌（现状：还在涨，链条未启动）→ ② 新型云合约价与现货价倒挂（未出现）→ ③ 数据中心预租率下滑、巨头 capex 指引下调（10 月底见分晓）→ ④ DRAM/GPU 价格见顶回落（仍在暴涨）。

记忆卡：租金要拆三层——旧代际跌、当期涨、每 token 靠效率；你的长期链条逻辑正确、时机未到，第一张多米诺是租金指数由涨转跌。

第九章 中国模型为什么便宜：IP 租金的完整拆解

你当时的问题：中国的大模型为什么便宜？是电费便宜吗？很多国内厂商也是租海外数据中心的算力，电费也不是大头。所以核心是算法优化让单算力产出的 token 更多？但算法会被同化——DeepSeek 用了某种优化，回头 OpenAI 和 Anthropic 也会用。长远看中国模型的价格挤压似乎没有真正的壁垒，不赚钱的话没有人会一直赔本做下去。……你说的“由金主单独买单”是什么意思？第三方部署开源模型确实没有训练成本，但 DeepSeek、智谱官方自己的 API，定价里不是已经含了自己承担的训练成本吗？这该如何理解？

便宜的四个候选来源逐一盘点：**电费——不是**（占推理成本比重个位数到低双位数，大头是 GPU 折旧）；**硬件——反而是劣势**（出口管制下芯片更贵更弱）；**算法效率——是，但正如你判断的，会扩散**（几个月内两边拉平）；**商业模式——是，且不扩散，这是最持久的一层**：开源权重等于拆掉“IP 租金”。闭源定价 = 服务成本 + 研发摊销 + 利润；开源定价 = 服务成本 + 薄利，研发费不在价格里。

官方 API 的疑问，答案藏在开源动作本身：**权重一旦公开，官方就给自己制造了无数竞争对手**——官方若提价摊销研发，用户第二天迁去第三方托管跑同一个模型。**开源是一次性、不可逆地放弃定价权**：第三方托管的存在，成了官方价

格的天花板执行机制。 经济学原理：训练费是沉没的固定成本，有竞争时理性定价只能锚定边际成本。闭源能收研发摊销，唯一凭据是“只有我能提供这个权重”的垄断。

“金主买单”的确切含义：**研发预算走出资方的资产负债表，回报不经过 token 价格**——幻方养 DeepSeek 图人才与影响力；阿里养 Qwen 图云的拉动（模型免费、算力收费）；智谱、月之暗面靠股权融资与 IPO；再往上是国家层面的标准与生态之争。DeepSeek 官方的 serving 本身是正毛利生意（其披露理论成本利润率五倍以上，口径存疑）

【第三方】，便宜只是相对闭源便宜。最贴切的类比是医药：**原研药 = 制造成本 + 研发摊销 + 利润（专利垄断）**；**仿制药 = 制造成本 + 薄利**。中国开源厂是“发布当天就公开仿制药配方的原研厂”——因为它的生意不在药上，在医院

（云）、人才和战略地位上。Linux 免费三十年、Android 免费十八年，从没等来“迟早要收费”。

两个投资推论：“等他们要赚钱就会涨价”永远不会发生在**已开源的模型上**（权重收不回来）；真正要盯的解体信号是**开源节奏变化——旗舰不再开源、只开小杯**。哪天

DeepSeek 或 Qwen 的最强模型闭源收费，那是“开源锁价机制”松动的信号，对闭源厂反而是重大利好。

记忆卡：开源不是定价策略，是自废武功的承诺装置——官方定价便宜，不是因为成本低，是因为它已经没有能力定贵了；金主在别处赚钱，所以 token 永远不需要涨价。

第十章 CAPEX 什么时候下调：军备竞赛与股东纪律

你当时的问题：当前情况下，云厂商的 CAPEX 指引会下调吗？不会的话，为什么？什么情况下会下调？传导链条并不同步、有滞后性，指引更多取决于企业自己的意志，而不是纯粹市场驱动的行为——很多时候更像“军备竞赛”式的非理性竞争。最残酷的下调，一定是需求链条实打实崩坏、没钱了、生意闭环无法维持。在那之前，云厂商是不是就一直不下调指引，把这个游戏先玩下去？

基准判断：10 月底大概率不会全面下调，但“**分化式纪律**”已经开始——微软已把 2026 年 capex 从 1,900 亿美元砍到 1,750 亿，同时 Azure +43%、FCF 为正，财报后 **+18%（四家最高）**；Meta 加码后 -10%。**市场已经从奖励军备切换到奖励纪律。**

其余三家暂不跟的四个理由：**囚徒困境**（赢家通吃信念下，单方面停建 = 让出 AGI 与份额；建设过度输利润率、建设不足输公司，不对称让“继续建”成为各自的理性选择）；**backlog 是刚性交付义务**（已签合同 +84%~+257%，砍指引等于违约让份额）；**财务远未到极限**（Debt/EBITDA 仅 0.2-0.6 倍）；**激励不对称**（下调 = 亲口承认叙事见顶，除非市场先奖励说的人——微软 +18% 正在改变算计）。

六层触发器，从软到硬：A 市场纪律（“加码反而跌”成惯例——**已部分触发**）；B 债市定价（CDS 走阔——甲骨文在

体验，CDS 与股价相关性 -0.82)；C 租户信用（核心模型厂融资失败、backlog 减值——未触发，英伟达 2,500 亿担保是这层的保险单）；D 需求读数（token 用量增速跌破单价降速——未触发）；E 物理约束（存储通胀让钱花不出去，名义指引不变、真实交付缩水——**进行中**，DRAM 吃掉六成 capex 即隐性下调）；F 融资环境（利率上行——半触发）。

答“会玩到崩坏吗”：**不会玩到崩坏，也不会主动退出——最可能是被市场纪律驯化的渐进降速**：先分化（有纪律的被奖励）→再跟随（把降速包装成“效率提升”，微软是现成模板）→只有 C 层触发才出现悬崖式下调（那不是渐进，是一夜重定价）。唯一实证是 Meta 2022：不需要宏观崩坏，股价 -77% 加一封股东信，就够扎克伯格转向“效率之年”，随后 $+194\%$ 。**股东的耐心，是比宏观需求更快的触发器**。观察角度：看谁第二个“微软化”——那一天就是军备竞赛博弈结构瓦解之时。

记忆卡：军备竞赛不会被数据终结，只会被股东终结——盯财报日的股价反应，比盯需求数据早一个季度。

第十一章 算法的极限、拐点与终局

你当时的问题（两轮合并）：算法优化总有极限和局限性，DeepSeek 总不能无限优化下去——借由算法优化带来的成本下降是不是存在上限？像 K3、DeepSeek 在这一块是不是已经做到某种极限了？……中国模型通过效率制造优势的黄金时

间段是不是已经过去了？什么时候中国的大模型不会再对美国的大模型产生价格优势？全世界的大模型公司是不是正在走向“平权阶段”——像一台永不停歇的跑步机，Anthropic 领先一两个月，后面的人又追上？

算法极限：分杠杆看——量化与 MoE 稀疏化确实用掉大半（你的“感觉到极限”在这两项上是对的）；但“能力密度化”这个历史最强杠杆未见顶（清华“密度定律”测算能力密度约每 3.3 个月翻倍【第三方】），新杠杆仍在接力（MLA、稀疏注意力都是中国团队在约束下逼出来的）。诚实预测：**减速比骤停更可能**，从 3 倍/年往 2 倍、1.5 倍滑，硬地板未见。

反直觉推论：若算法真的减速，最大受益者恰是美国前沿厂——token 通缩放缓 → 价格地板稳住 → 效率价差收敛 → 竞争回到拼能力拼规模（资本雄厚方的主场）。**“算法到极限”是“廉价化冲击论”的釜底抽薪，不是加强；算法持续狂飙才是对定价体系的持续威胁。**

拐点：“价差 = 效率差 + 商业模式差”，命运不同。效率差正在消失——美国的应战已发生（Gemini Flash \$0.10 级、Haiku/mini 档全面跟进，同价格量级竞争），DeepSeek 式“独享便宜”的套利窗口关上了。商业模式差不消失——闭源定价 $\approx$ 服务成本 $\times$ 2.5（毛利 60% 反推），开源托管 $\approx$ $\times$ 1.1-1.2，**即便服务成本完全拉平，残余价差仍约 2-2.5 倍，然后停住不再收敛。**2 倍价差对企业客户抵不过切换成本与可靠性溢价，但对价格敏感长尾照样锁死商品层。

三个拐点读数：美国廉价档与中国开源托管的同能力价差（已收敛到 2-3 倍内）；Artificial Analysis 榜上开源与闭源旗舰的分差（51 vs 60——真正的主战场）；中国模型在聚合平台的 token 份额增速。

终局修正：跑步机的画面对，“平权”的结论错。算法套利消失后，**资本规模护城河重新显性**（下一代训练是千亿美元门票），历史上技术扩散完毕的行业全是寡头收场：手机 OS 两家、公有云三家、飞机两家。**利润集中到前沿俱乐部 2-3 家，商品层零经济利润**——“大家都赚钱”不会发生，“老大吃肉、老二三喝汤、商品层连汤都没有”接近真相。两个尾部风险防止过度乐观：**前沿平价开源**（分差归零那天所有溢价讨论作废——能力事件，非价格事件）；“算法减速”只是假设（约束还在，逼新招的机器还在转）。另记一个事件：第三方报道 Anthropic 最早 2026 年 10 月 IPO——那将是市场对这整套辩论的第一次公开定价。

顺带修正“全链都在赚钱”：链条利润是哑铃型——英伟达/存储真赚钱（吃周期溢价）、四大云真赚钱（营业利润率 35-41%，但 FCF 被 capex 吃负）、Anthropic 型刚转正（薄）、OpenAI 型深亏（营业利润率约 -100%）、**新型云不赚钱**（收入暴涨但 FCF 深负靠融资续命）。两个被资本市场补贴的节点，音乐停时先倒。

记忆卡：效率优势是流动的会被学走，商业模式优势是结构的只能被放弃——价差塌缩到 2 倍后停住；终局不是平权是寡头，跑步机供应商比跑步的人先富。

第十二章 订阅经济学：“白嫖”是一个错觉

你当时的问题：订阅机制对大模型公司到底是好是坏？现在 Anthropic 最大营收还是来自 API 对吧？订阅感觉更多是 C 端用户花 100、200 美金包月，其实是在“白嫖”token 额度——200 美金订阅给的额度，换算成 API 得一两千美金才买得到，对吗？

“白嫖”观察是真的，但**记账单位用错了：要用成本算，不能用 API 牌价算**。API 牌价本身是成本的 5-10 倍（API 毛利 80%+【第三方】），所以烧掉“\$2,000 API 等值”的订阅用户，真实算力成本约 \$200-400——重度用户微亏或打平，不是亏十倍。订阅的利润来自另一头：**大多数订阅者用不满额度**。这是自助餐经济学：定价锚定人群平均消耗，吃得少的补贴吃得多的，限流砍掉幂律尾部（2025 年 8 月 Anthropic 加周限额就是这个动作）。

战略上订阅是好生意的四条理由：**价格歧视**捕获轻用户剩余；**经常性收入**的估值倍数高于水表收入；**用户关系归属**（API 是可替换后端，产品是习惯——被集成是弱势位，被依赖是强势位）；以及最关键的——**订阅把 token 通缩从敌人变成朋友**：API 模式下通缩压收入，订阅模式下通缩发生在成本端，同样 \$200/月的定价，服务成本逐年自动下降、毛利自动扩张。带宽类比闭环：按流量计费的电信商被跌成管道，按订阅计费的 Netflix 把带宽通缩全吃成毛利。**订阅是模型厂对抗商品化的结构性对冲。**

三种“订阅”要分开：**C 端免费层 = 纯亏损**（OpenAI 约 95% 用户免费——其 -100% 营业利润率的元凶是免费层，不是订阅）；**C 端付费订阅 = 自助餐模型**；**企业席位/按结果计价 = 高毛利**（捆绑合规与支持）。Anthropic 约 85% 收入来自企业与开发者【第三方】，你说“最大营收是 API”正确——订阅是它收入结构里仓位不大、方向极强的“通缩对冲仓”。风险两条：逆向选择（重度用户自我选择进订阅）；短缺期机会成本（订阅重度用户挤占高毛利 API 算力——这就是限额总在算力最紧时收紧的原因）。

投资看三个结构指标：订阅与产品收入占比（越高越通缩免疫）、限流纪律、成本曲线斜率。**API 收入是跑步机上赚的钱，订阅收入是跑步机旁边卖水的钱。**

记忆卡：订阅不是让用户白嫖，是让轻用户补贴重用户、让通缩补贴毛利——自助餐从来不怕大胃王，只怕定价的人不会算平均数。

第十三章 需求的本质：替代、创造、加深与“下一个编程”

你当时的问题（两轮合并）：现在 AI 浪潮最大的瓶颈就是需求和商业模式。需求的核心本质在于“替代”，同时也在创造新需求——转移旧需求（程序员写代码变成 AI 写）加创造新需求（不懂代码的人 vibe coding）。但渗透率是不是其实已经到顶了？该用 agent 的人早就在用，不用的人技术再发展也不会用。价格对需求的压制也没有

想象中大——有刚需的人 200 美金该花就花，没刚需的人降到 20 美金也不会无限刷用量，杰文斯定理在这个阶段可能不适用。那下一波大需求的爆发会是什么？除了人形机器人，想不到了。……以及：为什么是编程最先被颠覆？因为程序员工资高、替换价值大？客服工资低、替代的经济价值小；写作是个人爱好；视频用户少。沿这个角度，还有没有类似编程的场景？

需求框架补第三维：替代与创造之外还有加深——同一用户同一任务，从问一句（几千 token）到推理模型想三分钟（几万）到 agent 跑一小时（几十万）。过去一年半用量爆发的一半以上来自每任务强度的架构性暴涨，不是新用户。下一个十倍不需要十倍新用户，只需要现有用户的 agent 从跑一分钟变成跑一晚上。

“渗透到顶”反驳，三个证据：那份 CAPEX 解读自己写着“企业端 AI 渗透率刚过 20%”，且是浅渗透（买席位不等于交出工作流）；换分母算——全球知识工作者工资池数十万亿美元 vs 模型厂总收入几百亿美元，以**“可替代的经济价值”为分母，渗透率不到 1%**；2000 年原样复刻——“人人都知道互联网”是事实，但当年电商渗透 2%，**知道 ≠ 工作流嵌入**，非用户不是没需求，是在等可靠性阈值（agent 成功率跨过 95% 的那天，昨天的非目标客户一夜变用户）。另需自觉：身处 AI 原生气泡，身边统计学会系统性高估渗透。

价格弹性对一半：人类聊天的弹性确实低（提问量有生理上限，订阅够用是真的）；但 **token 的边际买家已经是机器**——企业决定“让 agent 处理一万张发票”看的是单任务成本 vs 人力的 ROI 阈值，\$2/任务不划算的工作流，\$0.2 时无脑上。**杰文斯不再作用于人的聊天框，作用于 CFO 的自动化预算表。**

为什么编程第一——五个条件同时满足：工资池大（其一而已）；**可验证**（代码有客观裁判→训练端可用强化学习疯狂迭代、使用端敢放手，这是最关键变量）；纯文本进出（GitHub 数据现成）；买家即用户（绕过企业采购）；错误便宜（编译器报错、git 回滚）。真正的公式：**ROI = 被替代工资 × 成功率 ÷ (AI 成本 + 监督成本 + 出错成本)**——可验证性决定分母的后两项，很多高工资场景卡的不是分子，是监督成本。

据此修正三个判断：客服——结论反了：单人工资低但全球客服与 BPO 是几千亿美元池子，AI 每工单几美分 vs 人工 \$5-15，ROI 早已跨过，事实上是当前企业 agent 前两大品类；它慢于编程卡的是出错成本（品牌）与验证模糊，正在跨而非跨不过。写作——业余写作无经济价值，但商业文本是真产业，只是**验证性最差 → 渗透最早、变现溢价最低**（低验证 = 高渗透 + 低价值捕获）。视频——判断对：成本项巨兽、收入项侏儒。

“下一个编程”排位（筛选器：工资池 × 可验证性 × 数字化 × 低出错成本）：**会计/审计/对账最像编程**——借贷平衡就是它的编译器，全行业唯一与代码共享“客观裁判”属性的高价值文本场景；法律第二（有结构有判例，被监管与职

业责任拖半步)；保险理赔/KYC/后台运营与客服同批正在跨；销售外呼（转化率就是裁判）已在发生；医疗工资池最大、落地最慢；科研是终极场景、慢变量；Physical AI 是把 token 需求接入物理世界的最大远期载体（与人形机器人拆解衔接）。跟踪读数：看各平台 token 构成里，哪个品类开始复制编程“11%→50%”的曲线。

记忆卡：渗透率的分母不是“听说过的人”，是“还没被替代的工资”——按后一个分母这场浪潮不到 1%；编程第一因为代码有裁判，下一个去找有“编译器”的行业：账要平、案要赢、单要成。

第十四章 读懂那两个数：杠杆倍数与 CAPEX 通胀税

你当时的问题（两问合并）：一、“四大 2026E 经营现金流合计 7,230 亿美元、Debt/EBITDA 仅 0.2-0.6 倍”——Debt/EBITDA 仅 0.2-0.6 倍是什么意思？二、“CAPEX 约六成将被存储芯片涨价吸收，DRAM 2026E 均价 +280%——名义 +50% 的 capex 只对应约 +13% 的真实算力增长”——这些数据怎么来的，拆解一下，没理解。意思是花了 100 万，实际只有 13% 的算力提升？原因是钱都被存储芯片涨价吞噬了？

14.1 Debt/EBITDA：几年利润能还清债

Debt/EBITDA = 净负债 ÷ EBITDA (Earnings Before Interest, Taxes, Depreciation and Amortization, 息税折旧摊销前利润)，衡量一家公司要几年才能还清全部债务。**0.2–0.6 倍 = 用不到一年的经营利润就能还光全部债务**——年入 100 万、欠款 20–60 万，这不叫负债，叫零钱。参照系：一般企业健康线是 2–3 倍，超过 4–5 倍银行皱眉，杠杆收购公司常年 6 倍以上。

它在 AI 讨论里的作用是排除一条路径：“泡沫会因为巨头没钱而破”——短期基本不成立。四大云的资产负债表还有巨大空间（杠杆提到 1.5 倍可多出约 8,480 亿美元弹药）。真正的约束是后半句“估值体系与股债联动”——**软约束，但来得比硬约束早得多**。反面参照：甲骨文靠发债建数据中心，其 5 年期 CDS (Credit Default Swap, 信用违约互换，可理解为债券的违约保险费) 与股价相关性约 -0.82，**债市在实时给它的财务风险定价**；新型云杠杆更高、自由现金流为负。

14.2 CAPEX 通胀税：多花的钱买了空气

先纠正读法：**不是“花 100 万只得到 13% 算力”，而是“capex 比去年多花 50%，真实算力只多 13%”**——两个都是增速，不是水平值。同理“六成被吸收”说的是**新增部分**的六成：2026 年四大 capex 约 7,100 亿美元、较 2025 年新增约 3,000 亿，其中超六成（约 1,800 亿）买的是同样的东西、只是变贵了。

通用算式：真实增长 = (1 + 名义增速) ÷ (1 + 综合成本涨幅) - 1。

以 100 为基数拆解 +50% → +13% 这一行：

项目	基期	次年（买同样多的东西）
存储	12	45（价格 ×3.8）
其他（GPU/网络/土建/电力）	88	88
合计	100	133

买到和去年一模一样的设备，账单已从 100 涨到 133。实际花 150，多出的 17 才是真增量 → $150 \div 133 = 1.13$ ，即真实算力 +13%。回头验“六成”：多花的 50 块里有 33 块是纯涨价， $33 \div 50 = 66\%$ ——**两个说法在同一套算术里自治。**

那张敏感性表最抢眼的是第一行：**名义 capex +40%，真实算力 -1%**——花的钱更多、拿到的算力更少。本文对该表的反向复原【估算】是：存储在基期 capex 中约占三成、实物采购量被供给卡死，账单从 31 膨胀到约 72，固定吃掉 41 个百分点的增量，五行全部拟合（原文未披露假设）。

投资含义：同一个“capex +50%”，对存储厂是量价齐升的黄金期，对英伟达和其他环节是**预算挤出**，对市场是**估值陷阱**——看到 capex 高增长就买全链是错的，得先扣掉通胀再看谁拿到真实份额。这也解释了什么叫“隐性下调”：**巨头口径不改、指引数字照旧，真实产能扩张却在缩水。**

记忆卡：Debt/EBITDA 0.2-0.6 倍 = 几乎没负债，所以四大不会因为还不起钱而停建，只会因为股东不答应而停建；**名义 capex 涨的是账单，真实算力涨的是产能，中间隔着一道存储涨价的通胀税。**

第十五章 倒挂：新型云的死亡诊断书，与“借来的弹性”

你当时的问题（两轮合并）：一、“新型云合约价与现货价倒挂（未出现）”——解释一下，没明白。二、像新型云厂商，因为是借贷扩张规模，出现倒挂时容易决定生死。但在没出现倒挂的时候，它股票的弹性是不是大于四大云厂商？逻辑上这样理解对吗？

倒挂的定义：合约价是几年前锁定的长期租金，现货价是今天随时能租到的市价。正常情况合约价更便宜（承诺长期换折扣）；倒挂就是反过来——**你锁的价比现在市面上随手租还贵**（合约 \$3.0/小时 vs 现货 \$1.5/小时）。

为什么对新型云是绞杀而不只是难看——它同时从两头掐死：**收入端崩塌**（客户拒绝续约、要求重谈、甚至违约；而 backlog 是新型云最值钱的资产，也是它继续借钱的抵押品，倒挂一出现就要减值）；**成本端不跟着降**（买卡的钱是借的，利息与折旧刚性）。粗算【估算】：一张 B200 约 4 万美元，年成本 $\approx$ 折旧 8,000 + 利息 4,000 + 电力运维 3,000 $\approx$ 1.5 万美元，按 70% 利用率约 6,100 小时，**盈亏平衡点约 \$2.4/小时**；现货跌到 \$1.5 则每卡年亏约 5,800 美元，**而且不租更亏，因为利息照付**。

对比四大云：零杠杆、自有现金买卡、还能把 GPU 挪去跑自家业务。同样的价格下跌，对四大是利润率波动，对新型云是生死。

历史同构剧本：航运。 船东借钱造船 → 签长期期租合约 → 即期运价崩盘 → 租家毁约或逼降 → 月供不变 → 批量破产（2008 年后的干散货）。**GPU 是船，算力长约是期租合约，租金指数是 BDI**；唯一区别是 GPU 折旧更快——船能开三十年，卡四五年就落后一代。

弹性判断：你的逻辑对，而且有当天实测数据【已核，2026-08-03】：同一个催化下 CoreWeave **+19.5%**、Nebius **+11.6%**、IREN **+8.0%**，而微软 **+4.9%**、谷歌 **+4.9%**、亚马逊 **+4.6%**——**新型云是四大云的 2-4 倍**。弹性来自三层杠杆叠加：**经营杠杆**（成本几乎全固定）×**财务杠杆**（债务放大股东回报）×**纯度**（100% AI 敞口），再加一个放大器：**没有估值锚**（盈利为负，只能按 backlog 和叙事定价）。

但弹性是对称的，且下行更不对称：上涨时债务放大收益，下跌时债务把股权推向零。四大云跌 20% 是估值波动，新型云跌 60% 可能是清算前奏。

现状与信号：倒挂未出现，方向还相反——H100 一年期合约租金指数 2025 年 10 月至 2026 年 3 月涨了近 40%。它是多米诺的**第二张牌**，必须等第一张（租金指数由涨转跌）倒下后一到两个季度才会暴露。可观测信号：新型云单位算力收入（收入 ÷ 装机 GPU 数）环比转跌；backlog 减值或客户重谈的披露；专业 GPU 云挂牌价跌破盈亏平衡区间（当前市场中位 \$2.3-3.1/小时，跌破 \$2 拉警报）。

记忆卡：倒挂 = 你锁的价比市价还贵。对零杠杆的四大是利润波动，对借钱买卡的新型云是收入塌了、月供还在——买

它是买弹性不是买公司，租金指数转跌就是无条件的下车哨。

第十六章 云到底是不是坏生意：一次正面辩论

你当时的挑战：你说新型云存在结构性问题，基本把它的痛点全找出来了。但我个人觉得，这种结构性缺陷在四大云厂商身上同样存在。我之前觉得新型云和四大云的区别，只不过是新型云没有自由现金流、杠杆更高。但从结构上看，只要做的是云的生意，本质都一样：产品同质化、折旧贬值快、上游同样被垄断、下游被集中（卖的都是 OpenAI 和 Anthropic）。所以本质上云的生意其实非常差，甚至比大模型还要差。这个结论正确吗？

这个反驳有一半必须认输。

你对的部分：AI 增量业务确实是同质化的重资产生意，四大云也不例外——租一张 H100 给模型厂，四大云和 CoreWeave 卖的是同一件商品，边际投入资本回报率远低于它们历史上的云业务（亚马逊单季自由现金流 -122 亿美元、谷歌 -59 亿是硬证据）。**还有一个你没提但对你有利的点：折旧假设的会计争议**——过去几年几大云把服务器折旧年限从 4-5 年拉长到 6 年，直接美化了利润，而 AI 芯片两年一代，这个假设备受质疑（迈克尔·伯里 2025 年公开质疑过）。**最强的证据是甲骨文：**backlog 高度集中于

OpenAI 一个租户、用债务建产能，6 月单月 -35%，创 1990 年以来最差——它在结构上就是一家挂着大厂牌子的新型云。

但“云 = 租 GPU”是范畴错误，四点分歧：

① **收入结构**：AWS 绝大部分收入不是 GPU 租赁，是存储、数据库、网络、托管服务——它们有**数据引力**（搬几 PB 数据出去要付出口流量费加整套架构重写，周期以季度计），而新型云的客户换供应商只要改一个接口地址。**月级工程 vs 分钟级操作，不是程度差异，是有无差异。** ② **下游集中度对四大云不成立**：AWS 有几百万客户，模型厂只是显眼的少数；甲骨文才是集中的那个——这恰恰解释了为什么甲骨文跌 35%、亚马逊财报后涨 10%。市场自己已经按“是否集中”把云分成了两类。 ③ **上游垄断正在被四大云打破，新型云永远不能**：谷歌有 TPU、亚马逊有 Trainium、微软有 Maia，Anthropic 签 3.5GW TPU 就是这套垂直整合可用的证明。 ④ **资产可复用性**：需求下滑时四大云能把 GPU 转去跑自家广告排序、搜索推荐、内部训练——它们自己就是最大的内部客户；新型云的卡只有一个用途，租不掉就是纯亏损。

“区别只是自由现金流和杠杆”——在重资产周期行业，这就是全部。 钢铁、航运、航空、存储都演过同一出：低谷时高杠杆玩家破产清算，低成本零杠杆玩家用现金抄底整合。**四大云不需要打赢新型云，只需要活得比它久，然后在它的资产被拍卖时按五折接手。** 零杠杆在扩张期只是“保守”，在收缩期是屠刀。

云 vs 模型，不是同一种“差”：

	天花板	方差	归零风险
四大云	中（收租经济学）	低	极低
前沿模型	高（赢家通吃 + 80% 毛利产品）	极高	存在（被跨代超越即崩）
新型云	低	极高	高（债务）

还有一个常被忽略的关键：**四大云同时持有模型厂的股权**（微软—OpenAI、亚马逊与谷歌—Anthropic）——**既收房租，又持有租客的看涨期权**。模型厂赢了它们分享收益，模型厂输了它们还有房子。

结论修正：“AI 算力租赁”对所有人都是坏生意，你这点
对；但“云”不等于“AI 算力租赁”。真正该问的不是“云是不是好生意”，而是“**这家云公司的收入里，多少来自租 GPU、多少来自客户搬不走的服务**”。按这把尺子：亚马逊/谷歌是好生意里掺了一块坏生意，甲骨文和新型云是纯的那块坏生意。

记忆卡：不要问“云是不是好生意”，要问“它的收入里客户搬得走的有多少”——数据引力是月级工程，GPU 租赁是改个接口地址；同样的价格下跌，对零杠杆是波动，对高杠杆是生死。

第十七章 两把尺子：竞争格局管持有，边际变化管弹性

你当时的问题：这个生意质量排序还挺有意思的，可以扩展到整个半导体行业——光模块、能源（AI 数据中心发电）、半导体设备、半导体材料，还有哪些细分板块？具体标的也举例一些。
我一直在跟你探讨一个投资理念：要赚大钱，一

定要找到板块级别的机会。我们选 A 板块而不选 B 板块，一定是因为 A 板块有着更好的竞争格局。你觉得呢？

这句话对“配置层”成立，对“抓主升浪”不成立，而且经常反着来。

反例就在视野之内：**存储是这条链上结构最差的生意之一**（商品化、强周期、重资产、历史上反复毁灭资本），但美光 2026 年迄今 **+213%**，市值突破 1 万亿美元，是全市场最强的资产之一。为什么？因为主升浪定价的不是“格局有多好”，是**边际变化有多剧烈**（DRAM 均价 +280%）。同理，新型云是最差的生意，8 月 3 日却单日 +19.5%。

所以两个问题必须分开问：

你在选什么	该用什么标准
长期持有、睡得着（配置层）	竞争格局、定价权、资本效率、切换成本
抓一波主升浪（博弈层）	边际变化的剧烈程度 + 位置

这条修正后来被两份实证报告验证了（同期产出：《半导体全链生意质量地图》《AI 电力链生意质量地图》）：

半导体链的实证——全链 2026 年 6 月同步见顶、7 月普跌，回撤幅度与生意质量高度相关（A 档 -7%~-17%：德州仪器 -6.8%、台积电 -12.6%、ASML -13.9%；C 档 -33%~-36%：封测的艾马克 -35.2%、长电 -33.4%），**但涨幅高低与生意质量几乎无关**（涨幅榜是美光 +213%、三环 +183%、Arm +157%、应材 +114%）。**质量定地板，边际定弹性——这是最干净的一次实证。**

电力链的实证更极端——赢家清一色是“卖设备干工程”的（Powell +99%、Quanta +64%、GE Vernova +56%、伊顿 +41% 创新高），输家清一色是“发电卖电讲故事”的（Oklo -40%、NuScale -33%、NRG -26%、Constellation -24%、Vistra -11%）。**“AI 缺电 → 买电力股”这个 2025 年最流行的叙事，2026 年被证伪了——因为**电价受容量拍卖价格上限管制、FERC 又在审查数据中心直连交易，**紧缺没有变成定价权。**

两条链的护城河性质根本不同：半导体是“别人造不出来”（技术垄断，可持续十年），电力是“别人排不上队”（物理排队：燃气轮机档期至 2030、变压器交期 160 周以上、并网 4-7 年）。**所以电力链没有永续 A 档，只有窗口期——判断任何环节只问一句：交期是在拉长还是缩短？**

两份地图共同的最刺眼发现：半导体链里新思科技（EDA）是唯一**“A 档质量 + 深度回调”**的组合（年内 -14.0%、距峰值 -36.2%），被**“AI 杀软件”**的板块叙事误伤，而它的真实需求端正被 AI 拉高——但也要诚实标注，EDA 确实面临**“AI 自动化芯片设计”**的长期威胁，这不是纯误伤。

记忆卡：竞争格局决定你能拿多久，边际变化决定你能赚多快——分不清这两件事，就会在主升浪里空仓、在周期顶上重仓；**结构最差的存储给了 2026 年最好的回报，这不是市场错了，是你问错了问题。**

第十八章 复盘方法论：事件如何映射到板块（含两处事实更正）

你当时的问题：中国的 Kimi 最近很火，中国大模型对美国闭源模型的追赶，这段时间本质上是利好云厂商的，对不对？因为中国打的是开源模型——四大云或新型云可以去部署中国先进的开源模型；之前他们只能部署 Anthropic 或 OpenAI 的模型，定价权和分配权都在模型方，现在部署开源模型，定价权就在他们自己手里。所以短期利空 Anthropic 和 OpenAI、利好云厂商，对吧？我想梳理几条线索：一、Anthropic 发布最新先进模型之后，网络安全板块涨了很多；二、中国开源模型利好云厂商，但可能只是短期，长期不一定站得住；三、甲骨文本质上应划归新型云，因为它靠融资放大规模；而且算力目前普遍供不应求。另外 SpaceX 也在做云和数据中心，甚至把数据中心租给了 Anthropic，对未来 AI 算力增长的预期非常高。我是想通过这些线索复盘，下次遇到类似机会能不能抓到。

18.1 两处事实更正

更正一（本笔记初版的错误，必须留档）：SpaceX 确实是 Anthropic 的算力供应商。初版第七章曾断言“Anthropic 的算力不是租 SpaceX 的，马斯克那边是 xAI 自建集群”——**这是错的**。核实后的事实【第三方】：2026 年 5 月

双方签订云服务协议，Anthropic 获得 COLOSSUS 与 COLOSSUS II 上约 **32.5 万张英伟达 GPU**、田纳西数据中心 **300+ MW 容量**，**每月支付 12.5 亿美元、直至 2029 年 5 月**；双方还在探讨多吉瓦级的**轨道数据中心**。SpaceX 2026 年二季度营收 78 亿美元、同比 **+92%**，其中约 20 亿美元增量来自 AI 业务；与 Anthropic、谷歌、Reflection 的合同到 2029 年合计或超 **760 亿美元**。这些细节公开，是因为 **SpaceX 正在 IPO 申报**。

这条更正对分类有实质影响：第十六章把“新型云”定义为“借债买卡的中间商”，但 SpaceX 不属于这一类——它**自带电力、土地、发射能力和 xAI 的现成集群**，是“重资产 + 自有稀缺要素”的另一个物种。判断一家算力提供商，仍回到那句话：**看它资产负债表上是“卡”多还是“电与地”多**。

更正二（对话中的记忆偏差）：引爆网络安全板块的不是 **Claude 3.5**，是 **Mythos**。Claude 3.5 是 2024 年的模型，当前前沿是 Claude Fable 5。真正的催化是 **2026 年 4 月 7 日的 Mythos**——它展示了前所未见的漏洞发现与利用能力，白宫层面研讨模型发布规则、仅向少数防御方开放；随后 5 月板块两个月涨约 37%，CrowdStrike 单月 +64%、Palo Alto +57%。

为什么这个区别对复盘极其重要：机制不是“发布了强模型 → 安全股涨”，而是“**模型被证明具备攻击能力 → 威胁被重新定价**”。记成前者，下次任何旗舰发布你都会去买安全股，而绝大多数旗舰发布不会引爆安全板块。**要盯的是能力的性质，不是发布本身**。

18.2 “开源利好云”：成立，且比直觉更强

你的机制推导是对的——托管开源模型时，**云不必与模型厂分成，整条 serving 毛利归自己**（对比 Azure 要给 OpenAI 分成、AWS 对 Anthropic 有让利）。

新增一条你没提到的加强证据：Kimi K3（2026-07-26 开源）2.8 万亿参数、100 万上下文、权重文件约 1.4TB、自托管需 8 张 H100 以上【第三方】。由此得出一条反直觉推论——**开源 ≠ 免费部署；模型越大，越必须跑在租来的基础设施上。开源权重反而把更多算力需求推向云。**K3 发布当天 Together AI、Modal 即上线托管抢首发。

受益程度必须分层：

主体	受益	原因
亚马逊（Bedrock 模型超市）	最纯	卖别人的模型不分成，且持有 Anthropic 股权
谷歌	高	自有模型 + TPU + 托管开源，三头吃
推理专门户（Together、Fireworks、Modal）	弹性最大	纯受益，但生意质量最差（零差异化）
微软	最尴尬	OpenAI 敞口最大，而 OpenAI 是消费者模式最脆弱的一家

你说“长期不一定站得住”也对：托管开源模型本身是零差异化商品服务，终将被压到边际成本附近。**长期真正留在云手里的是数据引力那部分（存储、数据库、托管服务），不是 GPU 出租。**

18.3 四条被忽略的传导链

① **开源削弱的不只是模型厂，还有“模型即服务”的分成经济学。**微软—OpenAI、亚马逊—Anthropic 的股权与分成

安排，价值锚定在“闭源模型稀缺”上；开源生态越强，这些股权的期权价值越低——这是四大云的一块隐性资产在缩水，容易被“云受益”的叙事掩盖。

② 开源最大的受益者其实是应用层，不是云。token 成本崩塌的消费者剩余，最终流向“用便宜智能做产品的公司”。历史剧本：带宽降价三十年杀死了电信商的定价权，却造出了谷歌和 Netflix。这与温度地图里“软件/AI 应用在历史最低倍数”是同一格——中国开源是那一格的隐性催化剂，而市场目前只在给云定价。

③ 开源制造了“主权 AI”这条全新的资本开支来源。各国与各受管制行业要“自己可控的模型”，开源权重 + 本地部署是唯一路径——这是一笔完全不经过 OpenAI/Anthropic 的算力订单，中东、东南亚、欧洲都在花这笔钱。

④ 净效应：整条链的利润分配进一步从“模型层”倒向“算力层”。一句话收拢：开源不改变 token 总需求，只改变谁能在这些 token 上收租；而它把租金从模型厂手里，交还给了持有物理资产的人。

18.4 事件→板块映射表（本章最可复用的部分）

事件类型	典型案例	利好	利空	时滞
能力型	Mythos 展示漏洞发现能力	防御方、被验证的下游场景	被替代的环节	1-4 周，最快
结构型	DeepSeek、Kimi K3 开源	房东（云）、应用层、芯片	闭源商品层、分成模式	数月，且必须分层
产能型	GE Vernova 订单、SpaceX-Anthropic 合同	供给方与设备商	——	即时到一个季度

三个可复用的提问（任何 AI 大新闻，按顺序问一遍）：

1. 这个事件改变的是“需求量”还是“利润分配”？

Mythos 改需求量（安全预算真增加）；开源改利润分配（总需求不变，钱换了口袋）。**改需求量的行情快而猛，改利润分配的行情慢而分层。**

2. 谁的定价权被拿走了，那笔钱去了谁的口袋？钱不会消失，只会搬家——顺着搬家路径找受益方，比顺着新闻标题找靠谱。

3. 位置对不对？叙事发生时受益方是不是已经涨过了（回到“方向 × 位置”）。

18.5 反面清单：三类“看起来受益”但不要买

无现金流的纯概念（Oklo -40%、NuScale -33% 的剧本）

| **高杠杆的中间商**（新型云、甲骨文——你把甲骨文归为新型云完全正确）| **被监管锁住定价权的资源方**（IPP 剧本：Constellation -24%，缺电是真的，但涨价不许传导）。

当下可盯的四个读数：Bedrock/Vertex 上开源模型调用占比的任何披露（验证“云受益”是否变成收入）| 推理专门户的融资与营收（开源红利最纯的温度计）| **SpaceX 招股书**（将首次公开披露 AI 算力业务的完整经济学，是这条链信息量最大的一份文件）| 10 月底四大云 2027 capex 指引。

记忆卡：能力型事件改需求、结构型事件改分配、产能型事件改交期——先认出是哪一类，再去找钱搬到了谁家；而任何一条结论，都要留出“我可能记错了催化剂”的余地。

附录：一句话记忆卡合集

主题	一句话
本轮云厂行情	backlog 估值法替代 FCF 估值法，根基在 token 定价
好的提问	自带可证伪结构，先拆确认题、再邀请挑 bug
事实基线	token 单价三年 -88%，ARR 反而暴涨——量价已共存三年
Bug 1	“1% 价格”与“80% 能力”不同时成立，同档价差是 3-5 倍级
Bug 2	能力差距在 agent 循环里复利放大，错误成本翻转总成本
Bug 3	量价是赛跑不是判决，赛跑要盯不能预设结局
Bug 4	廉价化杀模型毛利，不杀算力需求——分清谁赚钱与建不建
Bug 5	合规与主权是真实摩擦力，渗透主战场在长尾与第三方市场
洗牌次序	先洗中间层（套壳/二线模型/高杠杆新型云），后及核心
历史对照	2000 年电信：长期对、中期崩，可以同时成立
判定点	10 月底 2027 CAPEX 指引 + 单价 vs 用量赛跑
88% 降价	跌的是旧能力的价格，旗舰标价很粘；成本降速 $\geq$ 售价降速 = 健康
租金三层	旧代际跌、当期涨 40%、每 token 靠效率——多米诺第一张牌是租金指数转跌
开源锁价	开源是自废定价权的承诺装置，金主在别处赚——token 永远不需要涨价
CAPEX 纪律	军备竞赛不被数据终结，只被股东终结——盯财报日股价反应
算法拐点	效率差会被学走，商业模式差留 2 倍后停住；终局是寡头不是平权
订阅对冲	自助餐不怕大胃王；通缩在 API 是敌人、在订阅是毛利
需求分母	渗透率分母是“还没被替代的工资”，不到 1%；增长主引擎是加深不是拉新
下一个编程	去有“编译器”的行业找：账要平、案要赢、单要成——会计最像
杠杆倍数	0.2-0.6 倍等于没负债；四大不会因还不起钱停建，只会因股东不答应停建
CAPEX 通胀税	名义涨的是账单、真实涨的是产能；+40% 名义扣完税是负增长
倒挂	你锁的价比市价还贵——对零杠杆是波动，对高杠杆是死亡诊断书
借来的弹性	新型云是四大云的 2-4 倍弹性，利息是波动；买它是买弹性不是买公司
云的真问题	不问“云好不好”，问“收入里客户搬得走的有多少”
房东+期权	四大云既收模型厂房租，又持有模型厂股权——赢了分成，输了还有房子
两把尺子	格局管持有、边际管弹性；存储结构最差却给了最好回报
两条护城河	半导体是“造不出来”，电力是“排不上队”——后者只有窗口期

主题	一句话
电力链证伪	缺电是真的，买电力股是错的——紧缺没变成定价权
事件三分类	能力型改需求（快）、结构型改分配（慢且分层）、产能型改交期
复盘三问	改需求还是改分配？钱搬到谁家？位置对不对？
开源不等于免费	K3 权重 1.4TB、需 8×H100——模型越大越必须租云
算力商分类	看资产负债表上是“卡”多还是“电与地”多（SpaceX 属后者）
催化剂要认准	不是“发布强模型”，是“模型被证明有攻击能力”——性质比事件重要

免责声明与利益相关：本笔记为个人学习整理，基于 2026 年 8 月上旬的公开信息与第三方数据（Artificial Analysis、Silicon Data、Epoch AI、Menlo Ventures、Counterpoint、CNBC、USCC 等，均为第三方口径，部分来源数字互相冲突处已注明“口径不一”）；外部解读内容归其原作者。分析方为 Anthropic 旗下模型 Claude，与讨论对象存在利益相关，已尽量以第三方数据为准，读者应保留独立判断。本笔记不构成任何投资建议；据此操作，盈亏自负。